Segmentazione (di basso livello)

Segmentazione

La segmentazione può avere obiettivi diversi a seconda della specifica applicazione.

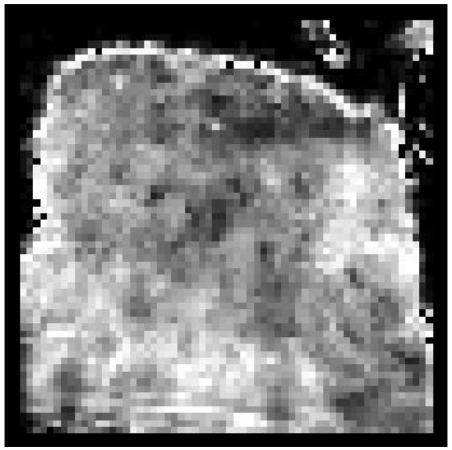

separazione di uno o più oggetti di interesse dallo sfondo

Segmentazione: superpixel

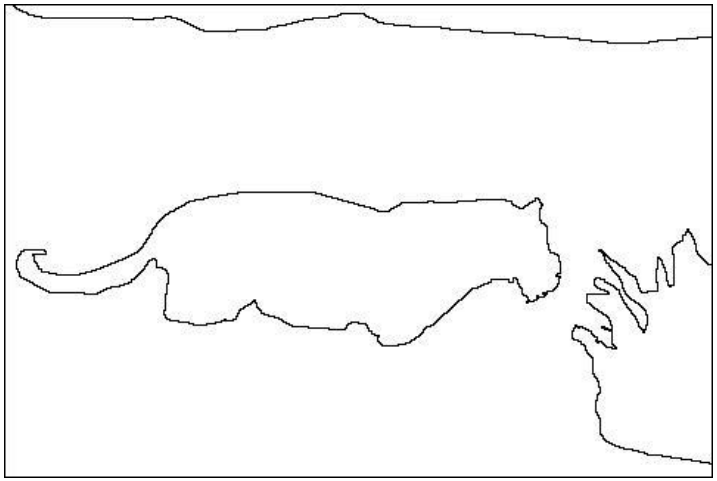

partizionamento
dell'immagine in regioni
con proprietà comuni

Segmentazione oggetto/sfondo

Può essere un compito a volte semplice ma talvolta anche molto complesso:

Caso Semplice

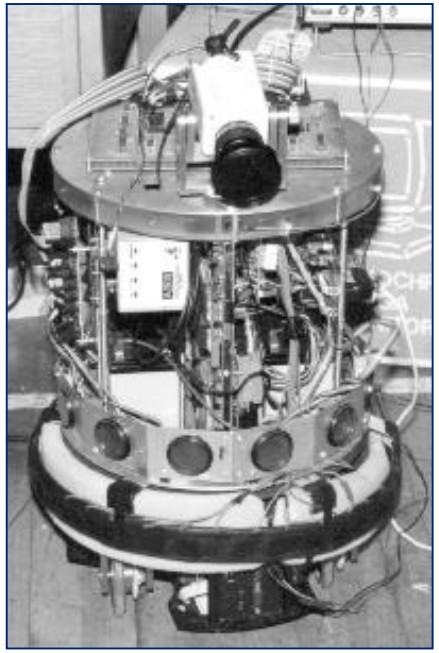

Caso complesso !

Binarizzazione con soglia/e globale/i

- Nel caso di una singola soglia globale T (es. un solo oggetto), il metodo consiste nell'impostare a 0 i pixel la cui intensità è inferiore a T e a 1 i rimanenti.

$$\boxed{\mathrm{NewI}[x,y] = \begin{cases} 0 & \mathrm{I}[x,y] < T \\ 1 & \mathrm{I}[x,y] \geq T \end{cases}}$$

- Sebbene molto semplice il metodo presenta i seguenti problemi:
  - scelta automatica della soglia/e ottimale/i
  - non corretta gestione di sfondi a intensità variabile (es. gradienti luce).
  - incapacità di segmentare oggetti non uniformi

Segmentazione colore: esempio

Localizzazione del **volto** e delle sue componenti interne:

- nello spazio RGB le diverse regioni del volto non sono spazialmente raggruppate, mentre in HSI si notano cluster ben evidenti per bocca, occhi, pelle, ... e quindi è relativamente semplice isolare tali caratteristiche.

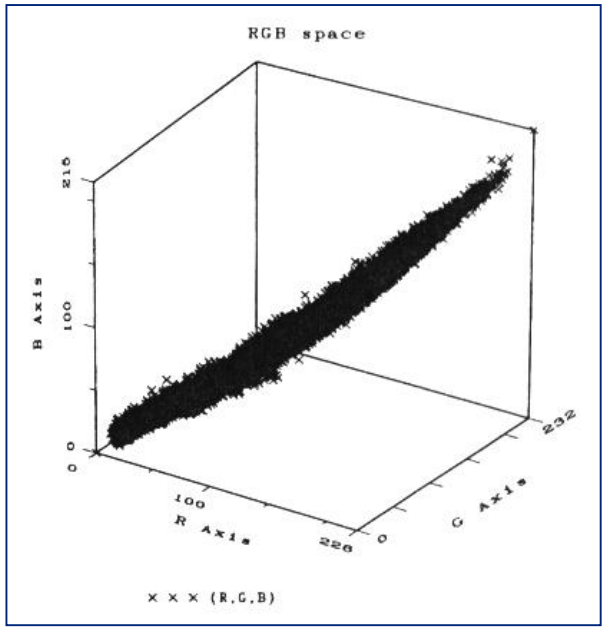

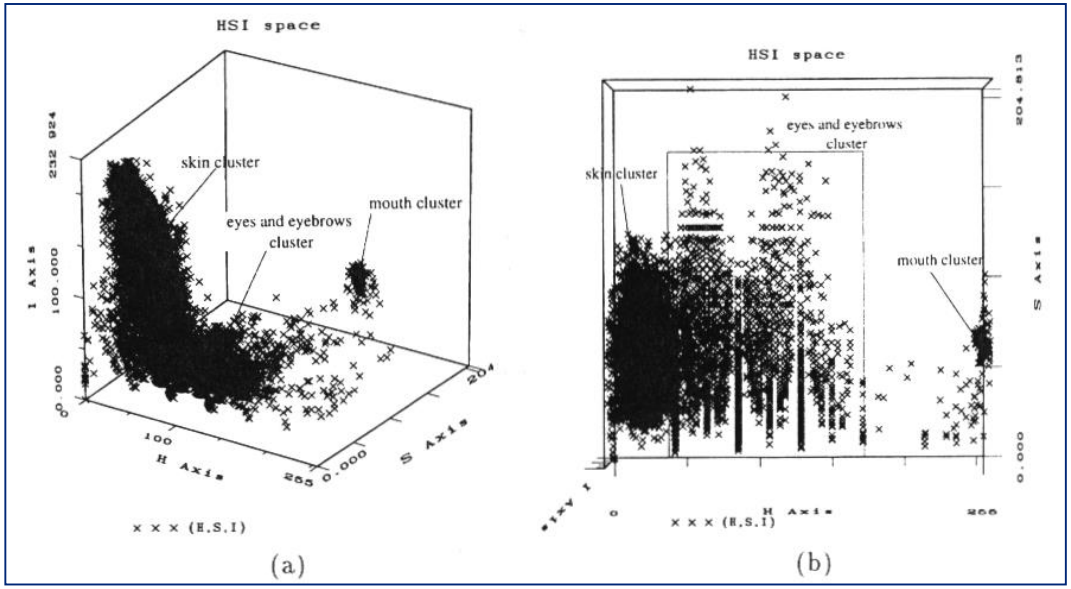

Segmentazione colore (1)

- L'utilizzo di **tecniche empiriche** per estrarre le regioni dello spazio colore che contengono gli oggetti che si vogliono segmentare non è raccomandabile (tranne nei casi molto semplici) in quanto:
  - risulta difficilmente generalizzabile, costringendo a noiose e critiche tarature manuali se le condizioni (luce, tipo di immagine, ecc…) cambiano.
  - l'impiego di parallelepipedi per racchiudere l'insieme di pixel di interesse (che porta a ottenere range indipendenti di ammissibilità per ciascuna componente dello spazio colore, es. 50<R<60, 100<G<120, 90<B<140), non porta a risultati molto accurati.

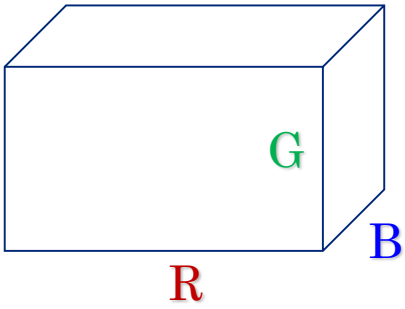

Segmentazione colore (2)

- Molto meglio **etichettare** manualmente (ad esempio racchiudendo con poligonali) le regioni di interesse su alcune immagini di training e lasciare a un **classificatore** il compito di individuare la sottoregione (anche non connessa) dello spazio colore. Terminato il training, il classificatore addestrato potrà essere utilizzato per segmentare nuove immagini:
  - il procedimento può essere agevolmente ripetuto anche se le condizioni cambiano (sufficiente etichettare qualche esempio anche delle nuove immagini).
  - i classificatori possono derivare regioni di forma anche molto complessa (attenzione però alla generalizzazione ...).

Esempio con classificatore

Pixel appartenenti al volto (foreground) definiti come pixel interni ai 3 poligoni marcati a mano

Esempio con classificatore

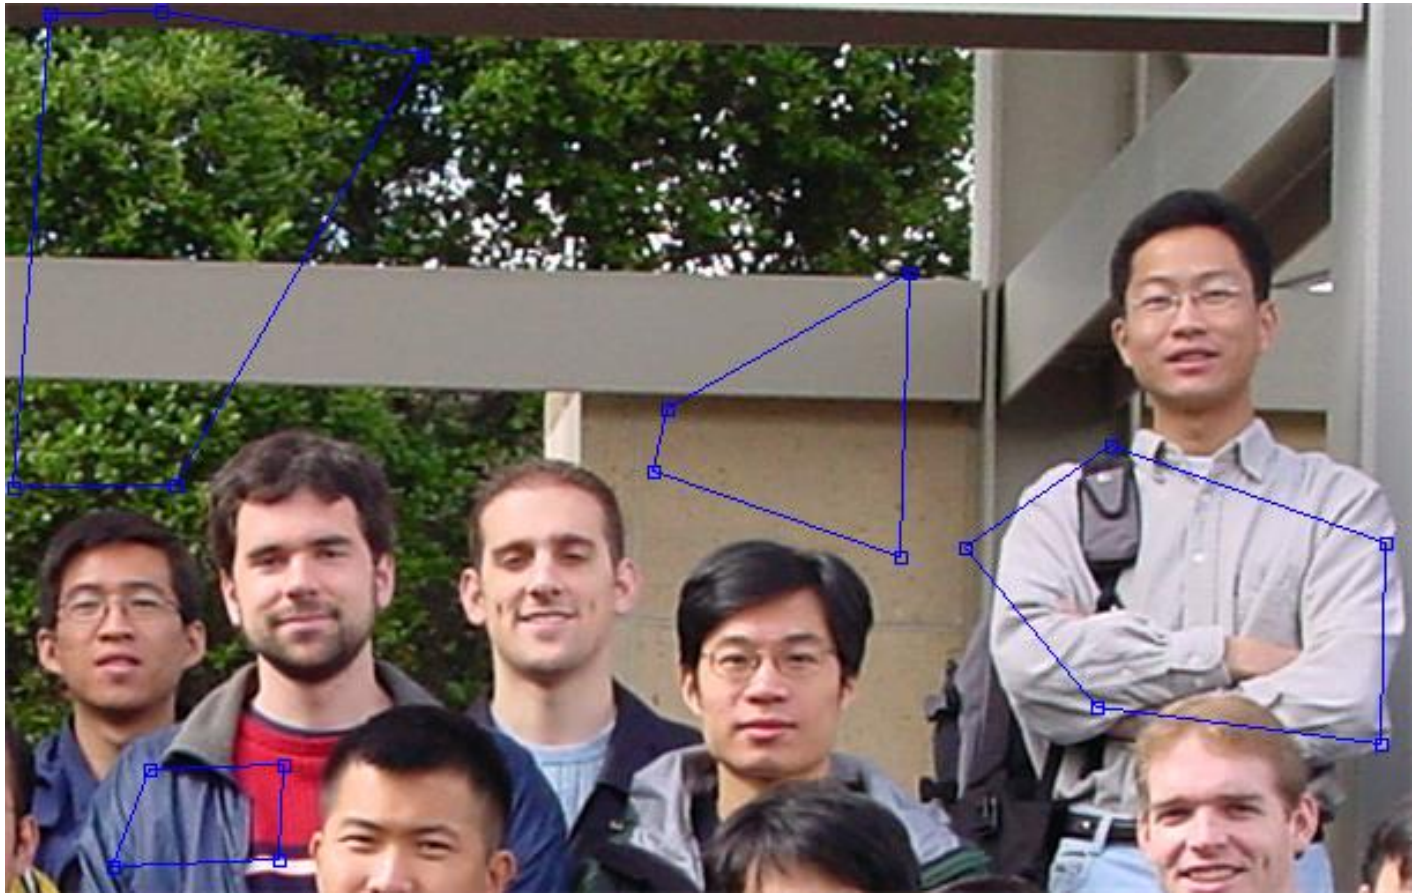

Pixel non appartenenti al volto (background) definiti come pixel interni ai 4 poligoni marcati a mano

Esempio con classificatore

I pixel del training set in una vista 2D (RG) dello spazio RGB: foreground (rossi) background (blu)

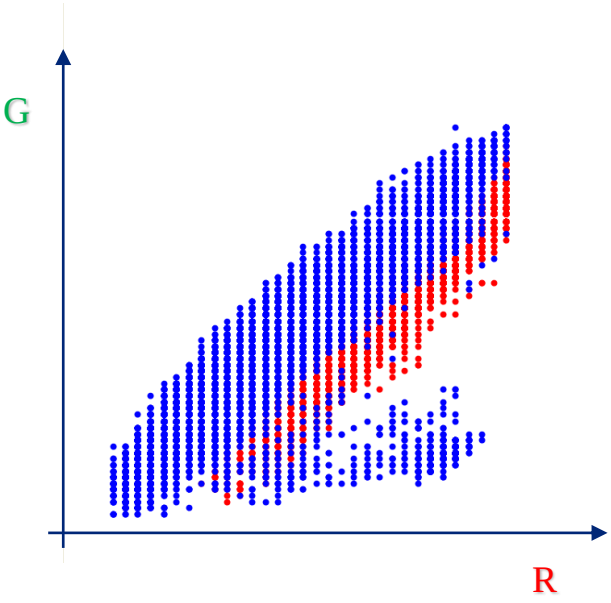

Un classificatore bayesiano parametrico con distribuzioni multinormali è addestrato a separare le due classi in RGB e applicato a una nuova immagine:

Risultato

Risultato sovrapposto all'immagine

Esempio verde pubblico

Verde Pubblico in un quartiere di Cesena

Esempio verde pubblico

Non “Verde Pubblico” sullo stesso quartiere

Esempio verde pubblico

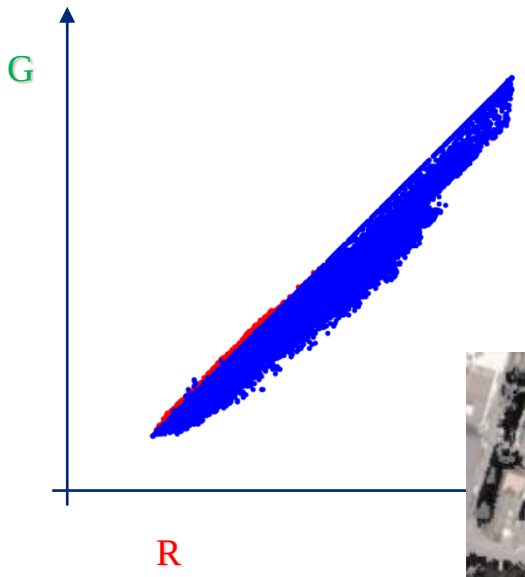

Un classificatore bayesiano parametrico con distribuzioni multinormali è addestrato a separare le due classi in RGB e applicato a una nuova immagine:

Morfologia matematica

- La morfologia matematica, derivata dalla teoria degli insiemi, offre strumenti che consentono di estrarre informazioni utili per rappresentare la forma degli oggetti e rimuovere particolari irrilevanti.
- Lavora solitamente su immagini binarie (Foreground/Background).
- Esistono due principali operatori morfologici:
  - **Dilatazione** (dilation): espande gli insiemi connessi di pixel di foreground (aumentare le dimensioni degli oggetti, riempire buchi o zone vuote).

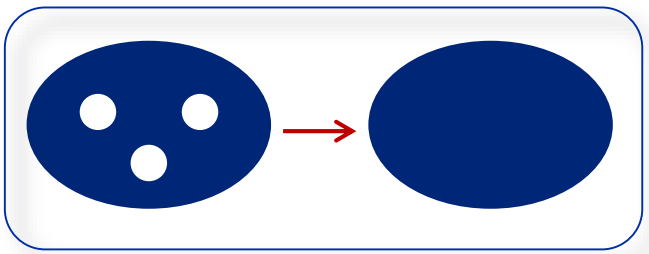

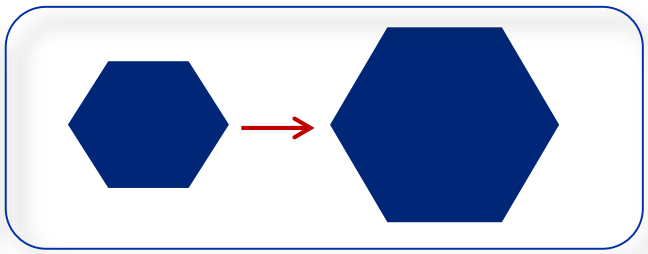

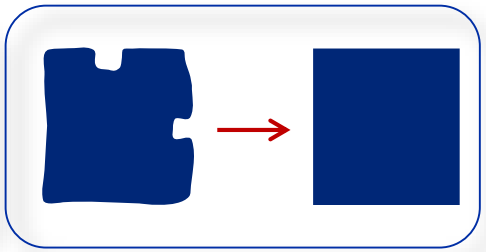

  - **Erosione** (erosion): contrae gli insiemi connessi di pixel di foreground (assottigliare gli oggetti, separa oggetti debolmente connessi).

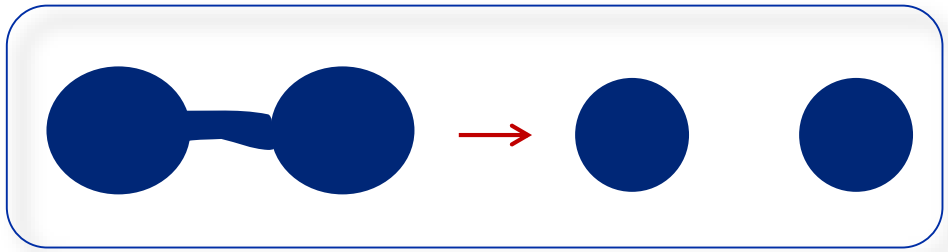

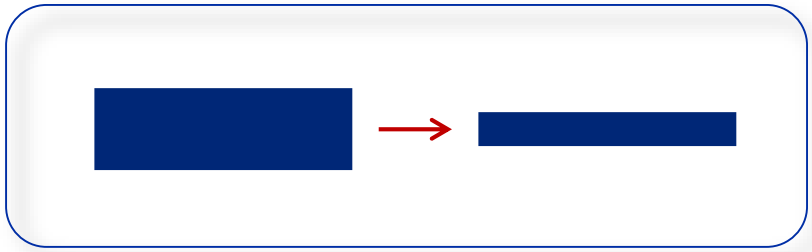

L'elemento strutturante

- Gli operatori morfologici modificano il contenuto dell'immagine binaria applicando un *elemento strutturante S* che può avere una qualsiasi forma rappresentabile tramite una maschera digitale.
- Solitamente si utilizzano elementi strutturanti circolari o quadrati.

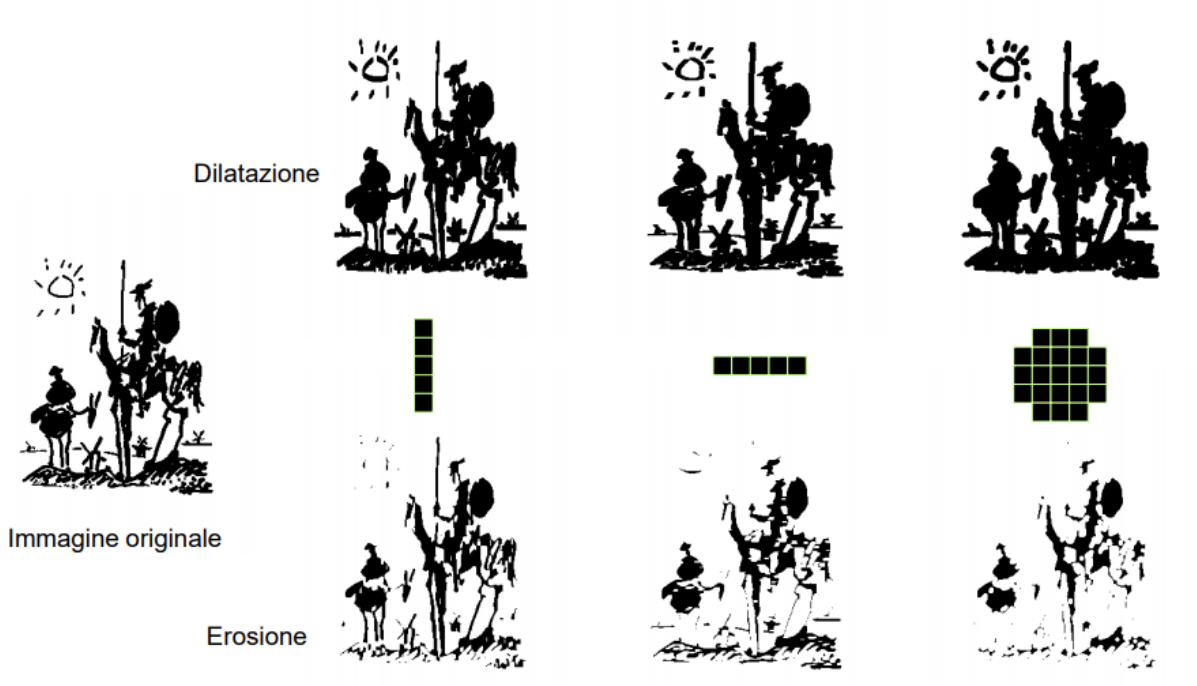

Erosione

- Data un'immagine binaria F e un elemento strutturante S, l'immagine risultante avrà valore di foreground nei pixel tali che, traslando in essi S, l'intero elemento strutturante è contenuto in F:

$$F \ominus S = \{q | (S)_q \subseteq F\}$$

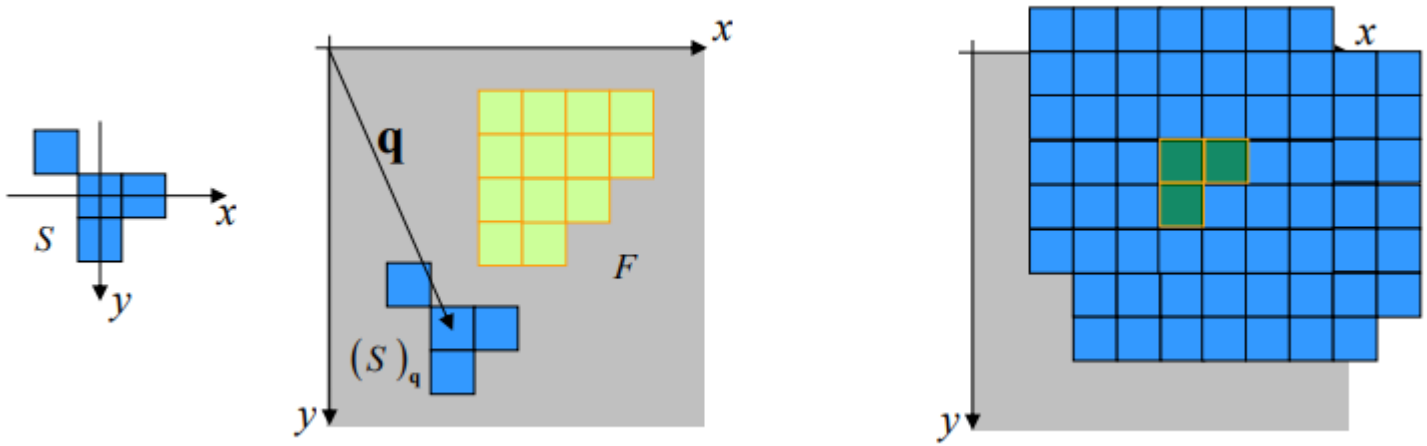

Dilatazione

- Data un'immagine binaria F e un elemento strutturante S, l'immagine risultante avrà valore di foreground nei pixel tali che, traslando in essi S^r, almeno uno dei suoi elementi è contenuto in F:

$$F \oplus S = \{q | (S^r)_q \cap F \neq \emptyset\}$$

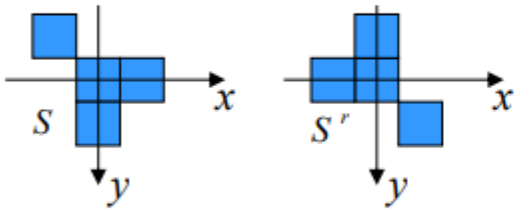

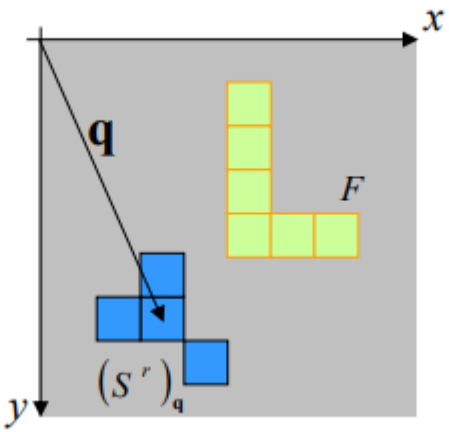

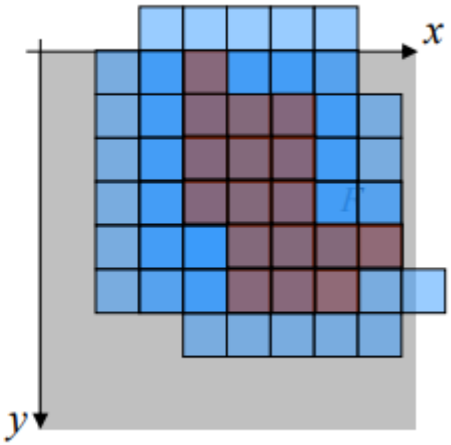

Opening e closing

Combinando erosione e dilatazione si possono ottenere altre operazioni:

- ***Apertura*** (opening):
  erosione + dilatazione
  - Separa oggetti debolmente connessi e rimuove regioni piccole

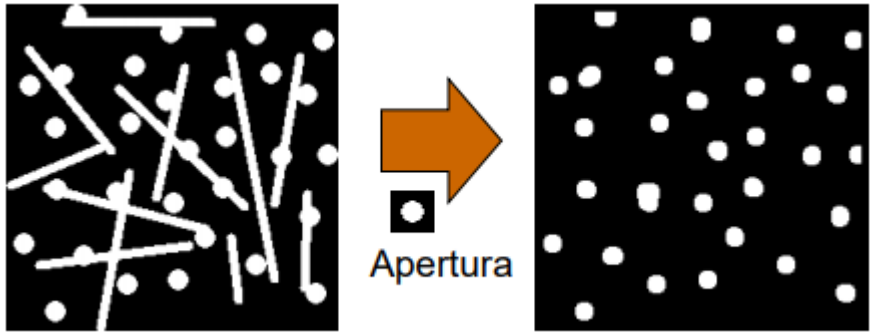

- ***Chiusura*** (closing):
  dilatazione + erosione
  - Riempie buchi e piccole concavità e rafforza la connessione di regioni unite debolmente

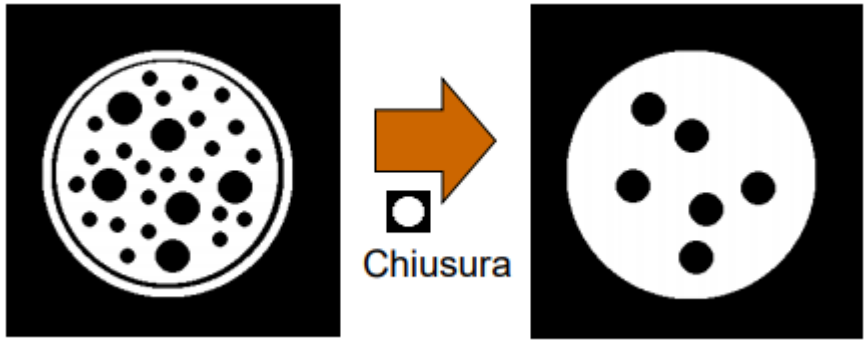

Impiego di edge per la segmentazione

Nei casi in cui lo sfondo è sufficientemente uniforme ma gli oggetti non sono caratterizzati da intensità (grigi) o colori uniformi, l'impiego di edge può aiutare nella segmentazione.

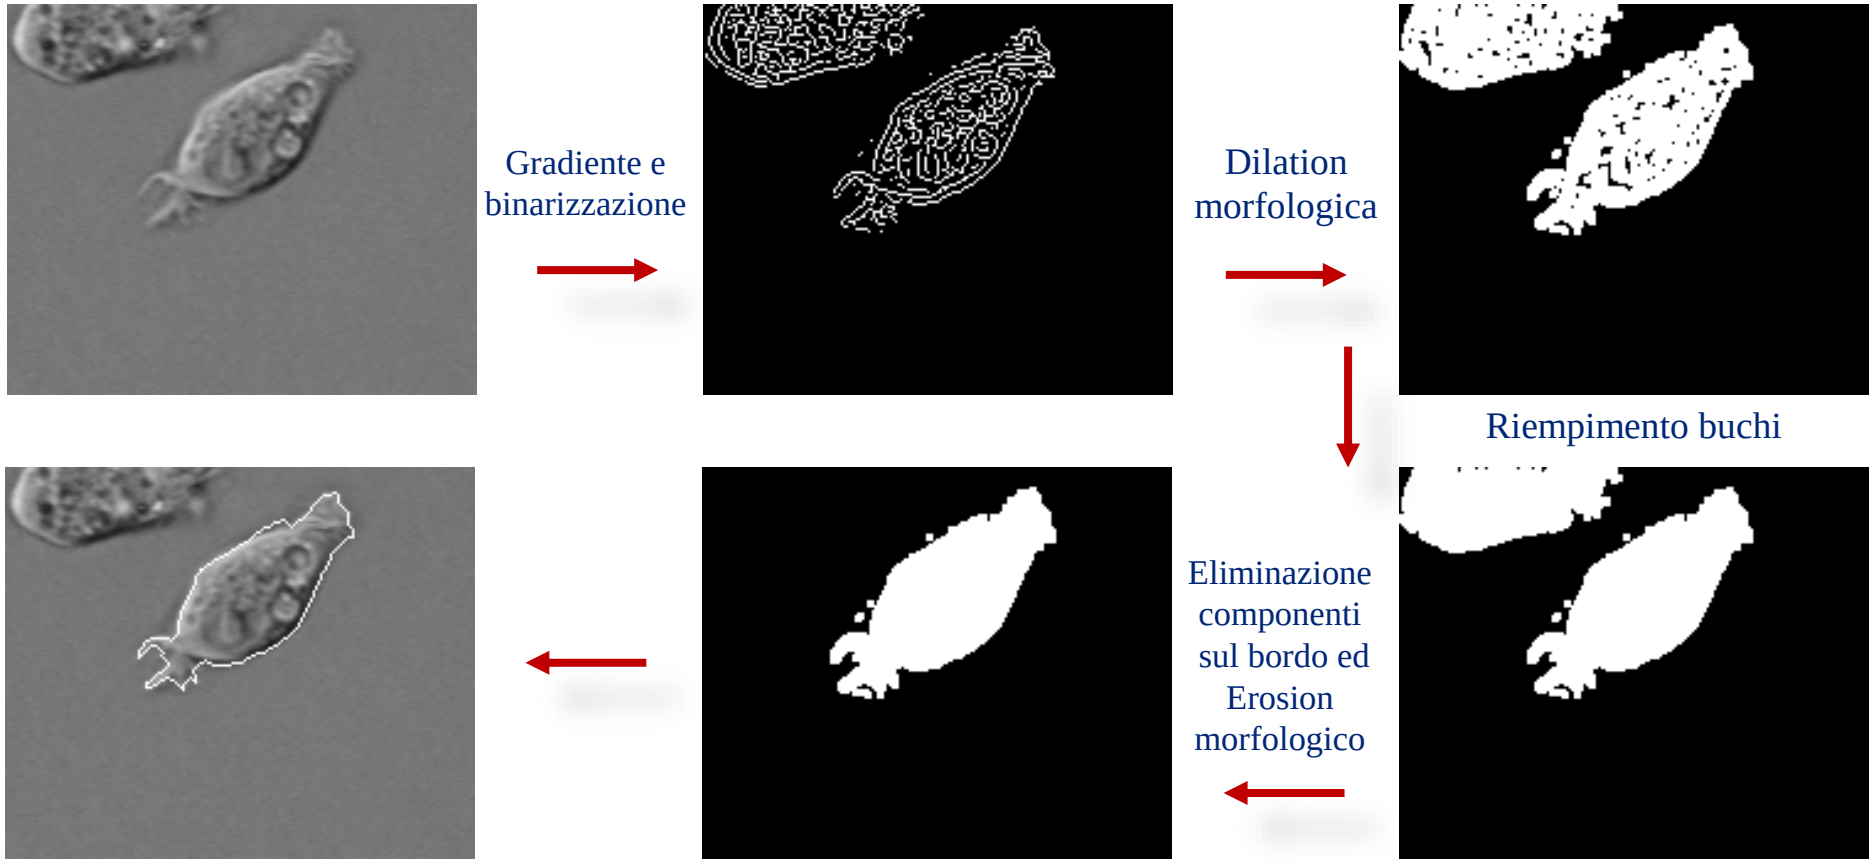

Segmentazione in presenza di rumore

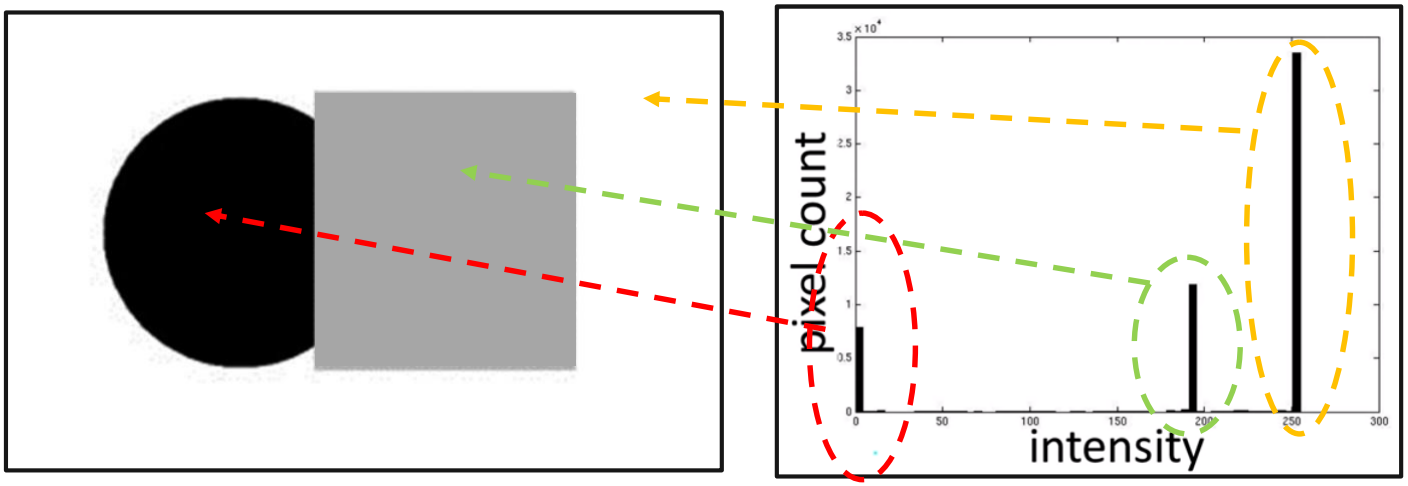

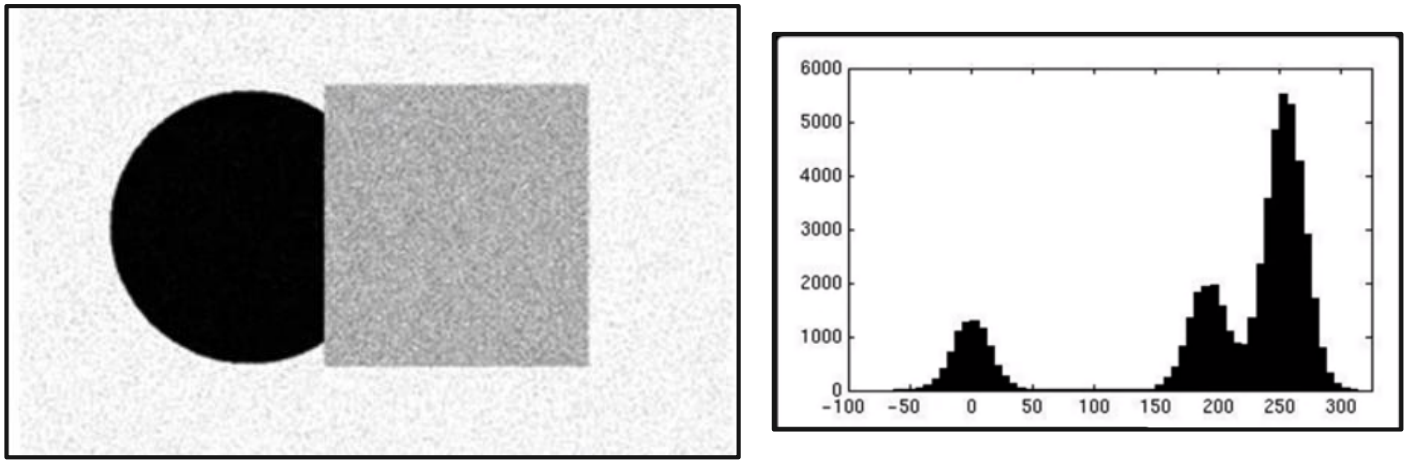

Segmentazione tramite clustering (1)

- Gli oggetti di interesse possono essere individuati applicando algoritmi di clustering (es. K-Means).
- La scelta dello spazio delle feature è fondamentale.
- Supponiamo di utilizzare solo il valore di intensità.

Feature space 1D

I migliori centroidi sono quelli che minimizzano la *Sum of Squared Distances*:

$$SSD = \sum_{cluster\ C_i} \sum_{p_j \in C_i} \|p_j - c_i\|$$

K-means clustering

Conoscendo i centroidi, quali punti saranno assegnati a ogni cluster?

Conoscendo l'attribuzione ai cluster come determinare i centroidi?

Algoritmo

1. Inizializza casualmente i centri dei cluster
2. Assegna i punti ai cluster:
   - Per ciascun punto p, trova il cluster più vicino c_i e assegna p al cluster c_i
3. Sulla base dell'assegnamento effettuato al passo 2 ricalcola i centroidi di ciascun cluster:
   - Calcola c_i come media dei punti assegnati al cluster
4. Se i cluster sono stati modificati, ripeti dal passo 2.

Segmentazione tramite clustering (1)

- Gli oggetti di interesse possono essere individuati applicando algoritmi di clustering (es. K-Means).
- La scelta dello spazio delle feature è fondamentale.

- Supponiamo di utilizzare solo il valore di intensità.

Feature space 1D

K = 2

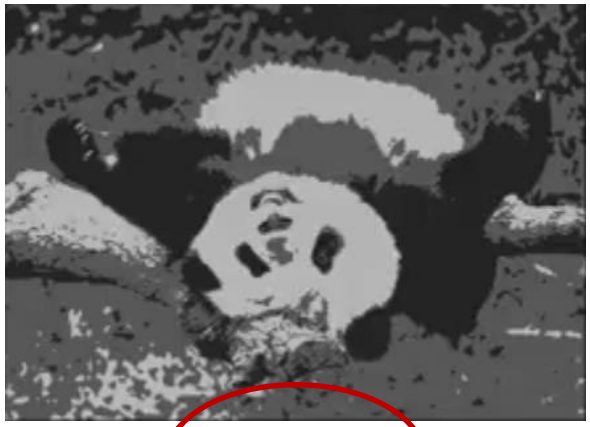

K = 3

Segmentazione tramite clustering (2)

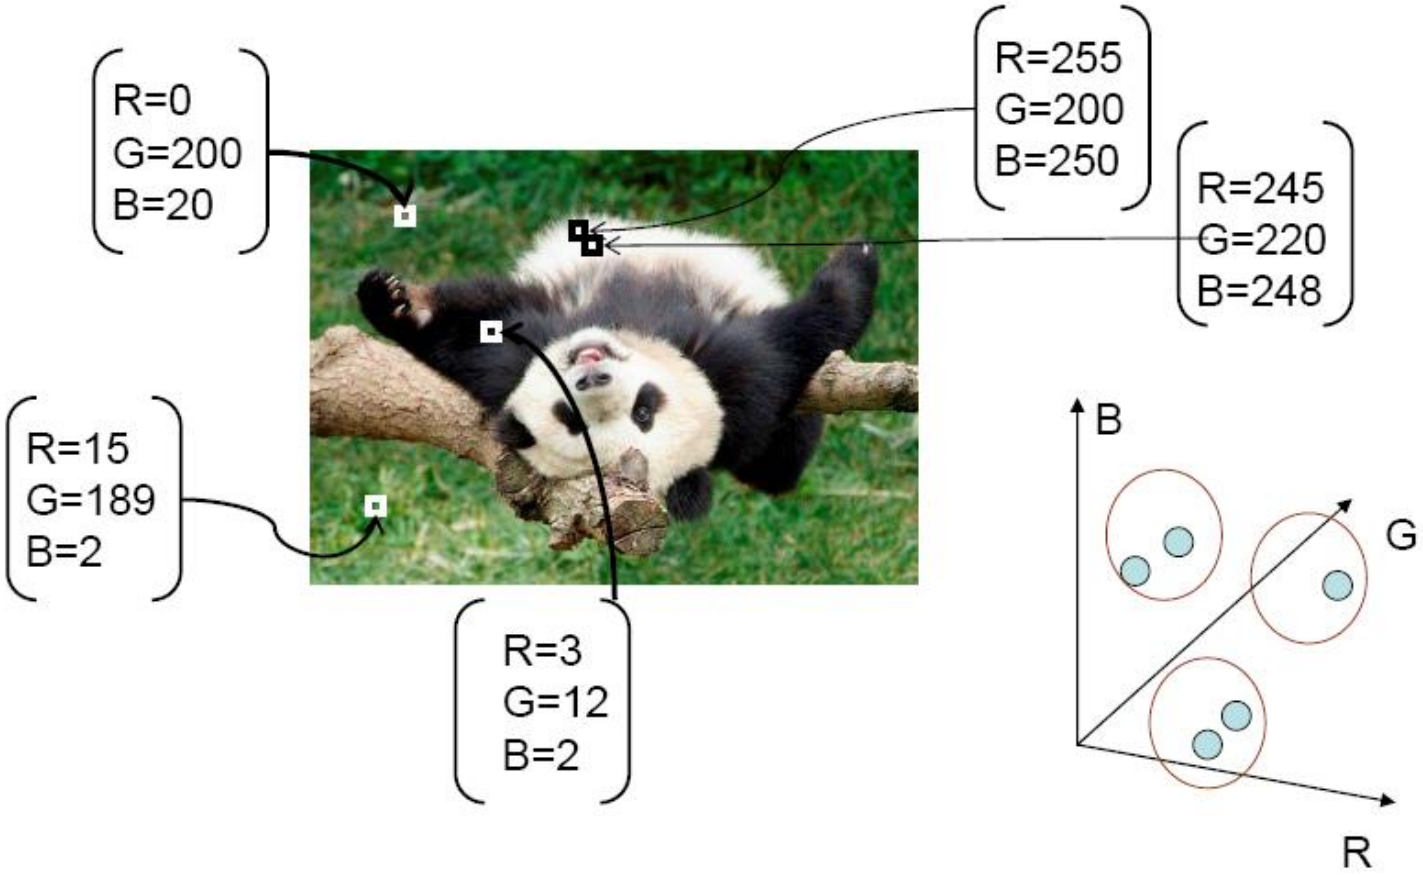

Segmentazione tramite clustering (3)

- Un feature space più rappresentativo consente di ottenere risultati migliori

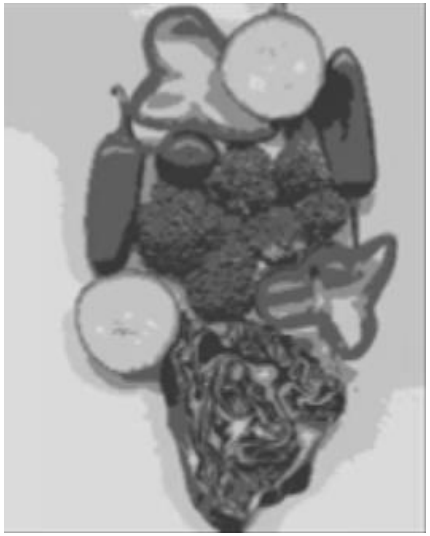

solo intensità

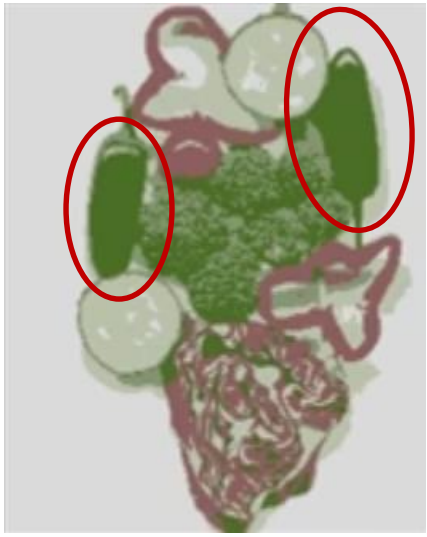

Colore (RGB)

- Problema: oggetti distanti possono essere assegnati allo stesso cluster…
- Soluzione: codificare nello spazio delle feature anche informazioni spaziali (ma anche tessitura, gradiente, ecc…)

K-means: pro e contro

- Pro:
  - Algoritmo molto semplice;
  - Converge a un minimo locale della funzione errore;

- Contro:
  - Elevata complessità computazionale;
  - Necessità di definire il valore di k;
  - Sensibile alla scelta iniziale dei centroidi;
  - Sensibile alla presenza di outlier;
  - Individua cluster di forma "sferica" (non ottimale per alcune distribuzioni di pattern)

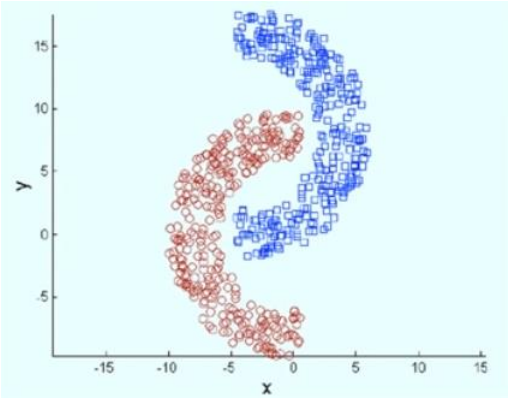

Mean shift

L'algoritmo Mean Shift ricerca i massimi locali di densità nello spazio delle feature

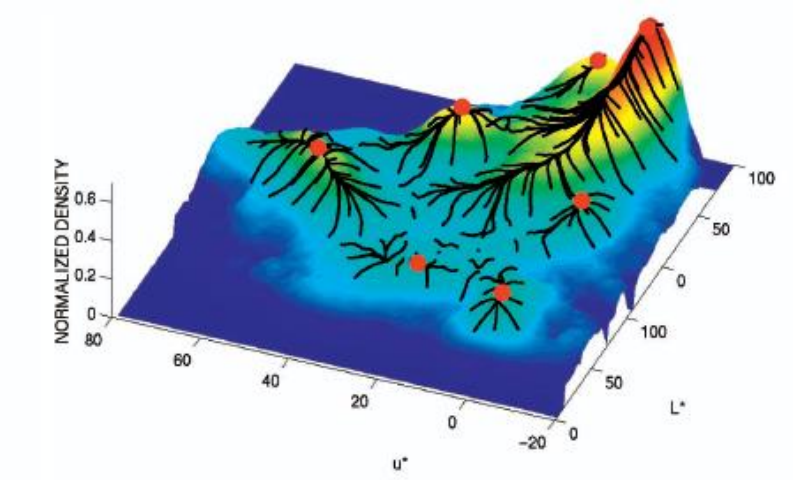

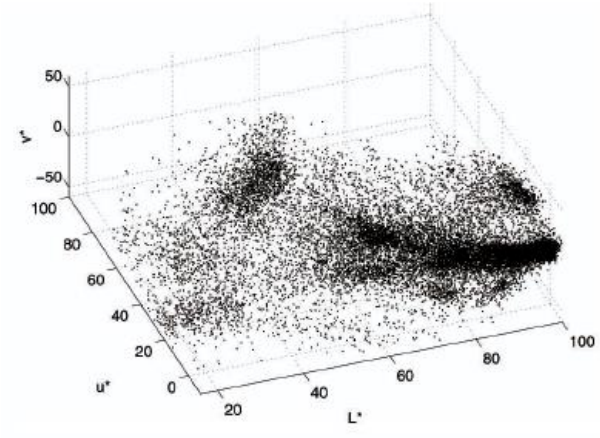

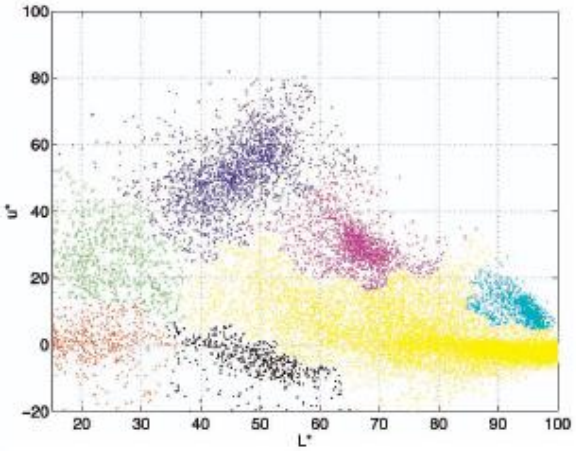

L'algoritmo Mean Shift

- Mean Shift è un algoritmo iterativo che considera lo spazio delle feature come una densità di probabilità empirica.
- L'input all'algoritmo è un insieme di punti che possono essere considerati come campioni estratti dalla densità di probabilità in oggetto.
- Se esistono regioni «dense» (cluster) di punti, esse corrispondono alla «moda» (massimo locale) della distribuzione di probabilità. Scopo dell'algoritmo è individuare questi punti di massimo locale.
- Ad alto livello l'algoritmo può essere descritto come segue:

1. Fissa una finestra attorno a ciascun punto;
2. Calcola la media dei dati all'interno della finestra;
3. Sposta la finestra centrandola sulla nuova media;
4. Ripeti i passi precedenti fino a convergenza

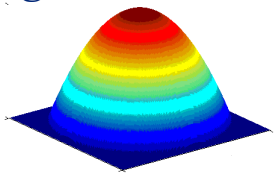

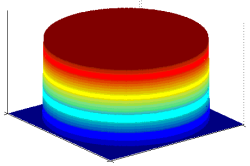

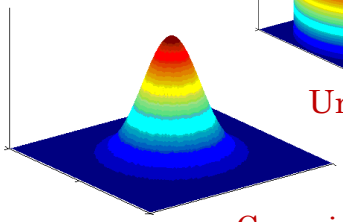

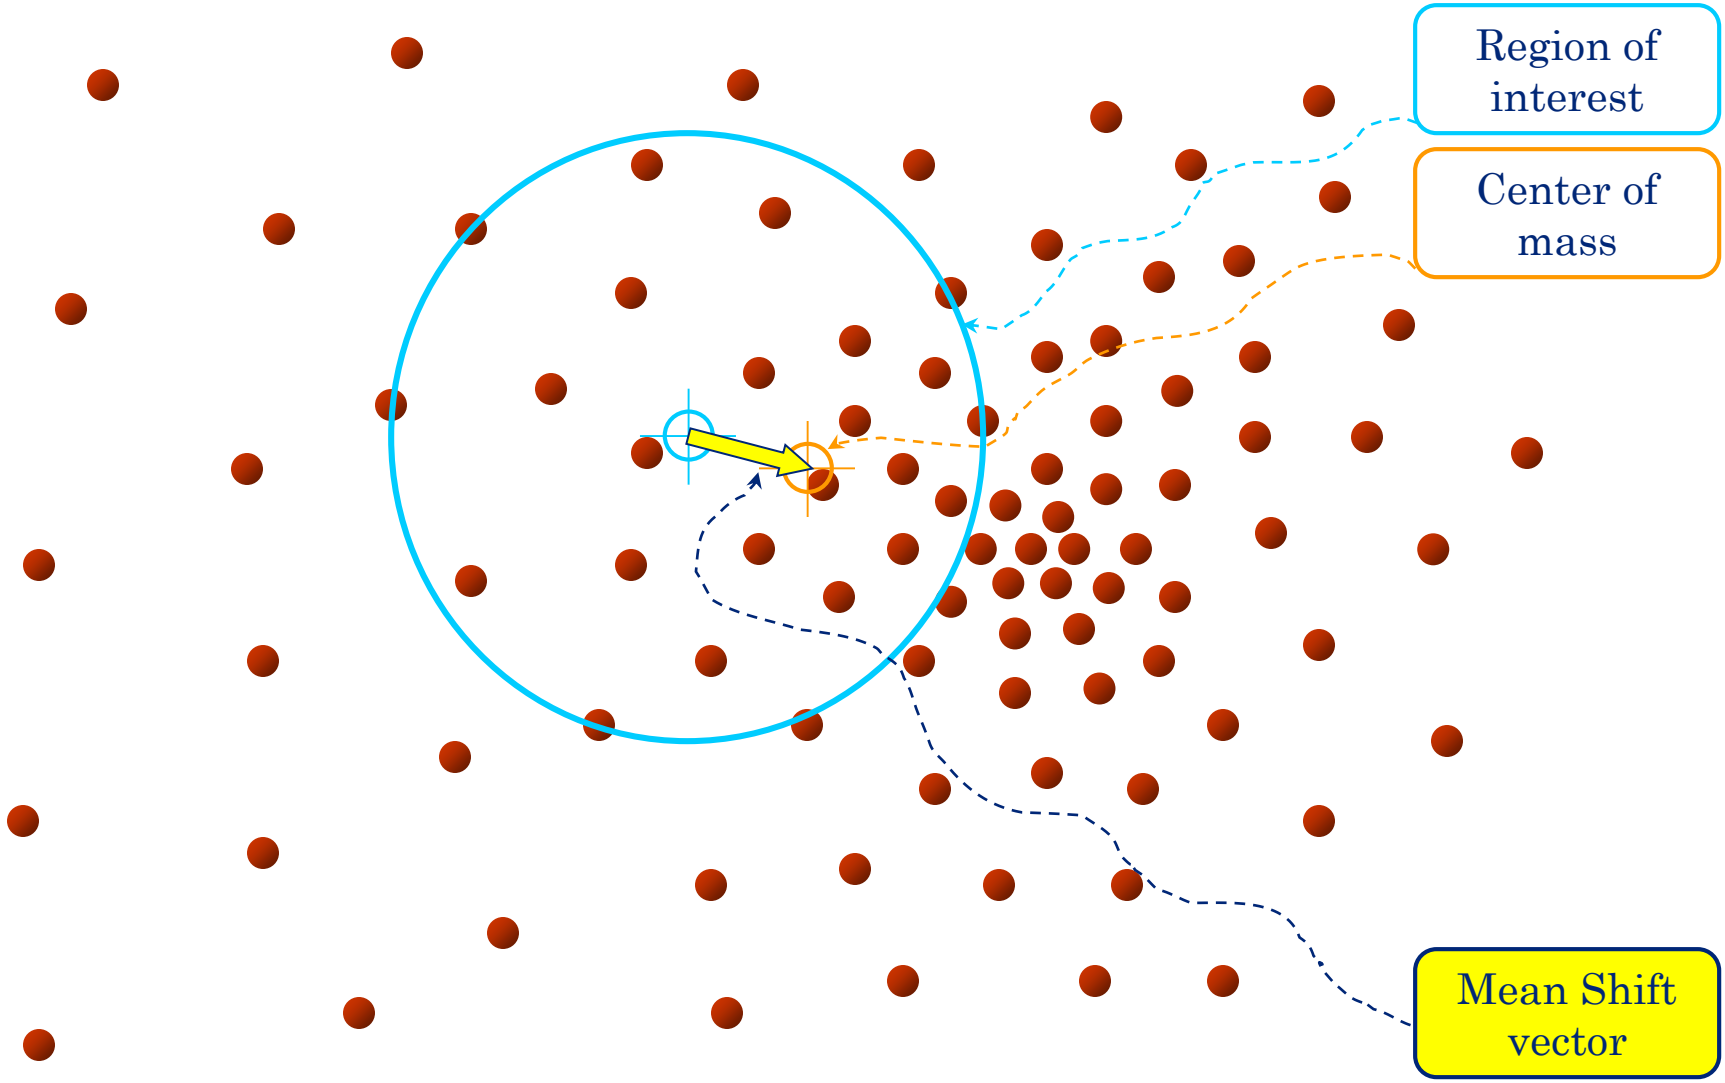

<u>Obiettivo</u>: Trovare la regione più densa

From "Mean Shift Theory and Applications", presentation for "Advanced Topics in Computer Vision" course, Weizmann Institute.

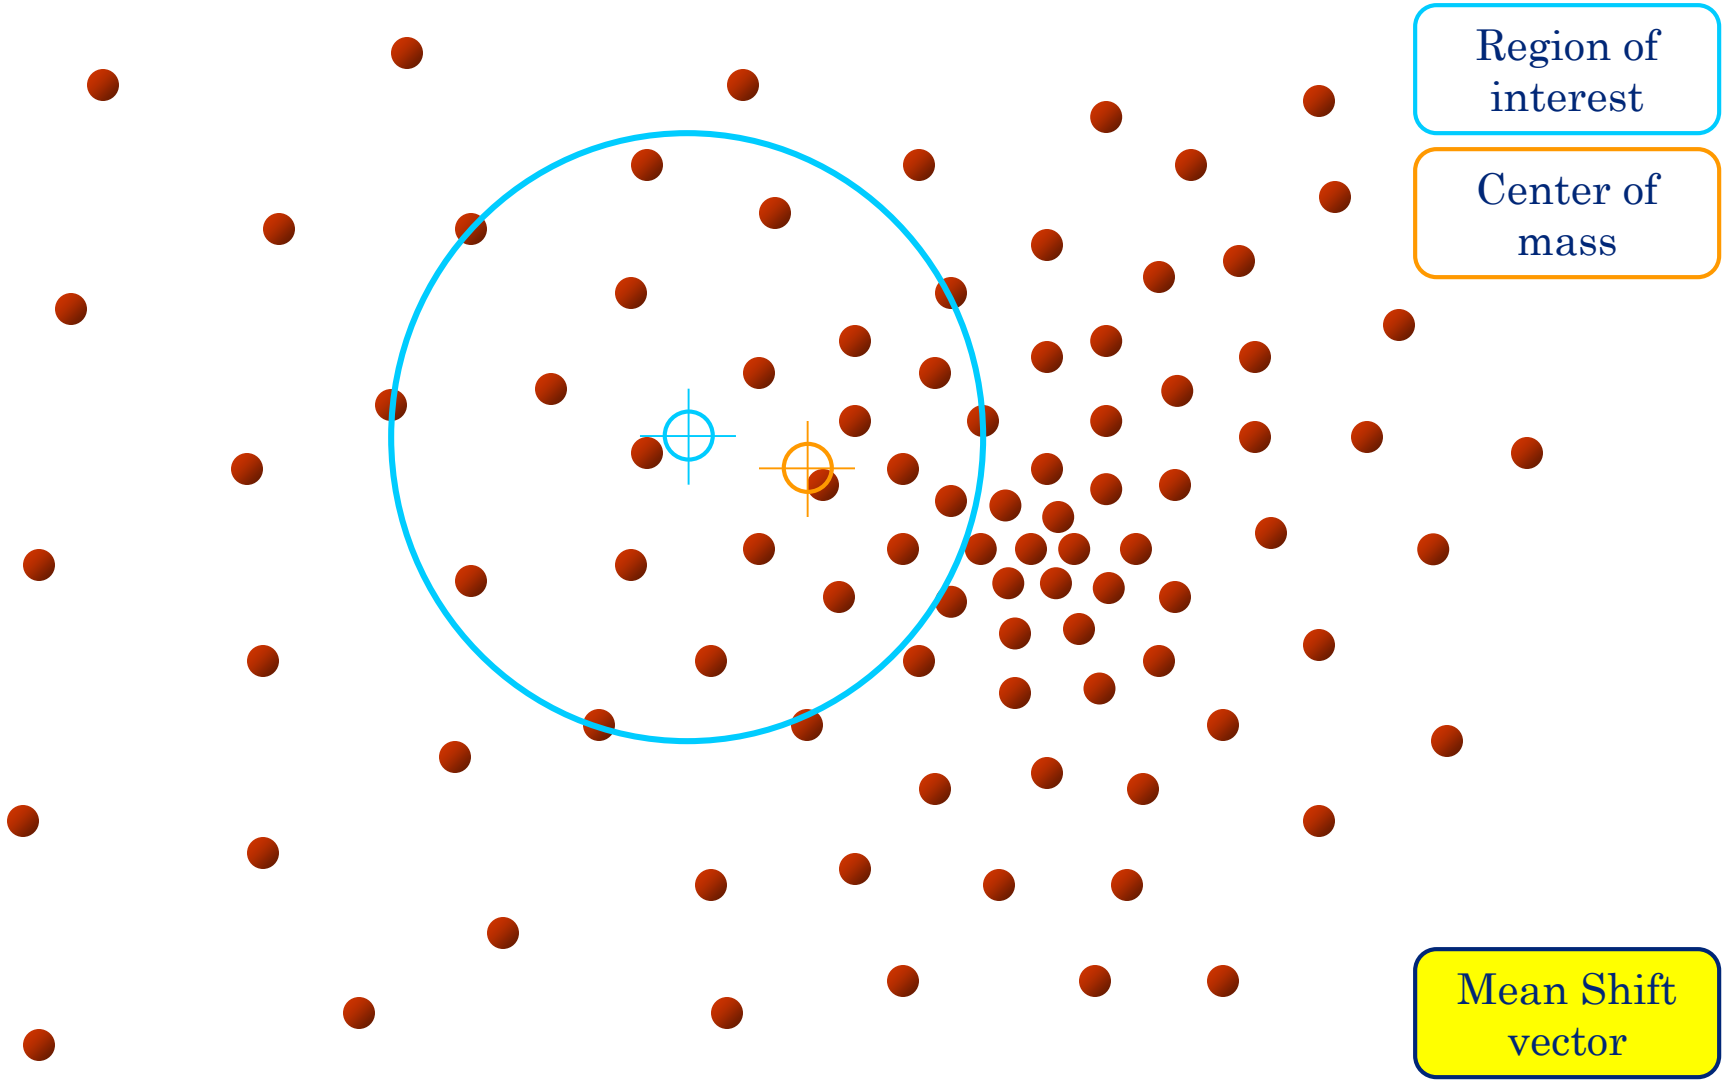

Obiettivo: Trovare la regione più densa

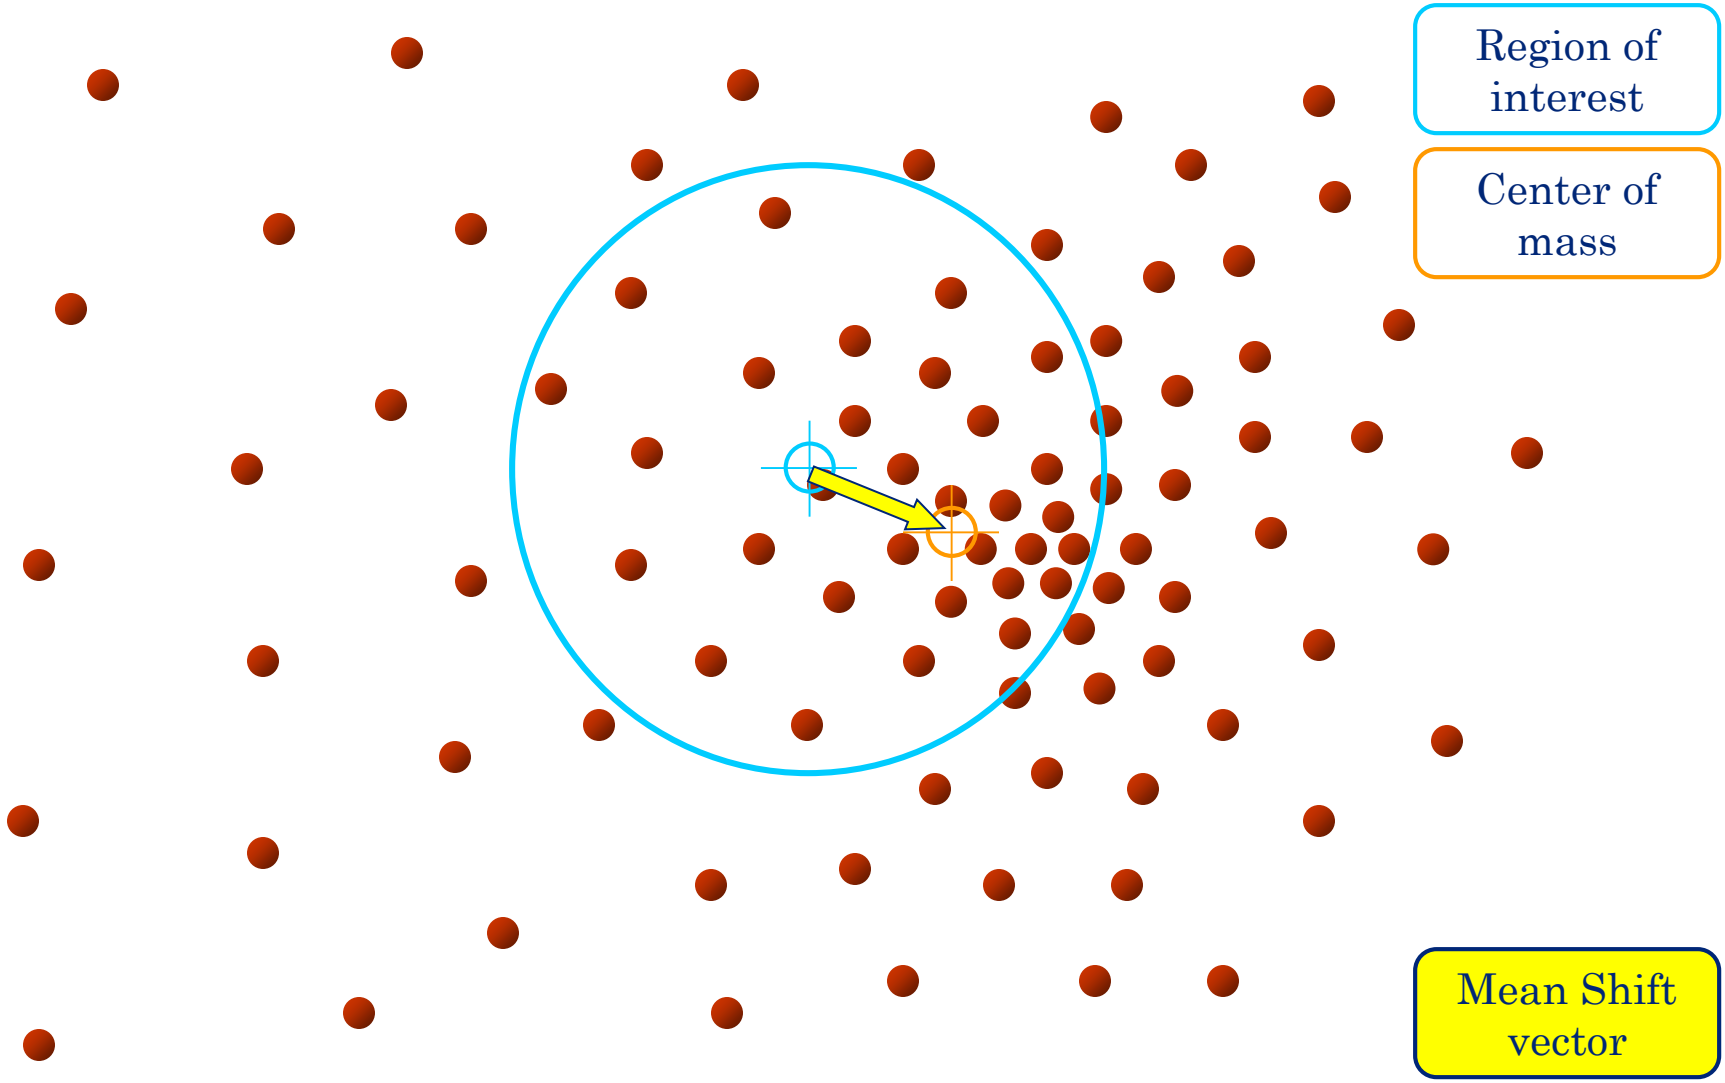

Obiettivo: Trovare la regione più densa

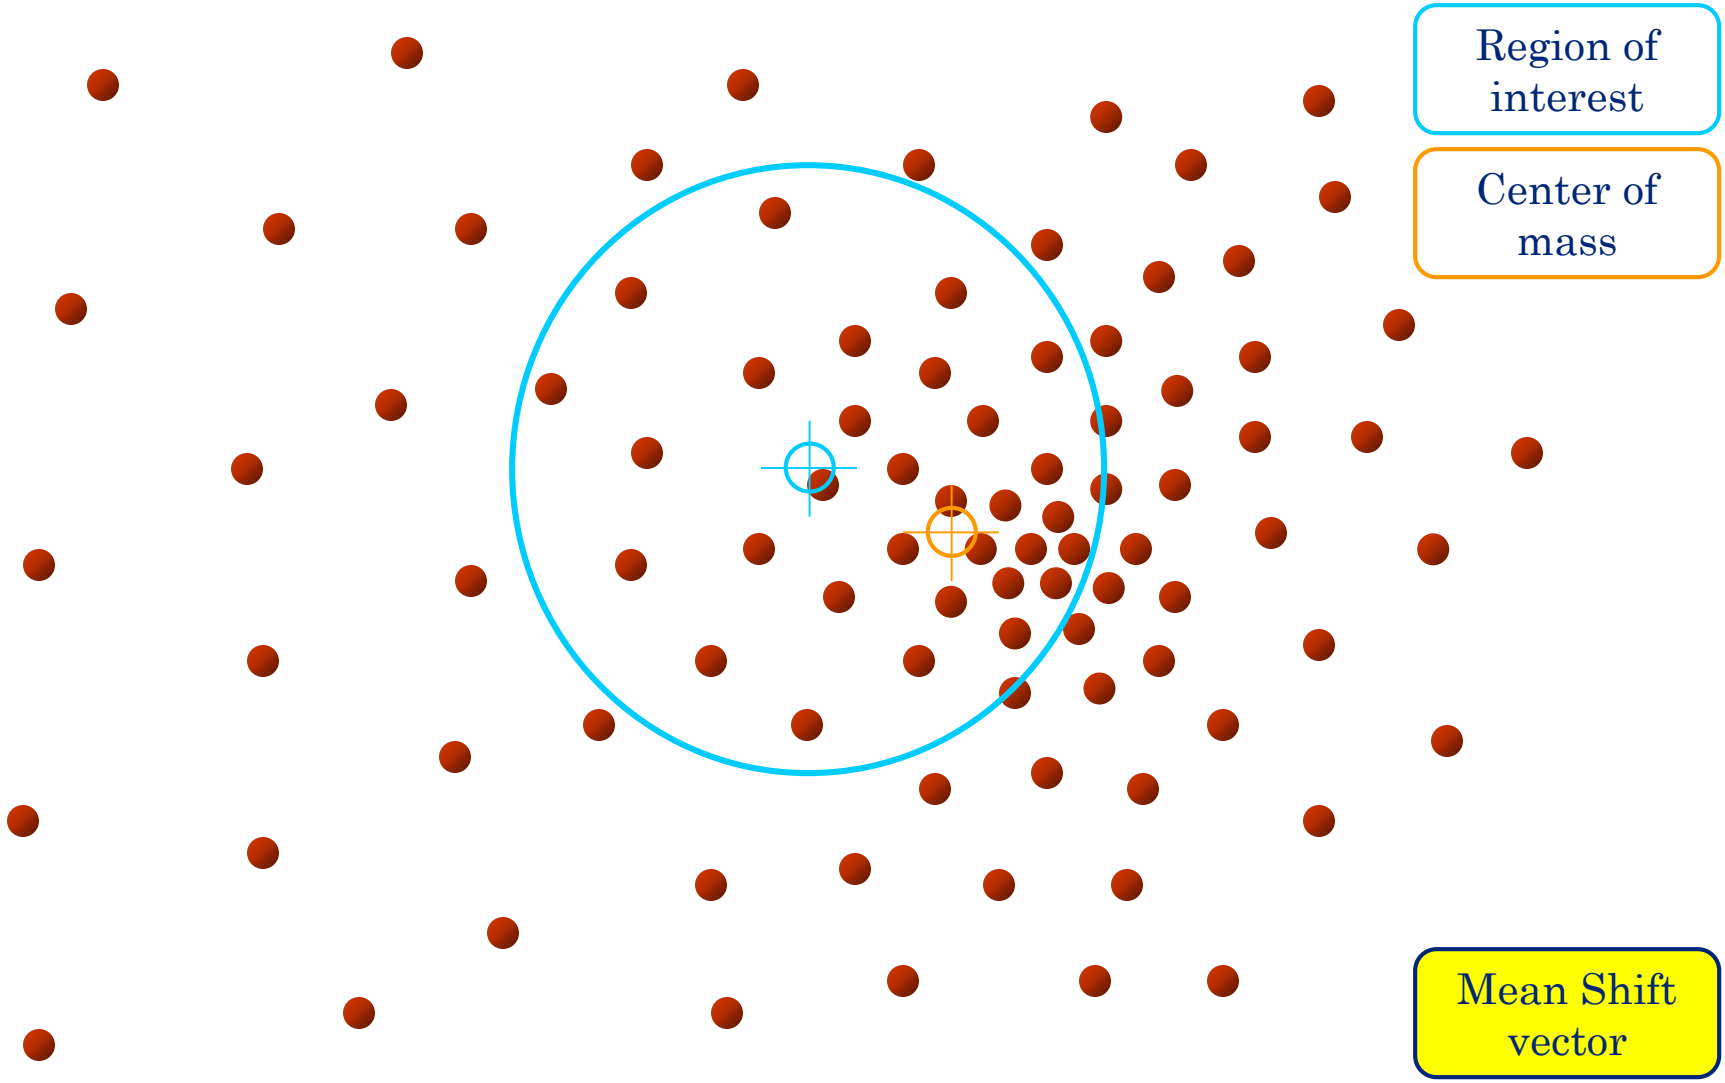

Obiettivo: Trovare la regione più densa

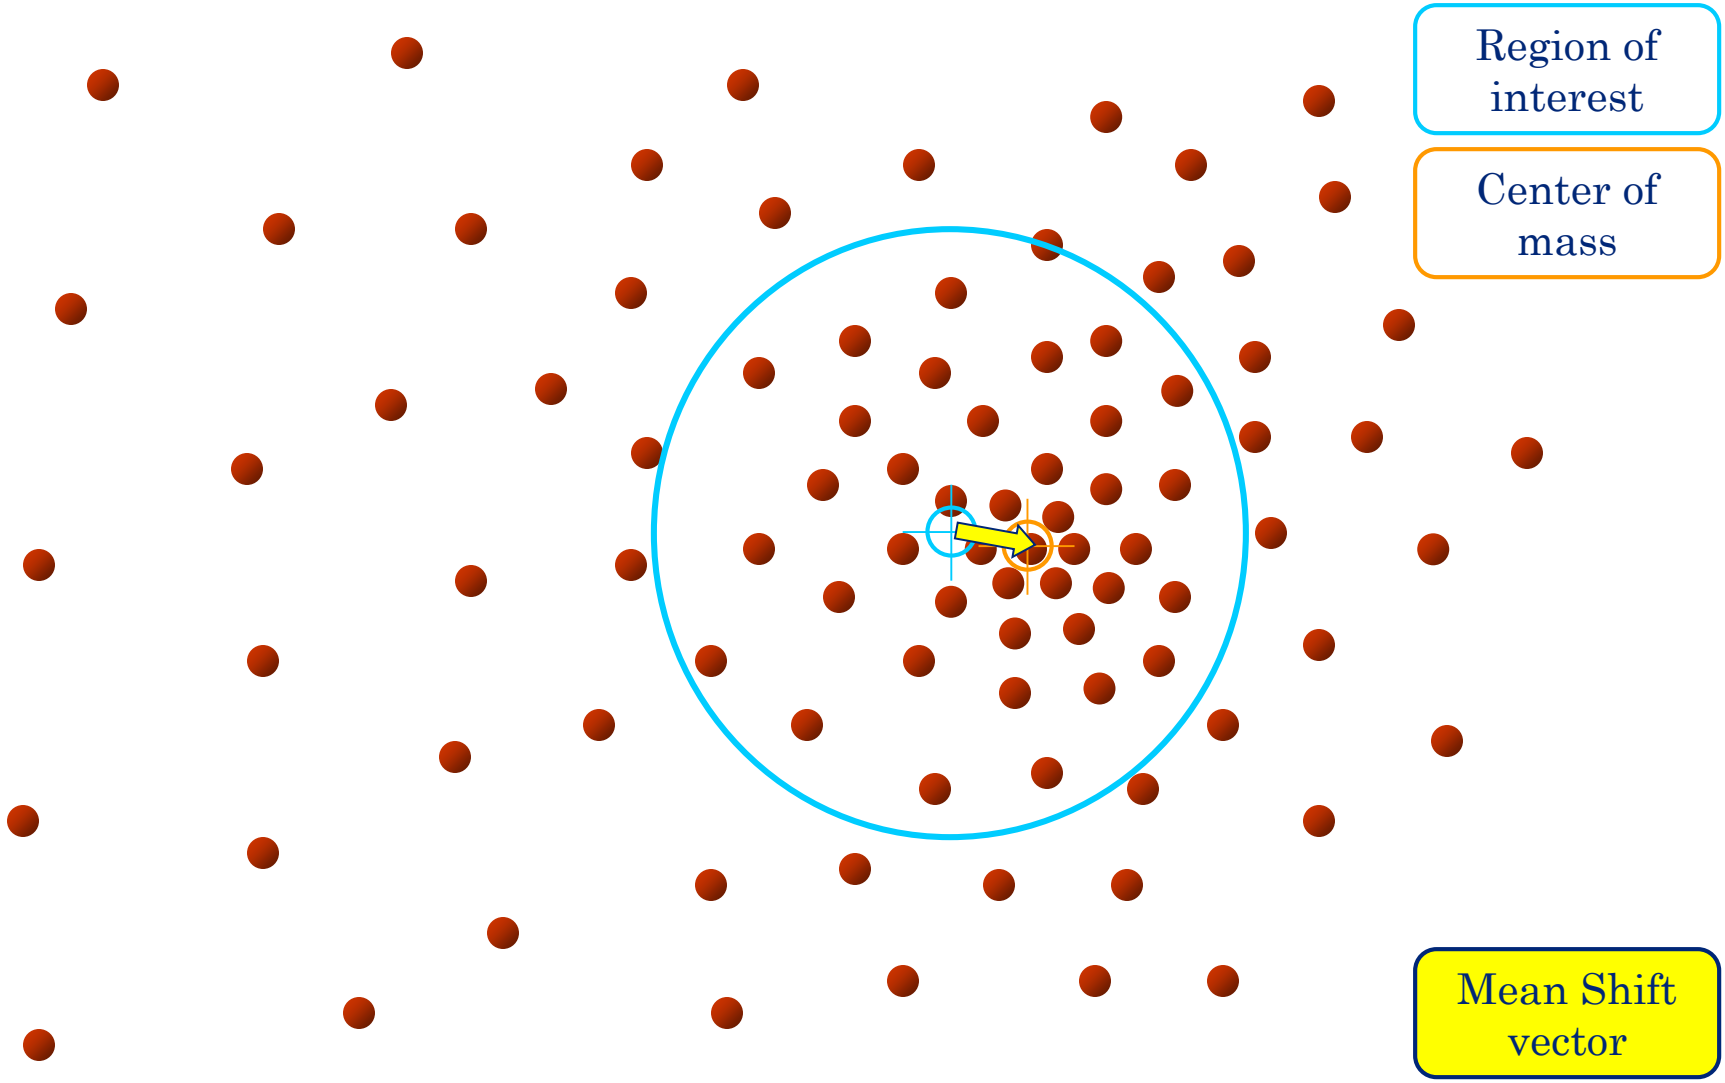

Obiettivo: Trovare la regione più densa

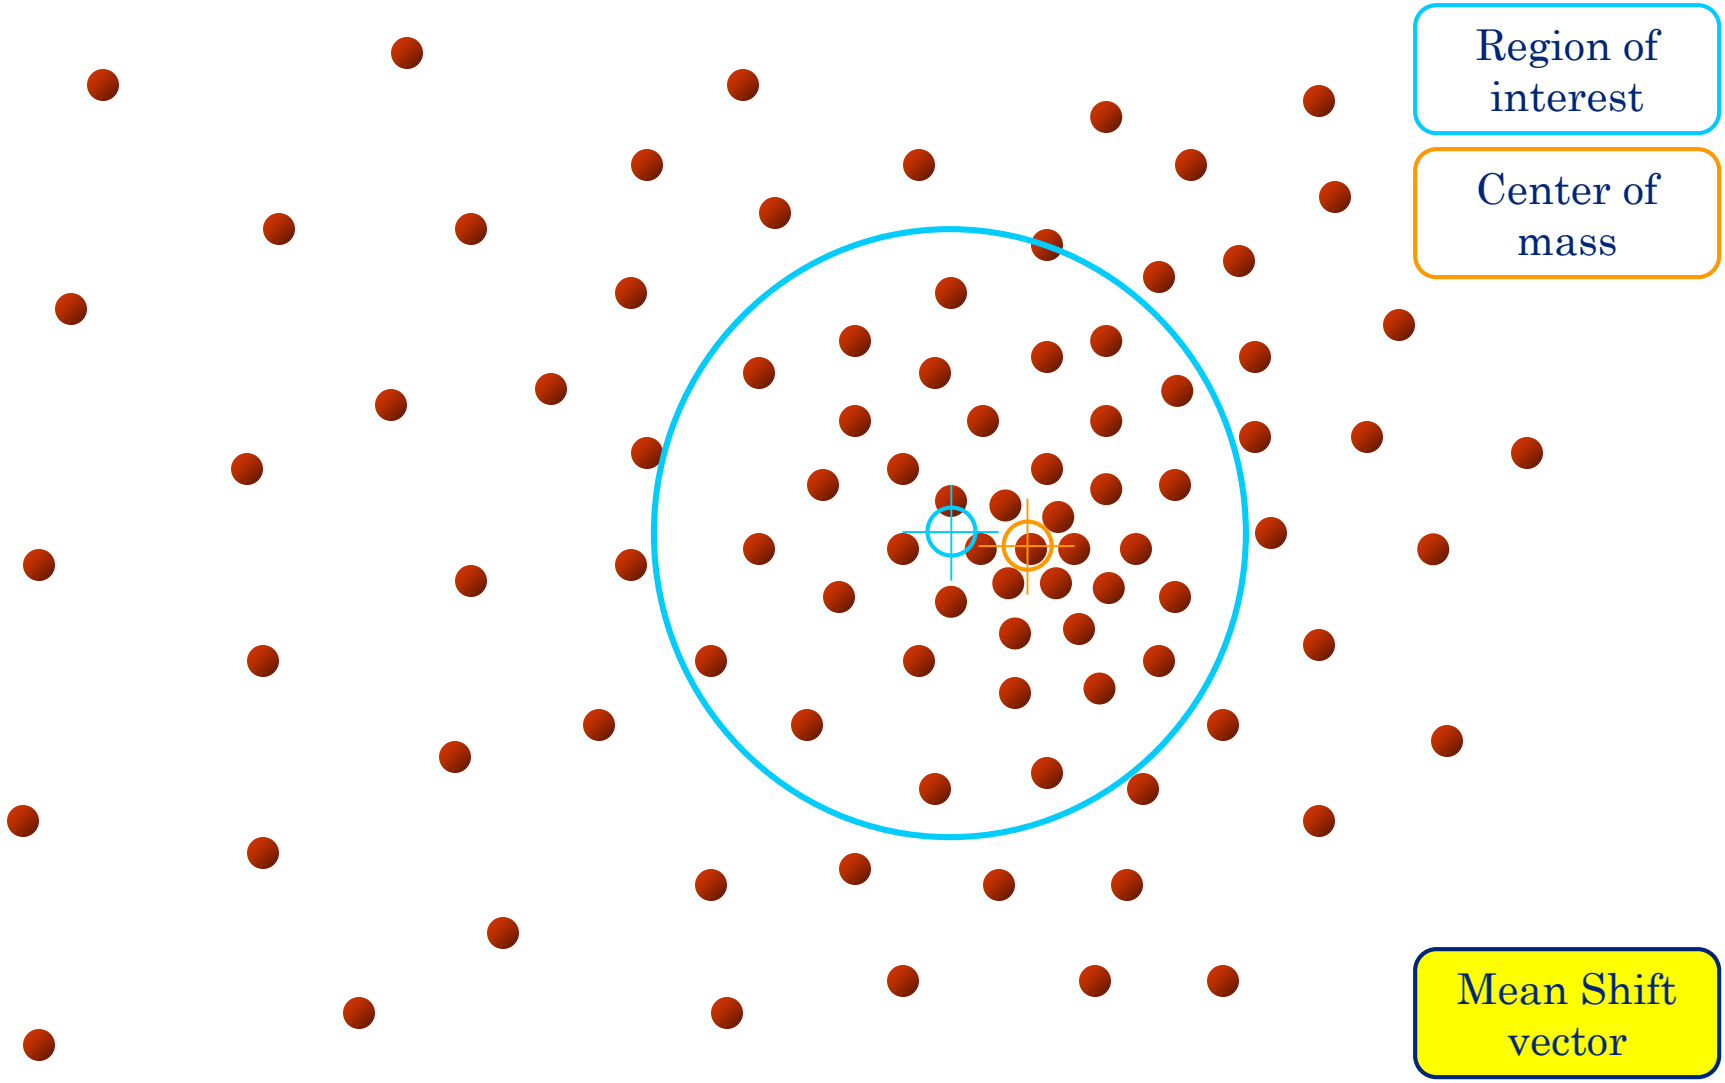

Obiettivo: Trovare la regione più densa

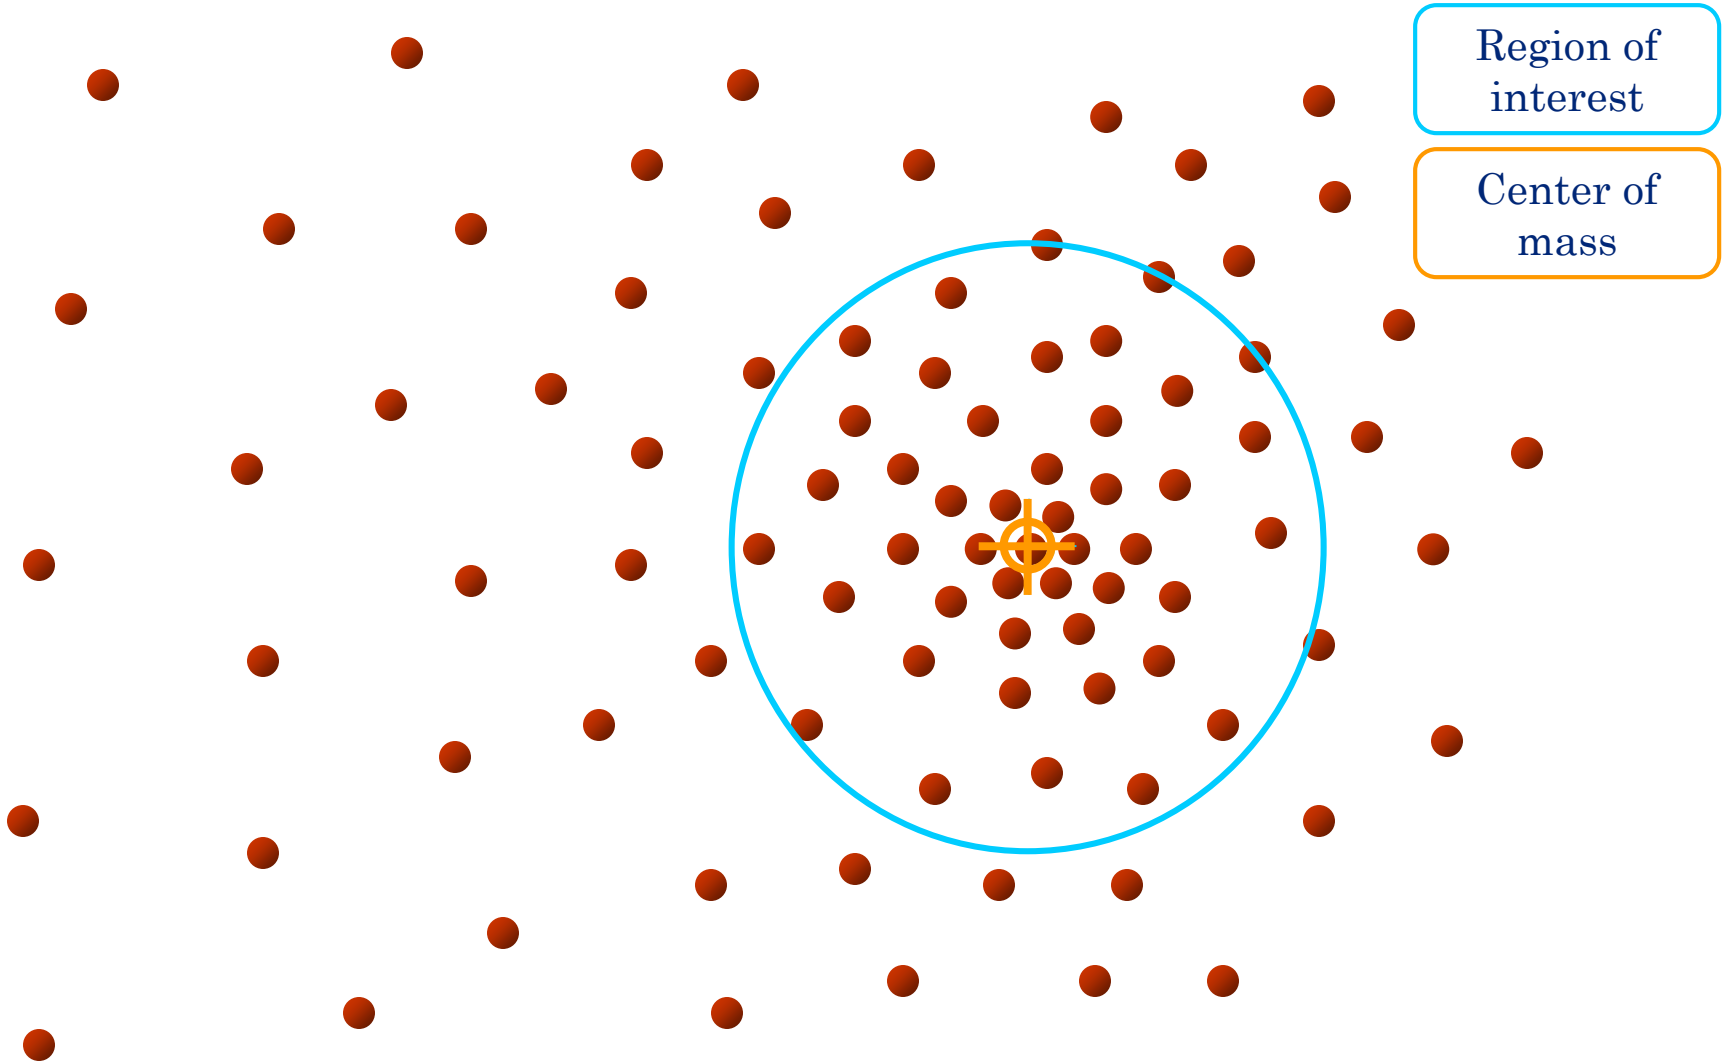

Obiettivo: Trovare la regione più densa

Segmentazione con Mean Shift

- Cluster: insieme dei punti che si trovano nello stesso "bacino di attrazione" di un massimo locale.

Algoritmo di segmentazione:

1. Codificare opportunamente l'immagine tramite feature;
2. Inizializzare le finestre di osservazione (es. gaussiane) in corrispondenza di ciascun feature vector;
3. Eseguire l'algoritmo mean shift fino a convergenza;
4. Fondere le finestre (pixel) che si riferiscono allo stesso massimo locale.

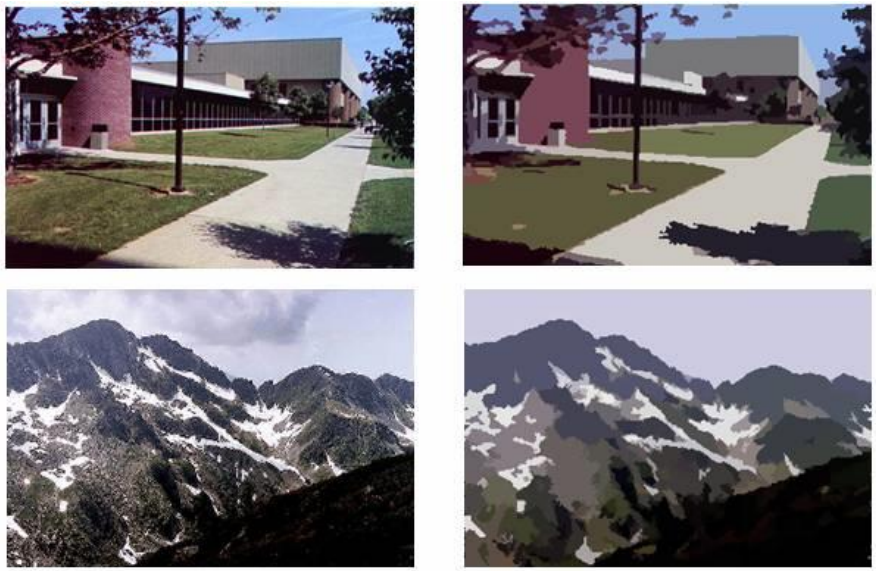

Mean Shift: risultati

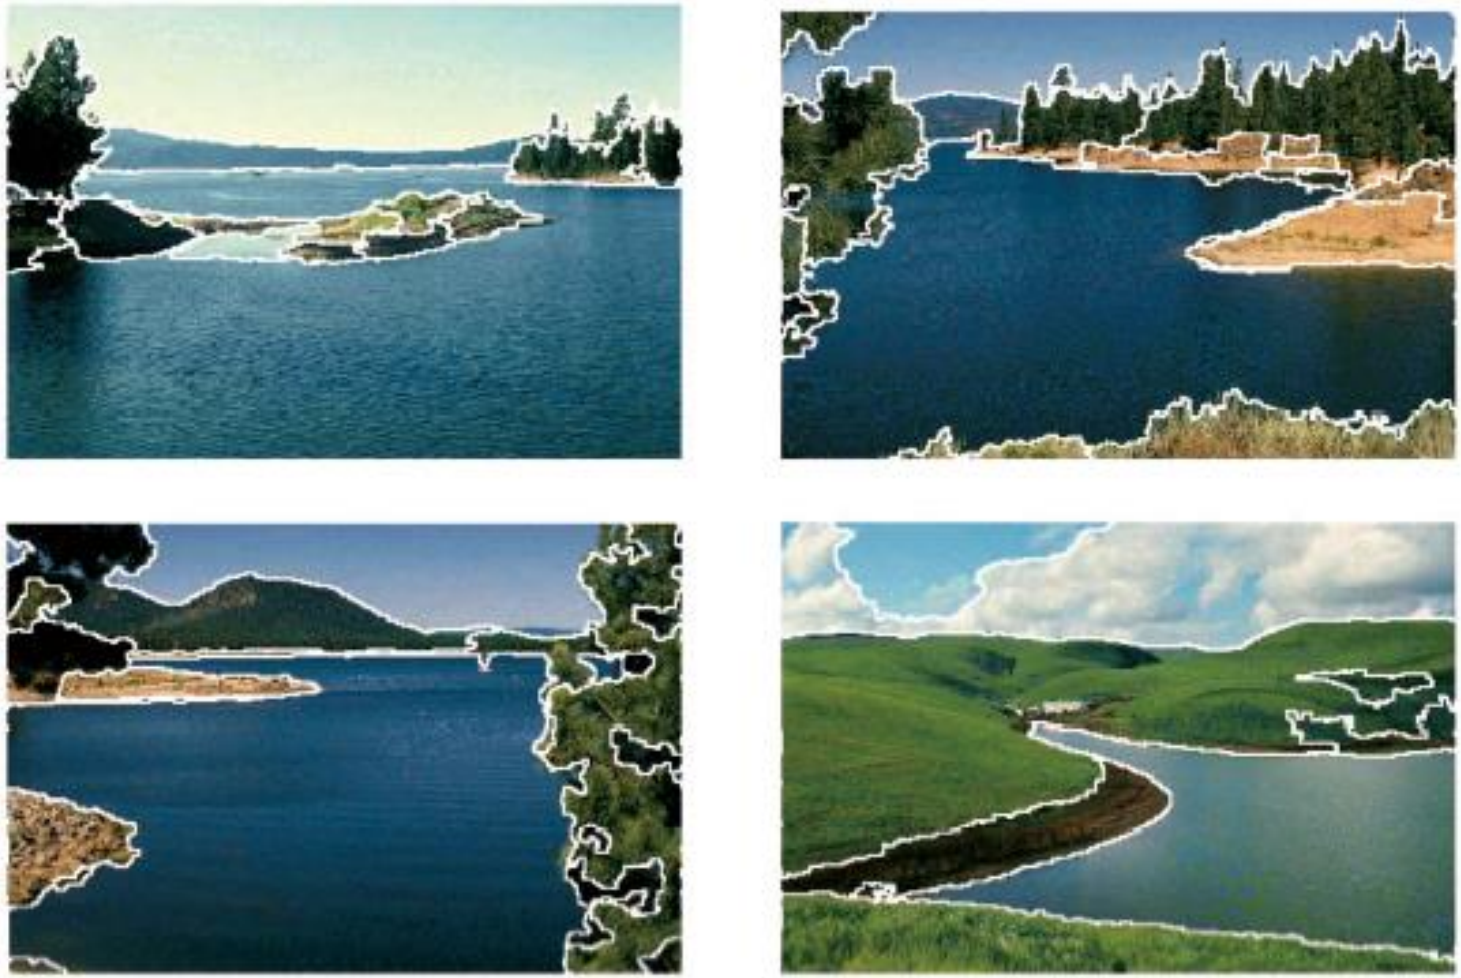

http://www.caip.rutgers.edu/~comanici/MSPAMI/msPamiResults.html

Mean shift: vantaggi e svantaggi

- Vantaggi:
  - Ricerca automatica dei massimi locali
  - È necessario impostare un singolo parametro (dimensione della finestra di osservazione)
  - È in grado di rilevare cluster di forma arbitraria
  - Tecnica generica
- Svantaggi
  - Determinare la dimensione della finestra ottimale non è semplice
  - Non adatto a vettori di feature a dimensionalità elevata.