SLAM: Simultaneous Localization and Mapping

Credits:

Davide Scaramuzza, *Tutorial on Visual Odometry*

Luigi Freda, *Visual SLAM: An overview*

Annalisa Franco

annalisa.franco@unibo.it

SLAM – Simultaneous Localization and Mapping

- *Mapping*: *Come appare il mondo?*
  Integrazione delle informazioni raccolte da diversi sensori in una determinata rappresentazione.
- *Localization*: *Dove mi trovo?*
  Stima della posizione di un robot all'interno di una mappa.
  Problemi tipici:
  - *Pose tracking: posizione iniziale nota*
  - *Global localization: posizione iniziale ignota*
- ***Simultaneous Localization And Mapping***
  Costruire una mappa, localizzando al tempo stesso un robot all'interno di quella mappa.

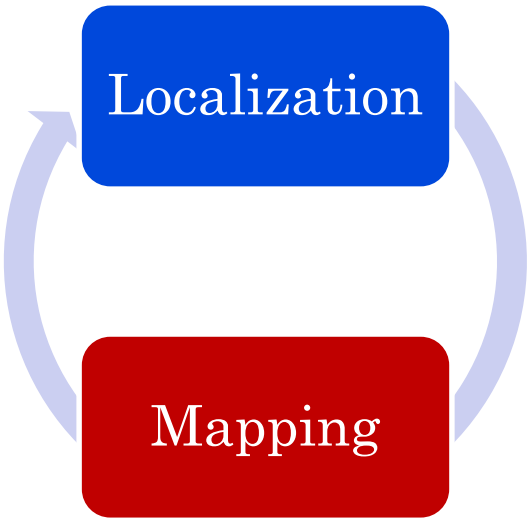

Per una localizzazione accurata è necessaria una buona mappa

La costruzione di una buona mappa richiede una stima accurata della posa

SLAM: Applicazioni

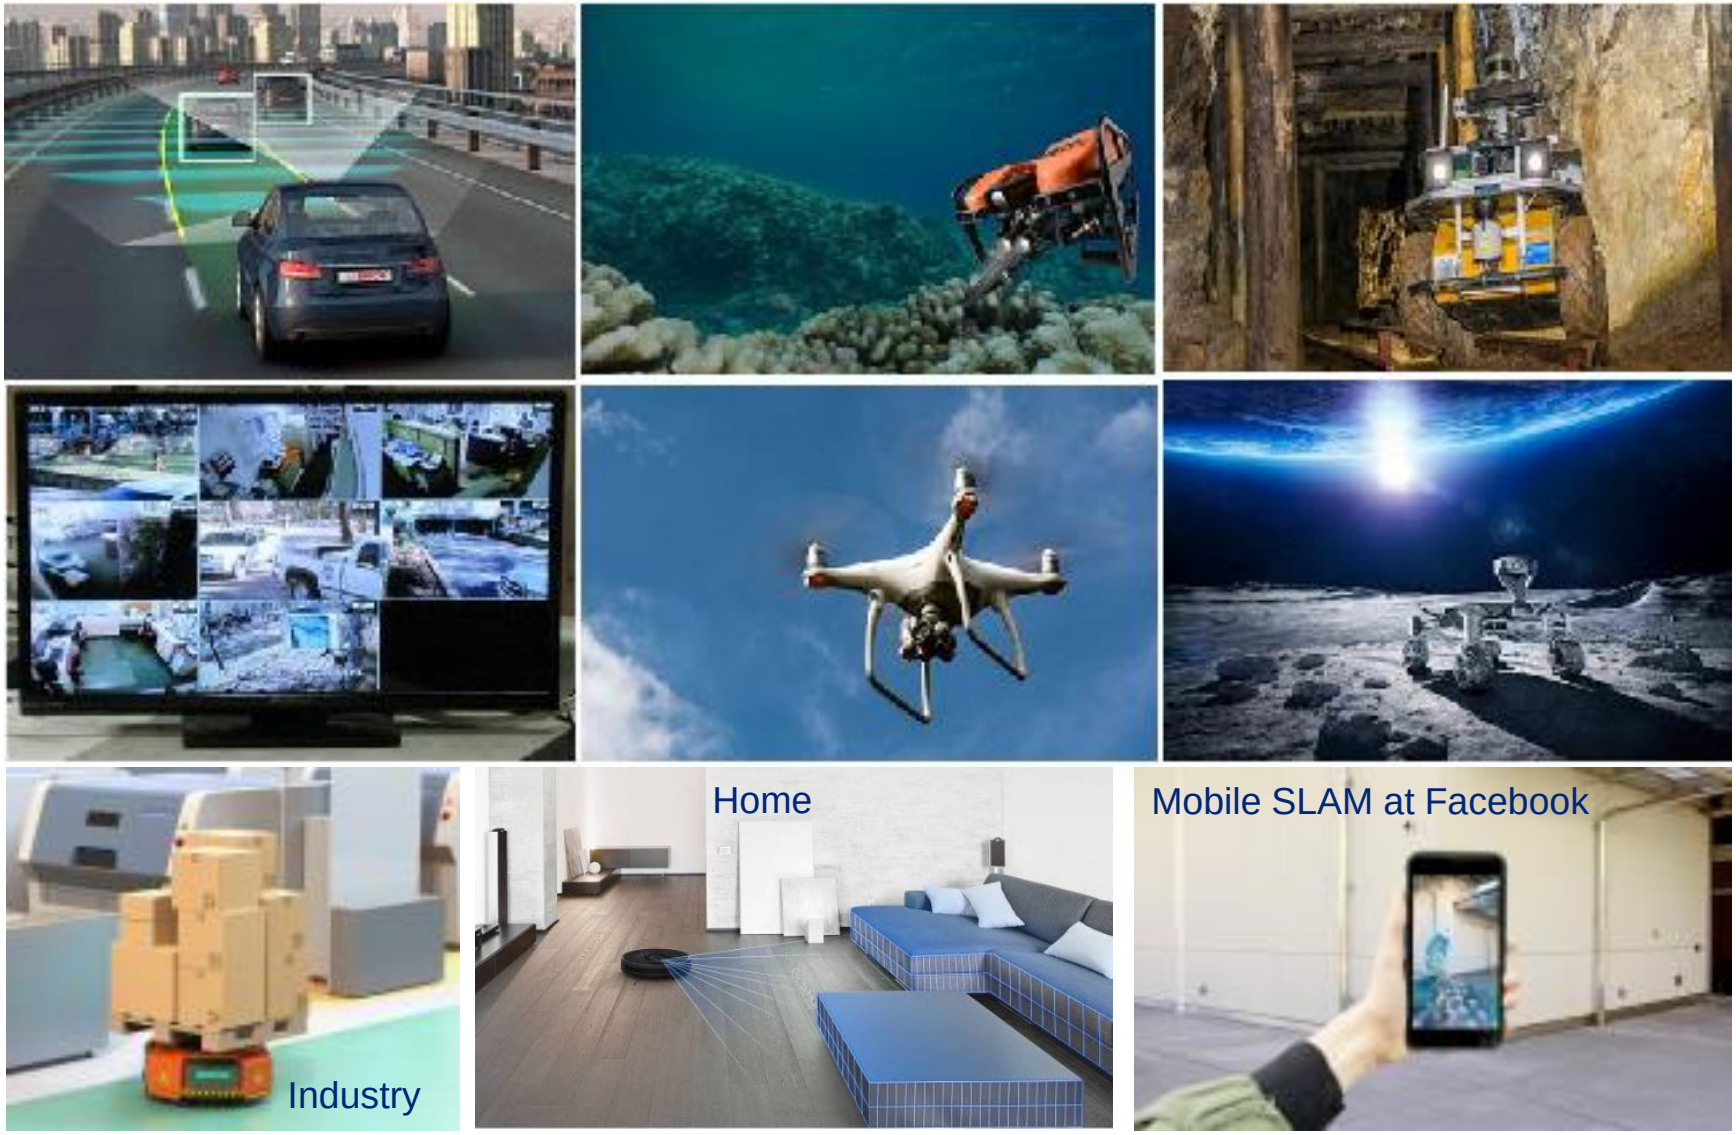

SLAM e Visual SLAM

SLAM e Visual SLAM

- Negli ultimi decenni sono stati studiati numerosi approcci per lo SLAM, basati su sensori di varia natura (IMU, sonar, IR, laser).
- *Visual SLAM:* SLAM basato su sensori visivi (camere, camere RGB-D, ecc.)
  - Informazione visiva molto ricca rispetto ai dati forniti da altri sensori
  - Possibilità di acquisizione con dispositivi di costo limitato
  - Maggiore complessità computazionale (applicazione real-time)
- Progetti open source
  - http://introlab.github.io/rtabmap/
  - https://vision.in.tum.de/research/vslam/lsdslam
  - https://webdiis.unizar.es/~raulmur/orbslam/
  - http://rpg.ifi.uzh.ch/svo2.html
  - https://github.com/mp3guy/ElasticFusion

Il tipico framework Visual SLAM

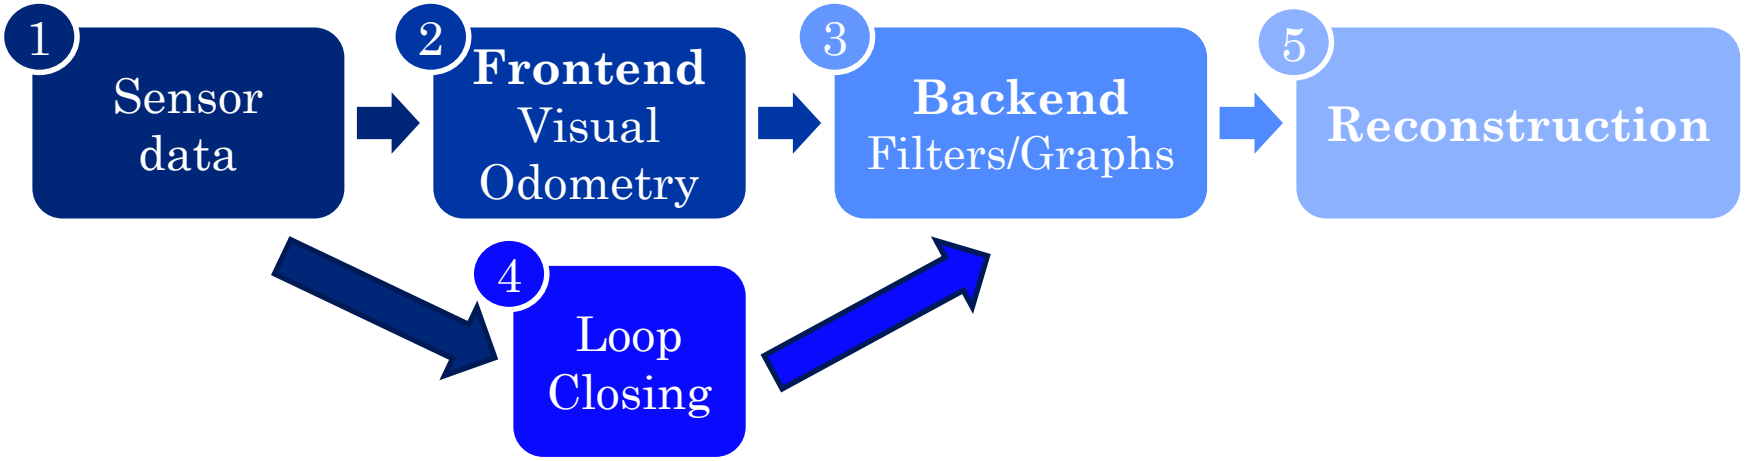

1. Acquisizione e pre-processing delle immagini
2. Stima del movimento della camera e generazione di una mappa locale approssimata
3. Ottimizzazione finalizzata a generare una mappa e una traiettoria accurate
4. Verifica del passaggio in posizioni precedentemente viste (riduzione drift)
5. Costruzione della mappa specifica per il task in oggetto

1 Sensor data

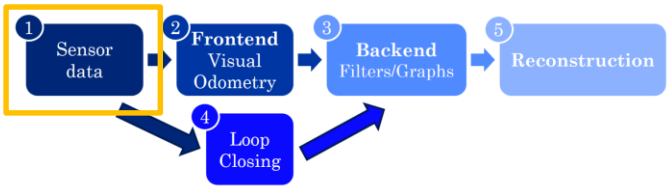

Camere monoculari

- Impossibile ottenere, da singole immagini, informazioni relative alla distanza degli oggetti.
- Necessario muovere la telecamera (solo valori relativi, scala ignota).

Camere stereoscopiche

- Telecamere sincronizzate poste a una distanza prefissata (baseline).
- Possibile calcolare la posizione 3D di ogni pixel (elevata complessità computazionale).

Camere RGB-D

- Telecamere (attive) a luce strutturata o Time-of-Flight.
- Ricostruzione 3D operata dal sensore
- Range di misurazione limitato, rumore, field of view ridotto (indoor).

2 Visual Odometry (1)

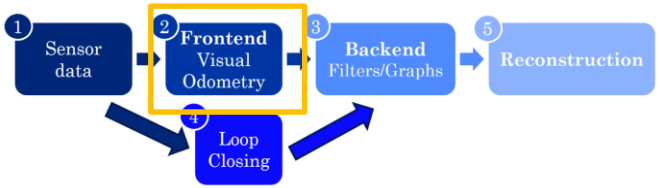

- Processo che stima incrementalmente la posizione di un veicolo esaminando i cambiamenti che il movimento induce nelle immagini acquisite tramite camere montate a bordo dell'oggetto in movimento.

2 Visual Odometry (2)

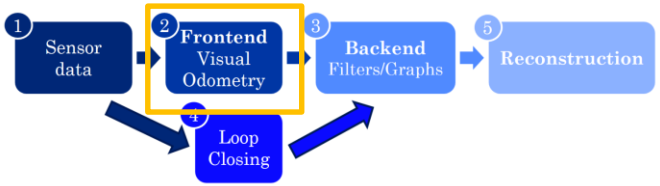

- Necessita di modelli geometrici per quantificare il movimento della telecamera.

- La concatenazione degli spostamenti stimati rappresenta la traiettoria dell'oggetto in movimento, la stima della posizione 3D di ciascun pixel permette di costruire la mappa.

- Il solo uso della VO può causare l'accumulo di un «drift», uno *scostamento* della traiettoria stimata da quella reale.

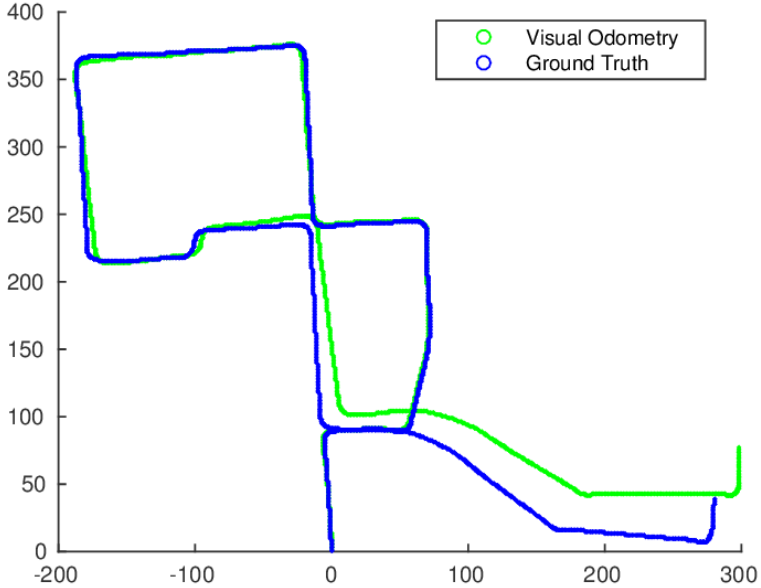

3 Backend optimization

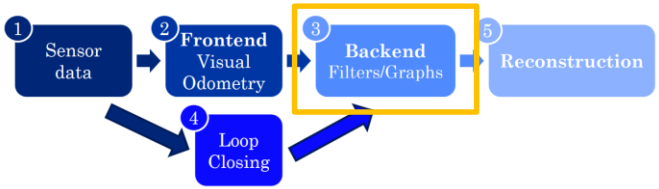

- Processo che gestisce il «rumore» presente nei sistemi SLAM.
- I dati acquisiti sono affetti da rumore.
- L'ottimizzazione in backend, a partire da dati rumorosi, si occupa di stimare lo stato dell'intero sistema:
  - traiettoria dell'oggetto in movimento;
  - mappa dell'ambiente.
- Richiede modelli capaci di stimare l'incertezza presente nei dati e l'utilizzo di filtri e tecniche di ottimizzazione.

4 Loop Closing

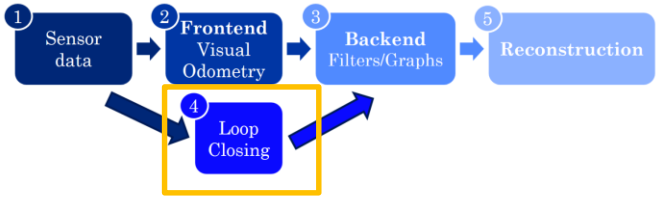

- Anche noto come *loop closure detection*.
- Ha l'obiettivo di verificare se l'oggetto in movimento è tornato in una posizione vista precedentemente.
- Se effettuato a partire dalle sole immagini, il problema si traduce in un problema di *ricerca di similarità* tra immagini.
- In caso di detection di un loop, l'informazione può essere trasmessa al backend per aggiustare di conseguenza la mappa e la traiettoria (global bundle adjustment). Se l'algoritmo di loop detection è affidabile, questo permetterà di eliminare il drift accumulato.

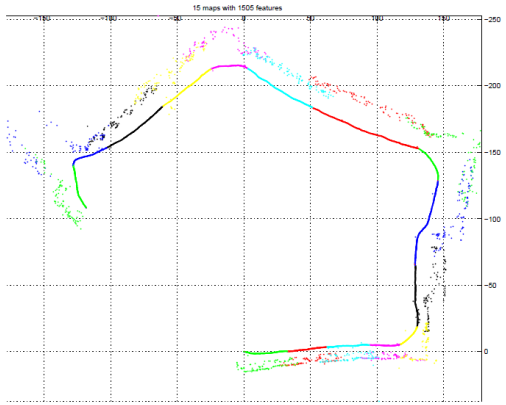

Before loop closing

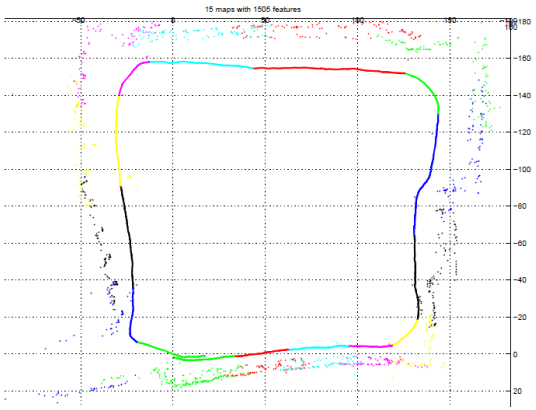

After loop closing

5 Reconstruction

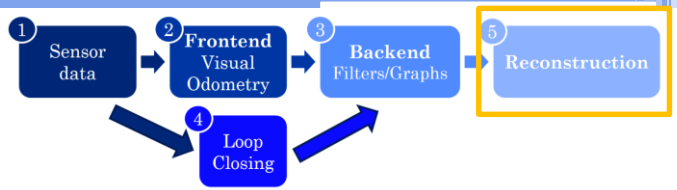

- Processo di costruzione di una mappa, ovvero di una descrizione dell'ambiente.
- La tipologia di mappa dipende strettamente dall'applicazione:
  - Mappa 2D/3D, nuvola di punti, superficie (mesh triangolari) con texture?

Metrical maps:

- Descrivono l'esatta posizione degli oggetti nella mappa
- Possono essere ***sparse*** (localizzazione) o ***dense*** (navigazione).

Topological maps:

- Descrivono le relazioni spaziali tra gli elementi della mappa.
- Sono grafi costituiti da nodi e archi che li connettono.

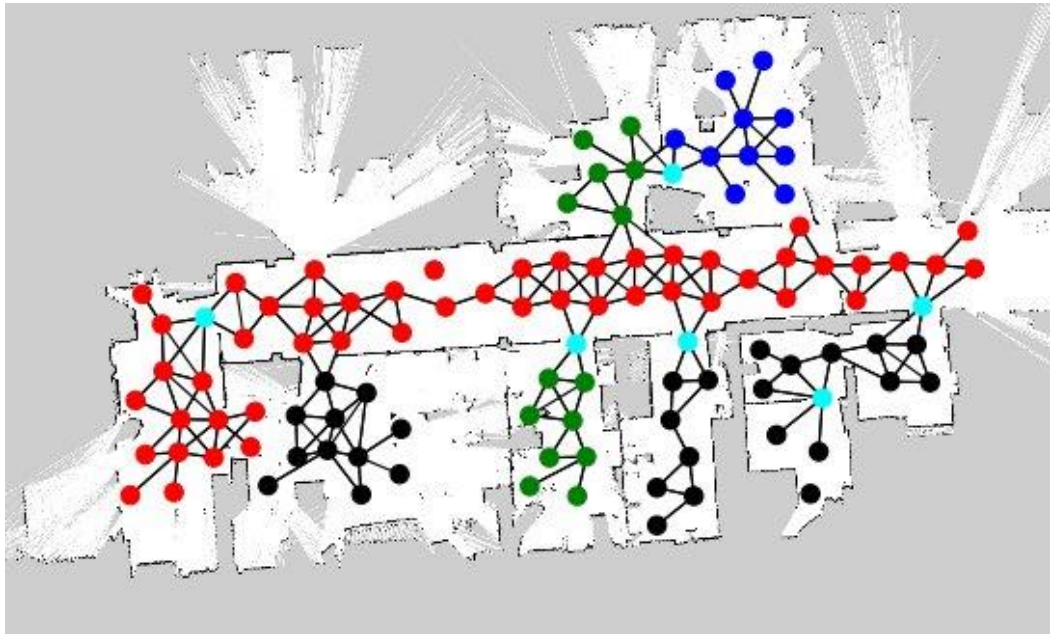

SLAM: formulazione matematica (1)

- Assunzioni:
  - I sensori acquisiscono dati a intervalli regolari.
    Indichiamo con $\mathbf{x}_1, .., \mathbf{x}_k$ la sequenza di posizioni che rappresenta la traiettoria.
  - La mappa è costituita da un insieme di N landmark $\mathbf{y}_1, .., \mathbf{y}_N$.
- Lo spostamento dell'oggetto (robot,veicolo, ecc.) nell'ambiente può essere descritto attraverso due componenti:
  - **Motion**: valore di $\mathbf{x}$ all'istante k;
  - **Observation**: rilevamento di un generico landmark $\mathbf{y}_j$ in posizione $\mathbf{x}_k$.

Motion equation

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k, \mathbf{w}_k)$$

$\mathbf{u}_k$: comando in input
$\mathbf{w}_k$: rumore

Observation equation

$$\mathbf{z}_{k,j} = h(\mathbf{y}_j, \mathbf{x}_k, \mathbf{v}_{k,j})$$

$\mathbf{v}_{k,j}$: rumore

camera model

$$Es. \begin{bmatrix} x_1 \\ x_2 \\ \theta \end{bmatrix}_k = \begin{bmatrix} x_1 \\ x_2 \\ \theta \end{bmatrix}_{k-1} + \begin{bmatrix} \Delta x_1 \\ \Delta x_2 \\ \Delta\theta \end{bmatrix}_k + \mathbf{w}_k$$

SLAM: formulazione matematica (2)

STATE ESTIMATION PROBLEM
Come stimare **x** (localization) e **y** (mapping), dato un input di controllo **u** e un'osservazione **z**?

- La risoluzione di questo problema richiede tecniche diverse a seconda di:
  - forma specifica di motion e observation equation (lineare/non-lineare);
  - Distribuzione di probabilità del rumore (Gaussiano/non Gaussiano).

- Il problema più semplice si ha nel caso *lineare con rumore Gaussiano*. La soluzione ottimale in questo caso è data dai Kalman Filters (KF).

- Casi più complessi richiedono tecniche di ottimizzazione non lineare o adozione di approcci più complessi rispetto ai KF.

Visual Odometry

VO: motivazioni

- Contrariamente all'odometria delle ruote (wheel odometry), la VO non è influenzata dallo slittamento delle ruote su terreni irregolari o in presenza di altre condizioni avverse.
- La stima della traiettoria è più accurata.
- La VO può essere usata in combinazione con alter tecniche:
  - wheel odometry
  - GPS
  - inertial measurement units (IMU)
  - laser odometry
- In ambienti in cui non è possibile l'utilizzo del GPS (es. ambiente subacqueo o aereo) la VO assume fondamentale importanza.

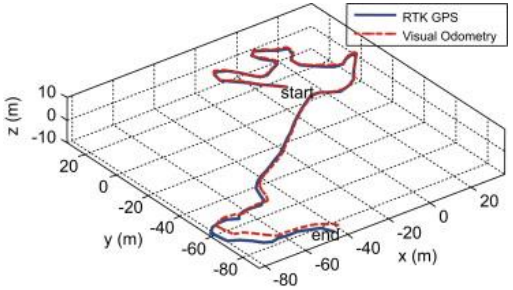

Principio di funzionamento

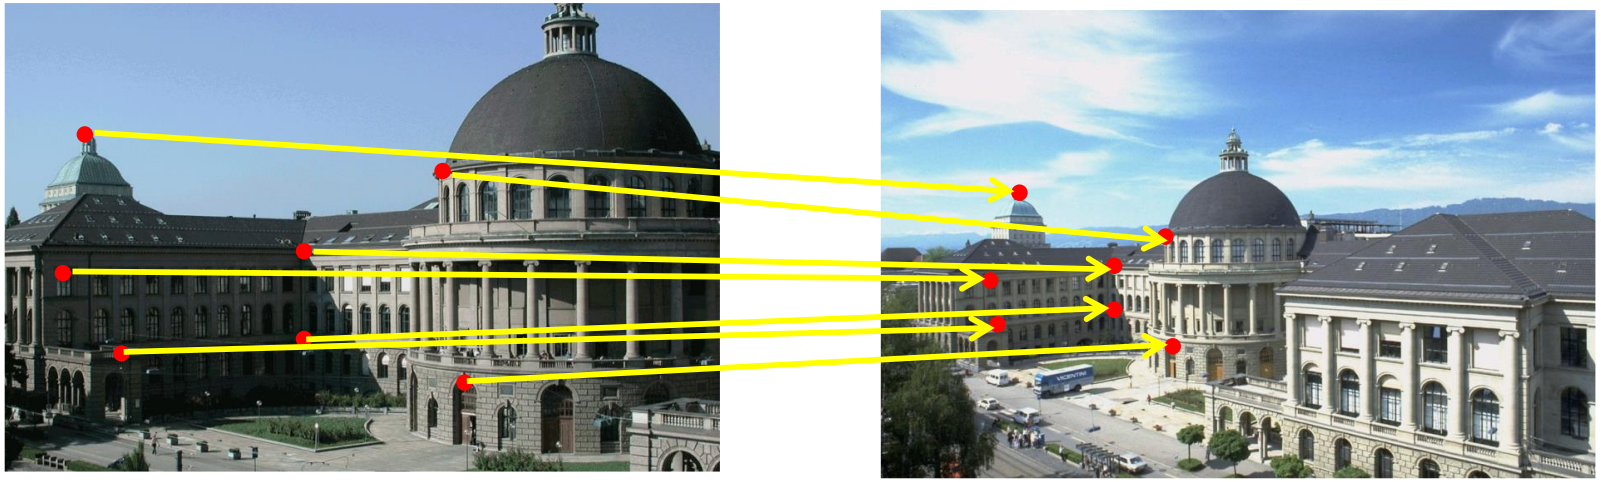

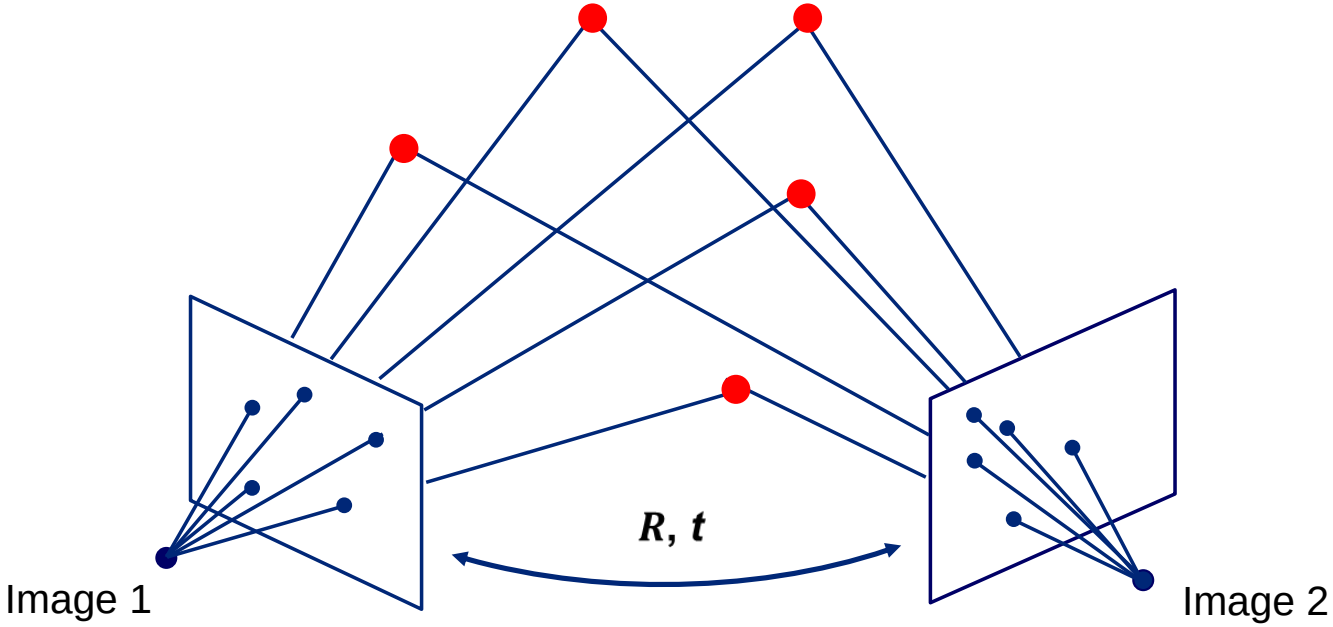

Formulazione del problema (1)

- Un agente si muove nell'ambiente acquisendo immagini a intervalli di tempo discreti k per mezzo di una telecamera fissata rigidamente.
- In caso di ***sistema monoculare***, la sequenza di immagini acquisite è definita come

$$I_{0:n} = \{I_0, .., I_n\}$$

- In caso di ***sistema stereo***, la sequenza di immagini sarà indicata come:

$$I_{l,0:n} = \{I_{l,0}, .., I_{l,n}\} \qquad I_{r,0:n} = \{I_{r,0}, .., I_{r,n}\}$$

- In questo caso, senza perdita di generalità, il sistema di coordinate della telecamera di sinistra può essere utilizzato come origine del sistema di riferimento.

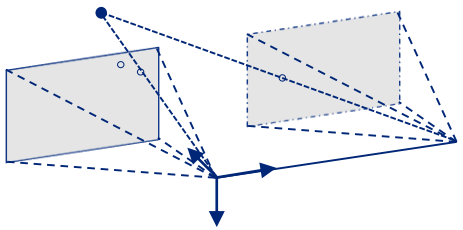

Formulazione del problema (2)

- In caso di ***camera RGB-D***, la sequenza di immagini acquisite si indica con:

$$I_{0:n} = \{I_0, .., I_n\}$$
$$D_{0:n} = \{D_0, .., D_n\}$$

- Le posizioni della telecamera in due istanti temporali adiacenti $k-1$ e k sono collegate da una trasformazione di tipo rigid body:

$$T_k = \begin{bmatrix} R_{k-1,k} & t_{k-1,k} \\ 0 & 1 \end{bmatrix}$$

- L'insieme $T_{1:n} = \{T_1, .., T_n\}$ contiene tutte le trasformazioni in sequenza.

Formulazione del problema (3)

- L'insieme delle posizioni della telecamera $C_{0:n} = \{C_0, .., C_n\}$ contiene le trasformazioni della telecamera rispetto al frame iniziale al tempo $k = 0$.

- La posizione corrente della telecamera C_n può essere calcolata concatenando le trasformazioni $T_{1:k}$:

$$C_n = C_{n-1} T_n$$

dove C_0 indica la posizione della telecamera all'istante $k = 0$ che può essere arbitrariamente specificata dall'utente.

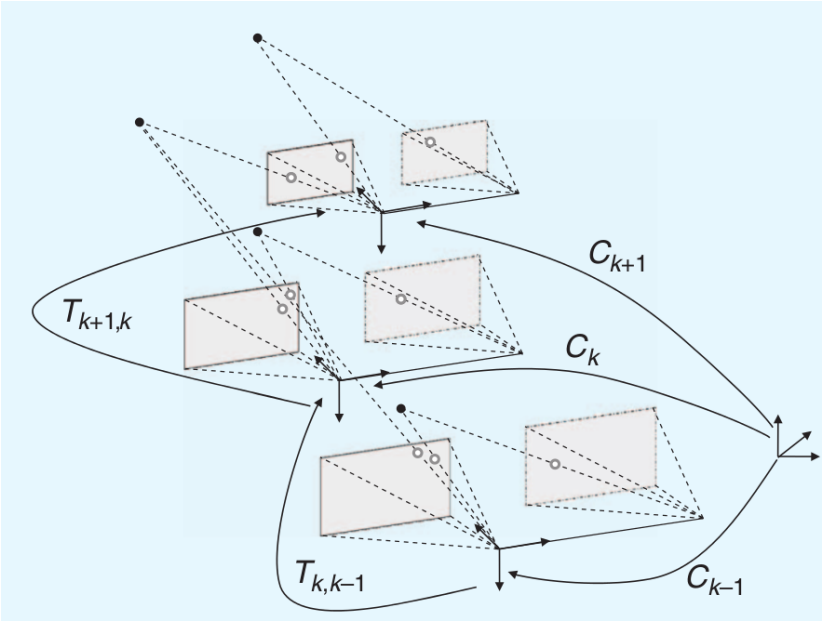

Formulazione del problema (4)

- Lo scopo principale della Visual Odometry è calcolare le trasformazioni relative tra le immagini I_k e I_{k-1} e concatenare queste trasformazioni per ricostruire la traiettoria completa della telecamera $C_{0:n}$.
- La VO ricostruisce dunque il percorso in modo incrementale.
- Per ottenere una stima più accurata della traiettoria locale è possibile effettuare un raffinamento iterativo sulle ultime m pose.

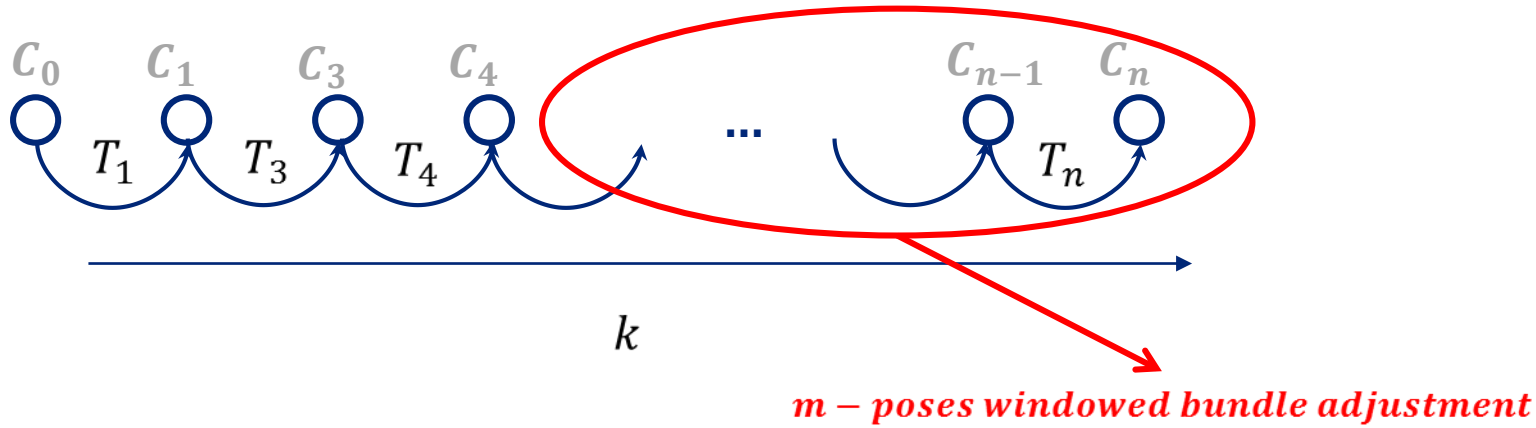

Il tipico framework Visual SLAM

1 **Feature Detection** → 2 **Feature matching/ tracking** → 3 **Motion estimation** → 5 **Local optimization**

- Condizioni necessarie:
  - Ambiente sufficientemente illuminato;
  - Predominanza nella scena degli elementi statici rispetto a quelli in movimento;
  - Presenza di sufficienti elementi di tessitura che consentano la stima del movimento apparente;
  - Sufficiente sovrapposizione della scena tra frame consecutivi.

1 Feature detection

Obiettivo: individuazione di un insieme di feature f_k al tempo k.

- In generale le feature salienti si trovano in aree dell'immagine ad alto contrasto.
- Tecniche basate su keypoint.

2 Feature matching Feature tracking

Obiettivo: trovare delle corrispondenze tra i due insiemi di feature f_{k-1} e f_k.

- Feature tracking: ricerca locale di ciascuna feature (es. predizione con filtri e correlazione);
- Feature matching: ricerca indipendente delle feature in ciascuna immagine e successiva ricerca delle corrispondenze sulla base di descrittori locali (es. ORB, SIFT, SURF, ecc…)

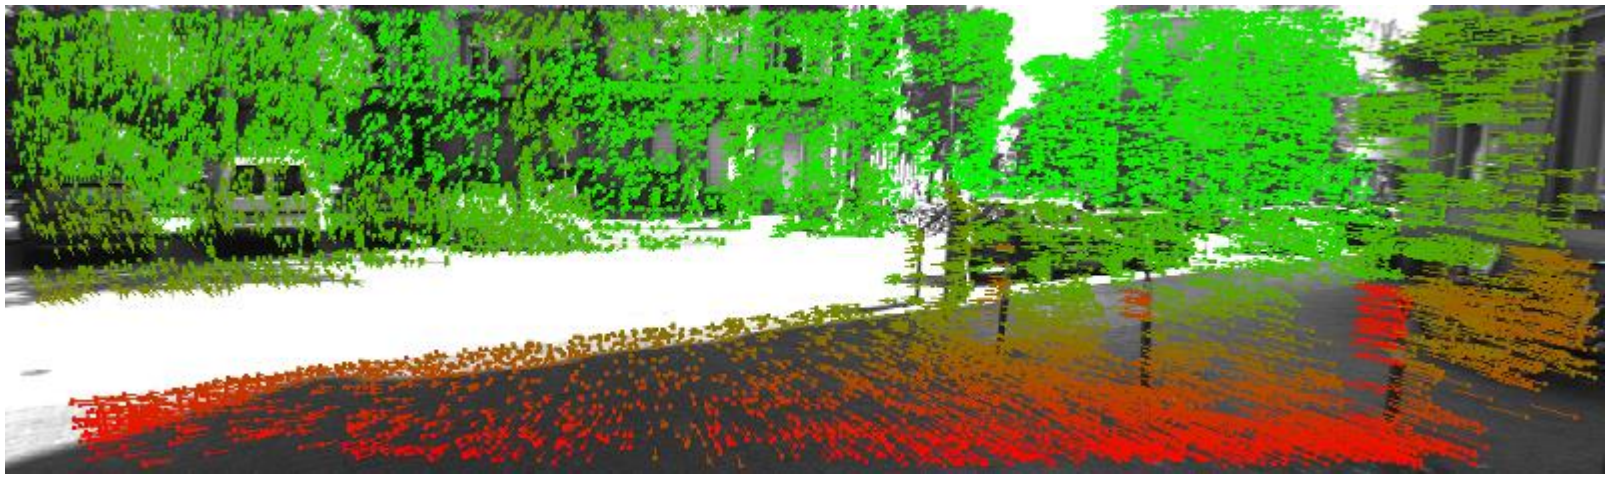

3 Motion estimation

Obiettivo: calcolare la trasformazione T_k tra le due immagini I_{k-1} e I_k.

- Esistono due categorie di approcci per la stima del movimento:
  - Appearance-based: si basano su un'analisi dei valori di luminosità di tutti i pixel nelle due immagini;
    - Metodi meno accurati e più onerosi dal punto di vista della complessità computazionale.
  - Feature-based: utilizzano feature salienti e ripetibili estratte dalle immagini.
    - Richiedono tecniche di feature matching/tracking;
    - Sono più robusti ed efficienti.

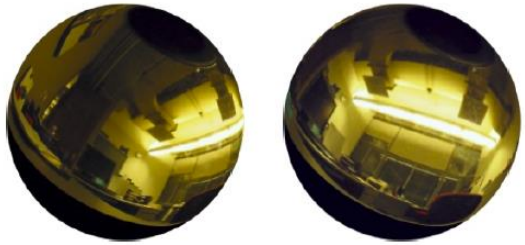

VO

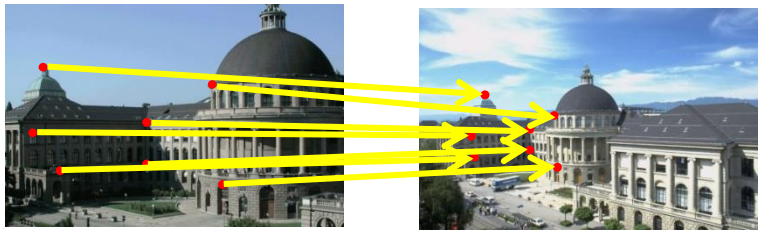

f_{k-1} f_k

3 Motion estimation

Obiettivo: calcolare la trasformazione T_k tra le due immagini I_{k-1} e I_k.

- A seconda della tipologia di dati acquisiti dal sensore, e quindi della rappresentazione delle feature f_{k-1} e f_k nelle due immagini, si utilizzano tecniche diverse per la stima del movimento:
  - 3D-3D: utilizza due insiemi di punti 3D, X_{k-1} e X_k, che rappresentano le coordinate di f_{k-1} e f_k;
  - 3D-2D: utilizza un insieme di punti 3D X_{k-1} corrispondenti a f_{k-1} e la loro retro-proiezione 2D f_k nell'immagine I_k;
  - 2D-2D: utilizza f_{k-1} e f_k, rappresentati entrambi in coordinate 2D all'interno dell'immagine.

Type of correspondences	Monocular	Stereo
2D–2D	X	X
3D–3D		X
3D–2D	X	X

3 3D-3D (1)

f_{k-1} e f_k sono specificati in coordinate 3D

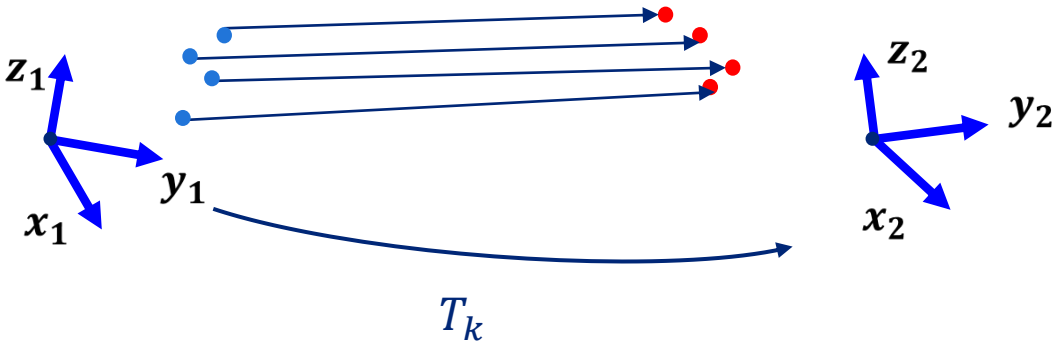

- È necessaria la *triangolazione* dei punti 3D (es. camera stereo);
- La stima della trasformazione richiede almeno <u>3 corrispondenze</u> non collineari.

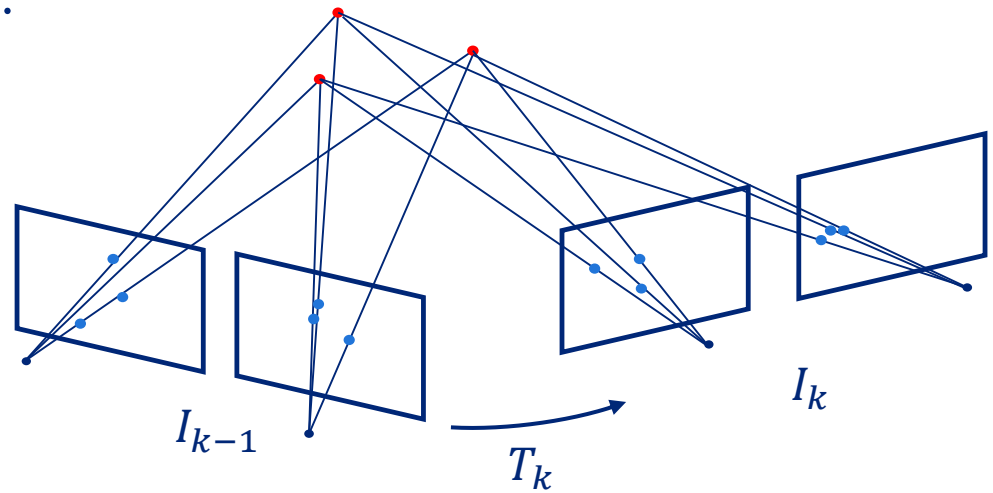

3 3D-3D (2)

1. Acquisizione di due coppie di immagini stereo $I_{l,k-1}$, $I_{r,k-1}$ e $I_{l,k}$, $I_{r,k}$
2. Estrazione e matching delle feature tra $I_{l,k-1}$ e $I_{l,k}$
3. Triangolazione delle feature corrispondenti per ciascuna coppia di immagini stereo:

$$I_{l,k-1}, I_{r,k-1} \Longrightarrow X_{k-1}$$

$$I_{l,k}, I_{r,k} \Longrightarrow X_k$$

4. Identificazione della trasformazione che minimizza le distanze 3D-3D:

$$T_k = \begin{bmatrix} R_{k,k-1} & t_{k,k-1} \\ 0 & 1 \end{bmatrix} = \underset{T_k}{argmin} \sum_i \| \tilde{X}_k^i - T_k \tilde{X}_{k-1}^i \|$$

5. Concatenazione delle trasformazioni $C_k = C_{k-1} T_k$
6. Ripeti da 1

3 3D-2D (1)

f_{k-1} è rappresentato in 3D e f_k in 2D

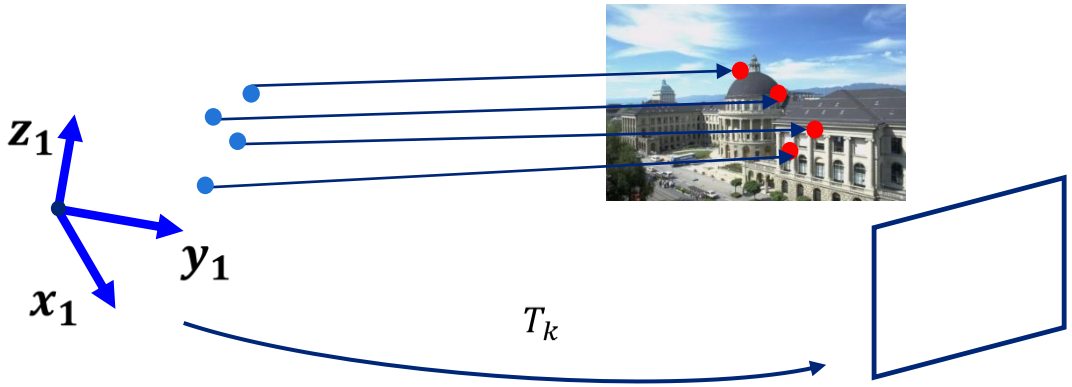

- La stima della trasformazione richiede almeno <u>3 corrispondenze</u>.

3 3D-2D (1)

Inizializzazione

- Acquisizione di due frame I_{k-2}, I_{k-1}
- Estrazione e matching delle feature estratte dalle due immagini
- Triangolazione delle feature: $I_{k-2}, I_{k-1} \Rightarrow X_{k-1}$

Frame successivi

1. Acquisizione del frame I_k
2. Estrazione delle feature e matching con il frame I_{k-1}
3. Calcolo della posa della camera (PnP) a partire dai match 3D-2D (tra X_{k-1} e f_k)
4. Triangolazione delle nuove feature: $I_{k-1}, I_k \Rightarrow X_k$
5. Ripeti da 1

3 2D-2D

f_{k-1} e f_k rappresentati in 2D

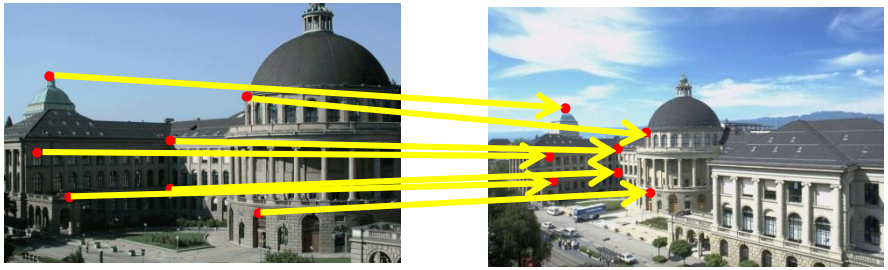

I_{k-1} I_k

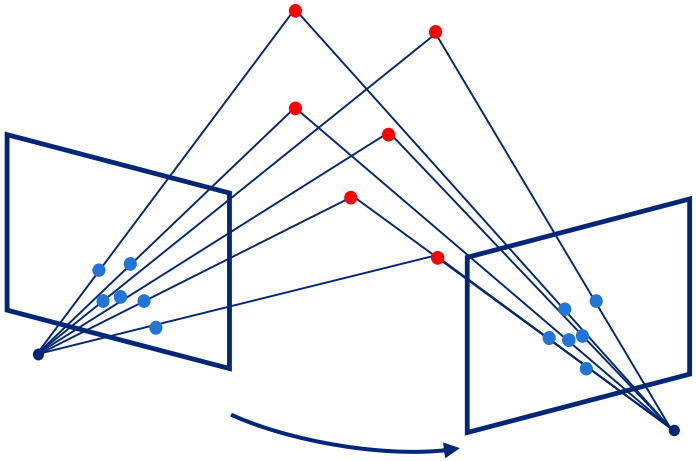

- La stima della trasformazione richiede almeno <u>5 corrispondenze</u>.
- La soluzione è rappresentata dalla trasformazione che minimizza l'errore di retro-proiezione dei punti triangolati in ciascuna immagine
- La trasformazione può essere stimata sulla base dei principi della *geometria epipolare* *(vedi appendice per approfondimenti)*.

3 2D-2D

f_{k-1} e f_k rappresentati in 2D

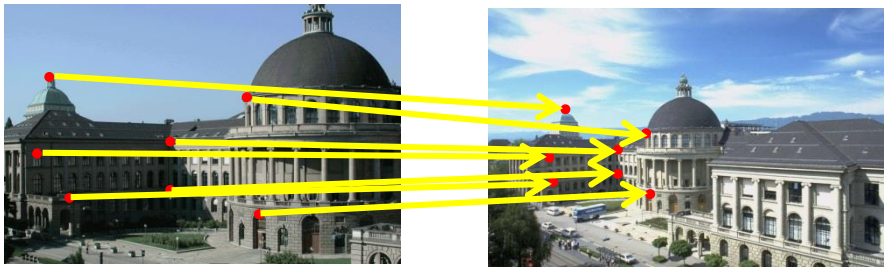

I_{k-1} I_k

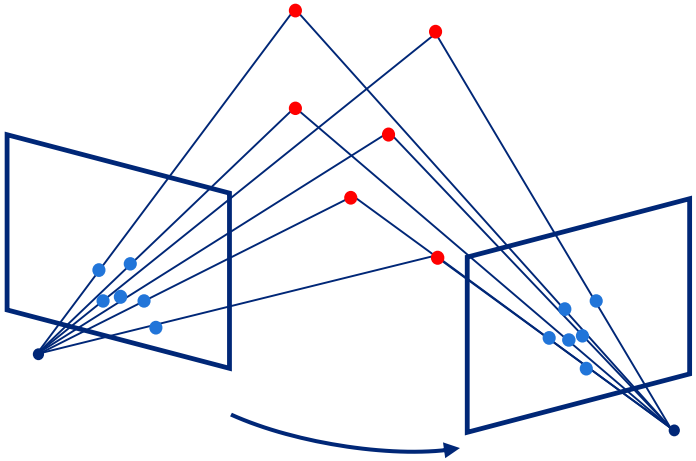

1. Acquisizione del frame I_k
2. Estrazione delle feature e matching con il frame I_{k-1}
3. Calcolo della matrice essenziale per la coppia di immagini I_{k-1}, I_k
4. Scomposizione della matrice essenziale in R_k e t_k e costruzione della trasformazione T_k
5. Calcolo della scala relativa e riscalatura di t_k ← ???
6. Concatenazione delle trasformazioni $C_k = C_{k-1}T_k$
7. Ripeti da 1.

3 2D-2D: scala relativa

- La scala assoluta della traslazione non può essere stimata a partire dalle sole immagini 2D.
- È comunque possibile calcolare la scala relativa per trasformazioni successive.
- Una possibile soluzione si ottiene triangolando i punti X_{k-1} e X_k in due frame consecutivi. Dato un insieme di corrispondenze, la distanza relativa tra qualsiasi coppia di punti 3D può essere calcolata agevolmente.
- La scala relativa è data dal rapporto tra le distanze di una qualsiasi coppia di punti in X_{k-1} e la corrispondente coppia in X_k:

$$r = \frac{\|X_{k-1,i} - X_{k-1,j}\|}{\|X_{k,i} - X_{k,j}\|}$$

- Per una stima più robusta, la scala è stimata come la mediana del rapporto r calcolato per più coppie di punti.

4 Local optimization

- Gli errori introdotti nella stima del movimento tra coppie di frame successivi si accumulano nel tempo.
- Ciò genera uno scostamento (drift) tra la traiettoria stimata e quella reale.
- L'incertezza nella stima della posa della camera $C_k = C_{k-1}T_k$ è sempre crescente.
- È perciò importante cercare di limitare questa incertezza il più possibile per le singole trasformazioni.

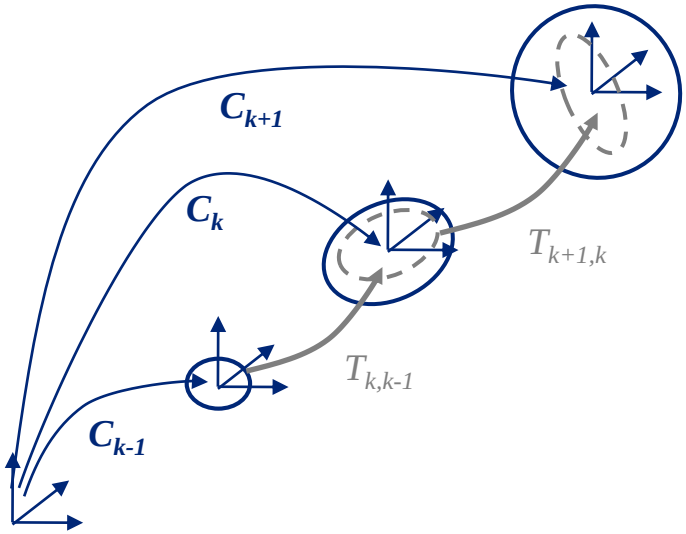

4 Local optimization

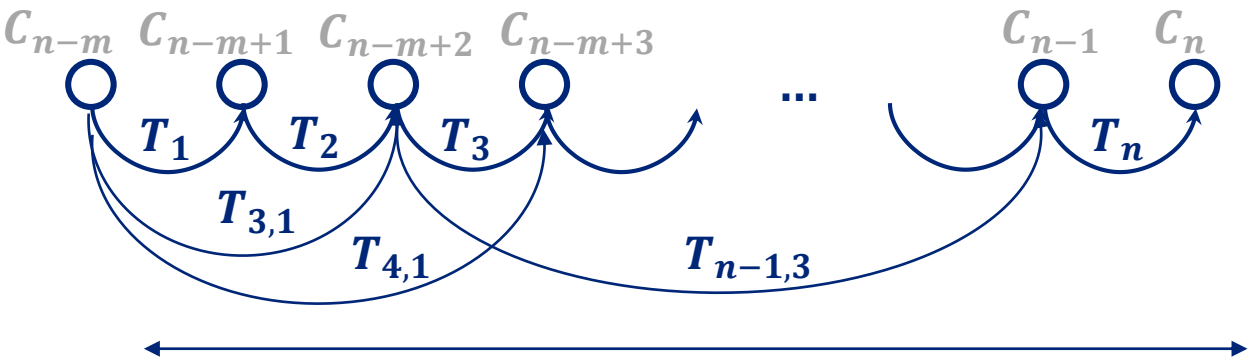

m – poses windowed bundle adjustment

- Le singole trasformazioni $T_{i,j}$ possono essere calcolate anche a partire da frame non adiacenti.
- Queste informazioni possono essere utilizzate come vincoli aggiuntivi per migliorare la stima della posa della camera, minimizzando l'espressione seguente:

$$\sum_{i,j} \| C_i - T_{i,j} C_j \|$$

- Per motivi di efficienza, l'analisi viene limitata agli m frame precedenti.
- Per la soluzione del problema si utilizza l'algoritmo Levenberg-Marquadt

4 Local optimization

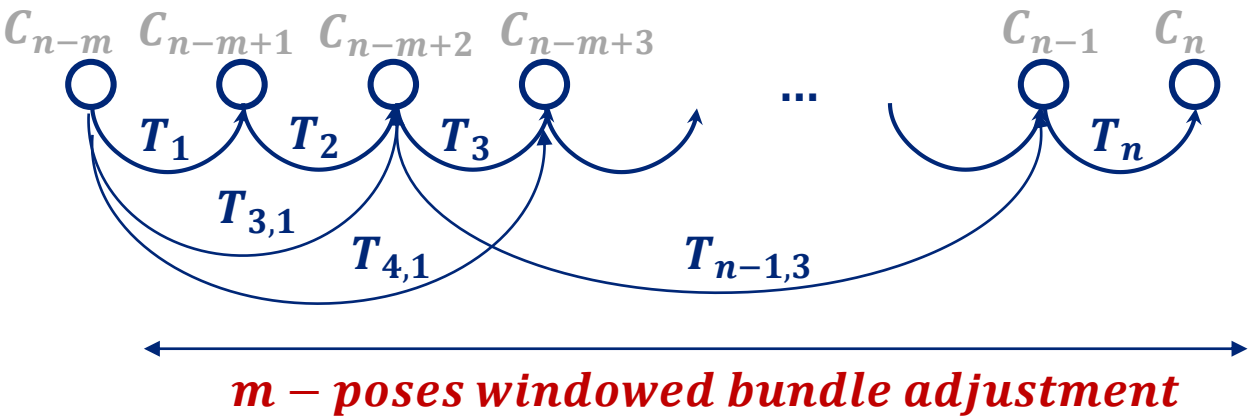

- La soluzione consiste nel minimizzare il seguente errore di retro-proiezione:

$$T_k = \begin{bmatrix} R_{k-1,k} & t_{k-1,k} \\ 0 & 1 \end{bmatrix} = \arg\min_{X_i, C_k} \sum_{i,k} \left\| p_i^k - g(X_i, C_k) \right\|$$

dove:

- p_i^k è l'i-esimo punto immagine dell'insieme di landmark 3D X_i, misurato nella k-esima immagine
- $g(X_i, C_k)$ è la sua retro-proiezione stimata sulla base della posa corrente C_k.

Nel nostro laboratorio…

- Xaxxon OpenLIDAR rotational laser scanner
- Intel RealSense D415 Active Stereo Depth Camera with RGB
- Gyroscope: Pololu L3GD20 3-Axis
- Microphone
- RGB camera front and rear Intel Realsense RGB 1920x1080
- Mono microphone and speaker

http://www.xaxxon.com/xaxxon/autocrawler

Appendice

Geometria epipolare

Geometria epipolare (1)

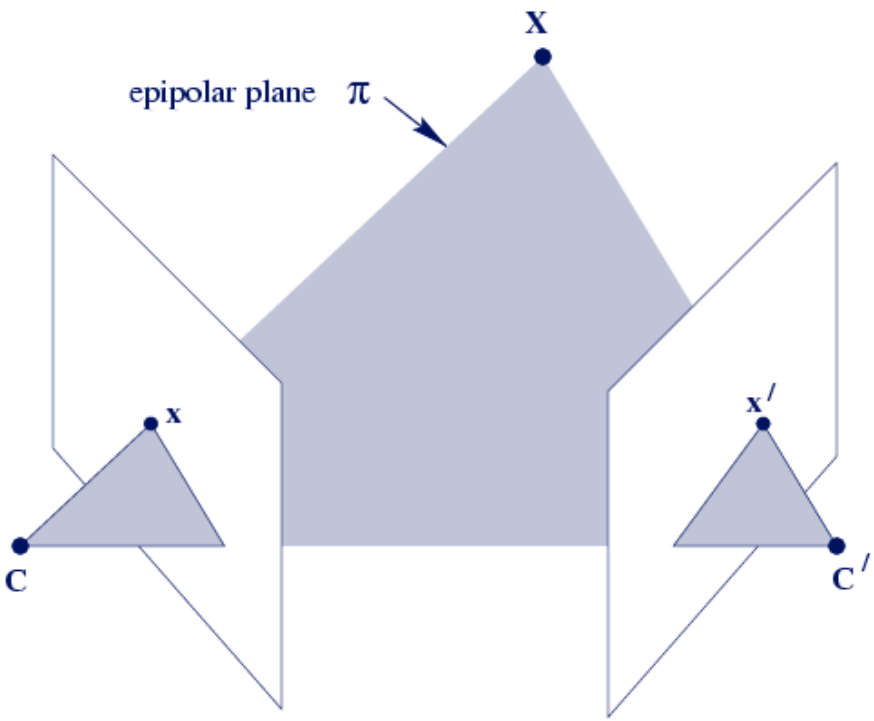

C, C', x, x' e X sono complanari

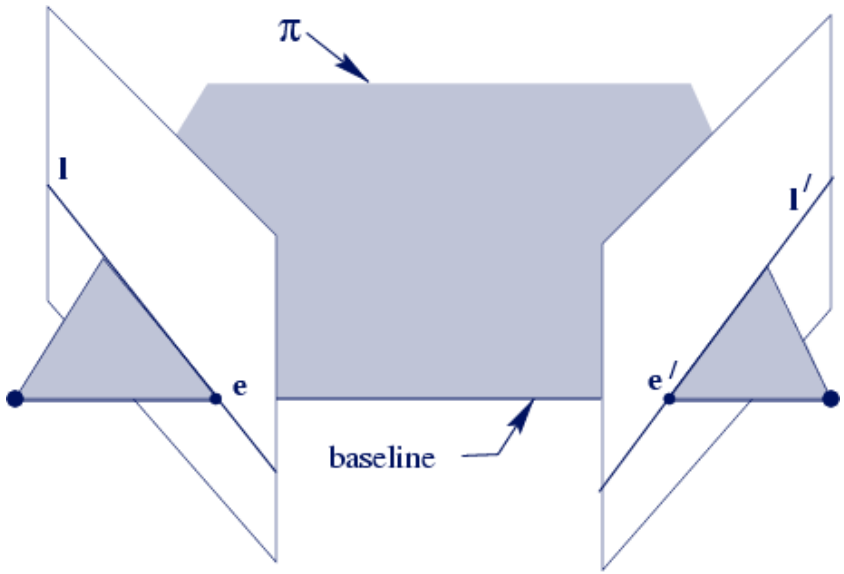

Tutti i punti di π saranno proiettati su l e l'

Geometria epipolare (2)

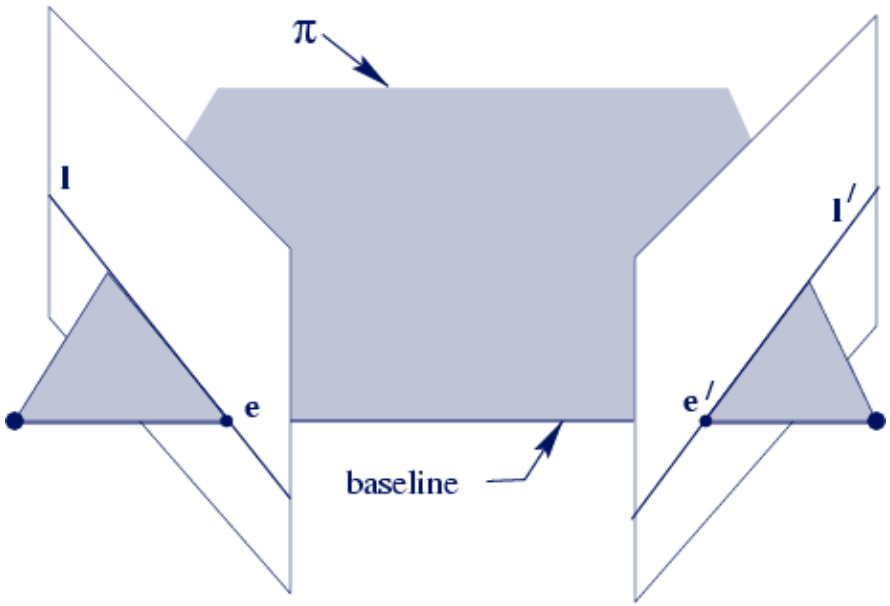

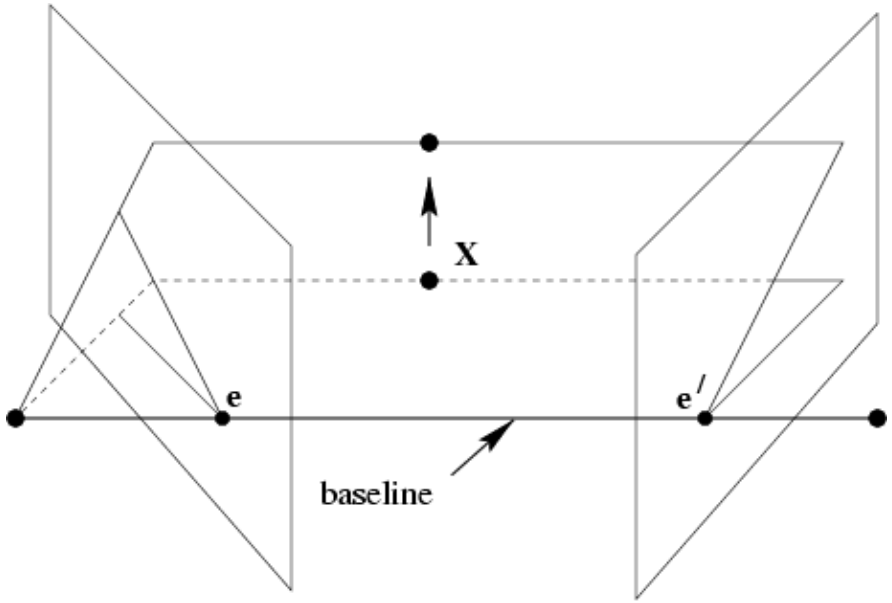

La *baseline* interseca i due piani immagine in due punti e ed e' detti *epipoli*.

Qualsiasi piano che includa la baseline è un *piano epipolare*.

L'intersezione di un piano epipolare con il piano immagine è detto *linea epipolare*.

Camere convergenti

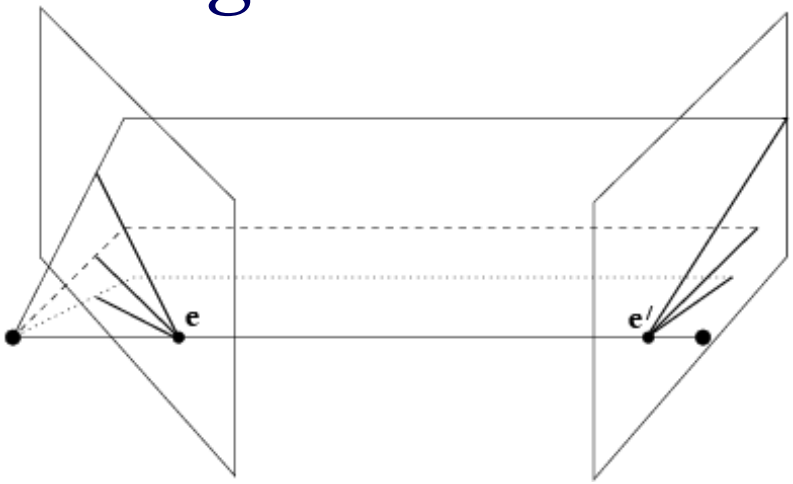

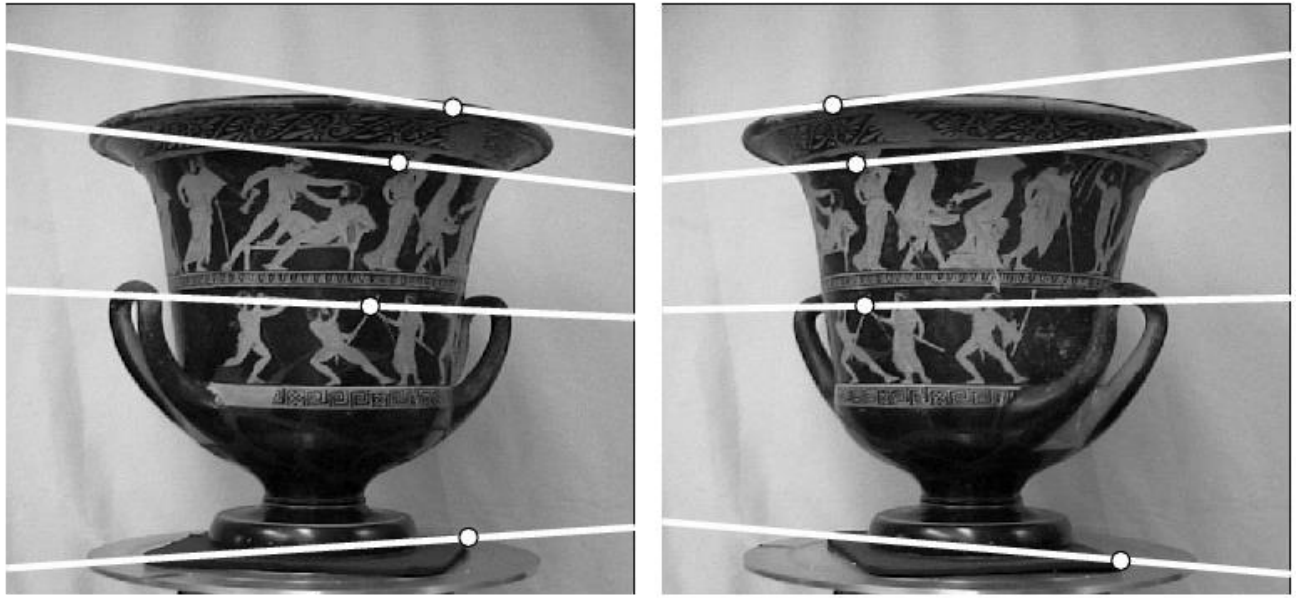

Camere parallele

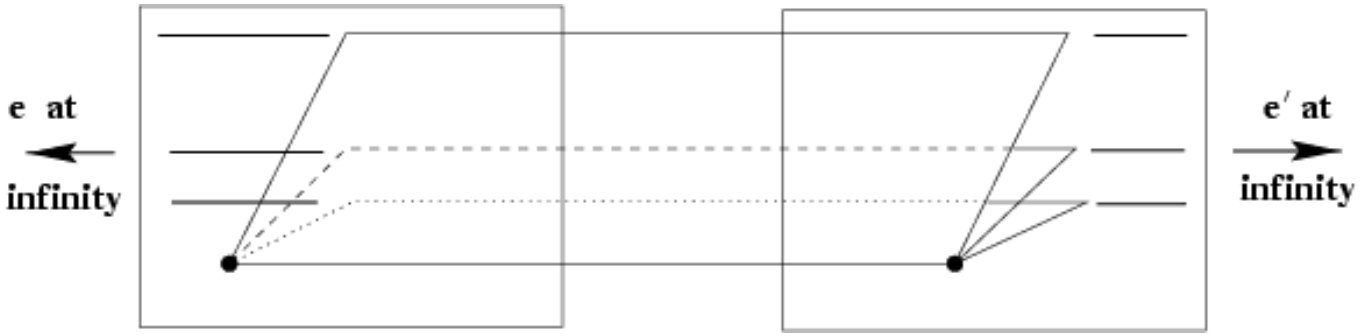

Camere calibrate (1)

$$\boldsymbol{p' = Rp + t}$$

$$t \times p' = t \times (Rp + t)$$

$$t \times p' = t \times Rp + \underbrace{t \times t}_{= 0}$$

$$t \times p' = t \times R\,p$$

$$p' \cdot (t \times p') = p' \cdot (t \times R\,p)$$

$$\underbrace{p' \cdot (t \times p')}_{= 0}$$

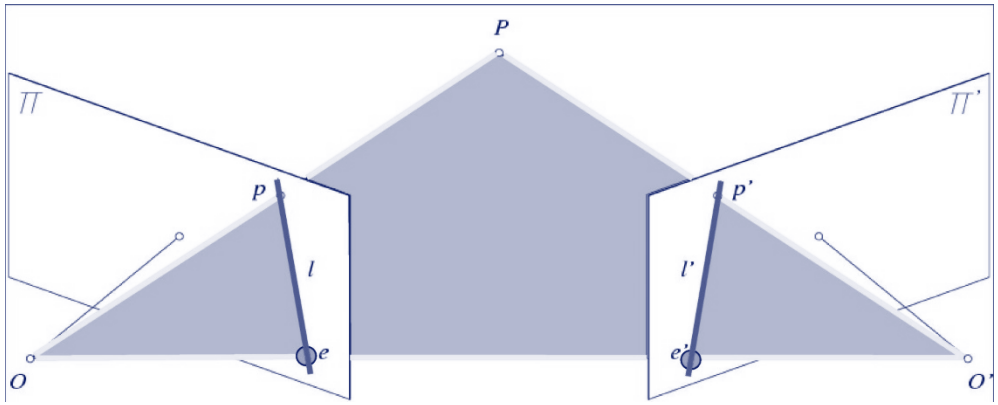

$$0 = p' \cdot (t \times R\,p)$$

$$p' \cdot [t]_\times R\,p = 0$$

$E = [t]_\times R$	*Essential matrix*
$\boldsymbol{p' E\, p = 0}$	*Epipolar constraint*

$$[t]_\times = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix}$$

Camere calibrate (2)

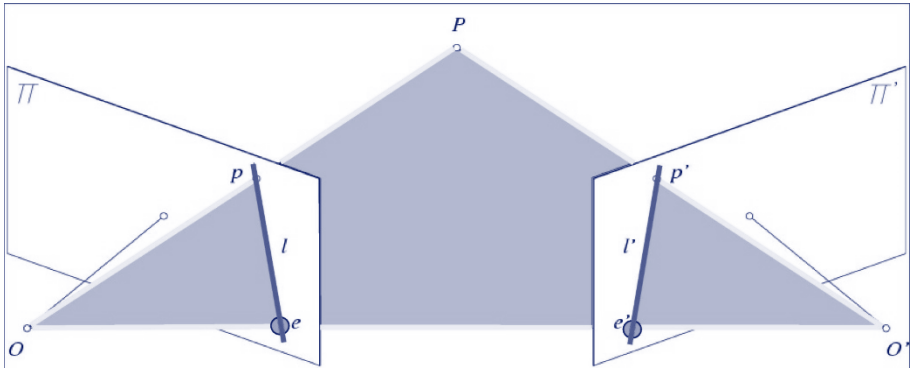

$$\boldsymbol{p}' = \boldsymbol{R}\boldsymbol{p} + \boldsymbol{t}$$

$E = [t]_\times R$ *Essential matrix*

$\boldsymbol{p}'\boldsymbol{E}\,\boldsymbol{p} = \boldsymbol{0}$ *Epipolar constraint*

- La matrice essenziale E può essere calcolata a partire dalle coordinate dell'immagine, usando SVD.
- Sono necessarie almeno 5 corrispondenze, ma un numero superiore di corrispondenze garantisce un risultato più accurato.
- La matrice essenziale può poi essere scomposta in R e t (sempre utilizzando SVD).
- Per la stima di E esiste una soluzione più semplice (Longuet-Higgins) basata su 8 punti (SVD).