Video Content Analysis

Annalisa Franco
annalisa.franco@unibo.it

Contenuti

- Introduzione
- Task
- Ambiti applicativi
- Problemi
- Visual motion
- La percezione del movimento
- Motion estimation
- Sottrazione del background
  - Aggiornamento del background
  - Gaussian Mixture Model
- Object tracking
  - Object shape representation
  - Object feature representation
  - Object detection
  - Tracking
    - Kalman filter
    - Mean-shift
    - GOTURN
- Action e activity recognition
  - Temporal templates

Introduzione

Con il termine *Video Content Analysis (VCA)* si intende *"la capacità di analizzare automaticamente un flusso video per rilevare e determinare eventi temporali e spaziali"*.

Si parla spesso in questo contesto di *semantic video understanding*, in riferimento al processo di analisi di una sequenza video al fine di individuare (localizzare e riconoscere) le «entità» presenti e gli eventi che si verificano al fine di attribuire un significato alla scena.

Persona 1 – prende in giro P2, scappa

Persona 3 – calcia P1

Persona 4 – interrompe il combattimento

CVPR 2011 - Tutorial on Human Activity Recognition - Frontiers of Human Activity Analysis – *J.K. Aggarwal, Michael S. Ryoo, Kris M. Kitani*

Task (1)

Video segmentation

- Scenario: una camera statica riprende la scena;
- Obiettivo: separare il background statico dal foreground in movimento.

Task (2)

Shot boundary detection

- Scenario: la camera può essere in movimento;
- Obiettivo: rilevare i cambiamenti di scena.

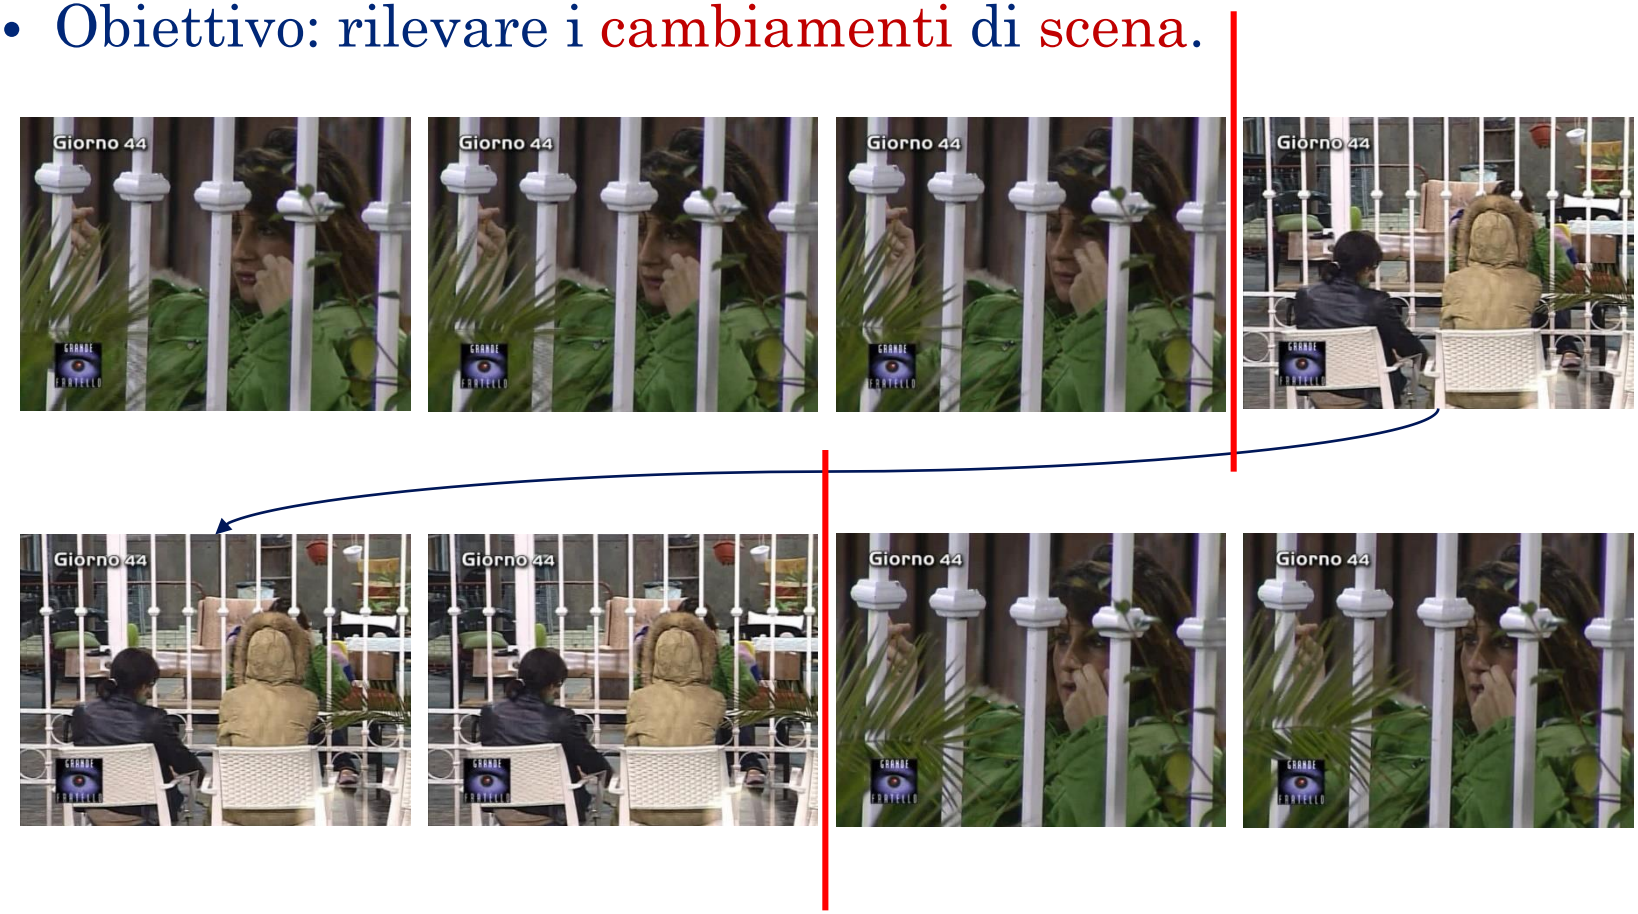

Task (3)

- **Motion segmentation**
  - Obiettivo: segmentare un video *isolando i singoli oggetti in movimento* (ciascuno presenterà un movimento coerente nel video)

Task (4)

Object tracking

- Scenario: camera statica o in movimento;
- Obiettivo: tracciare lo spostamento di uno o più oggetti in movimento.

car
car
car

Task (5)

- Mosaicing;
- Segmentazione di oggetti;
- Apprendimento di modelli dinamici;
- Stima della struttura 3D;
- Riconoscimento di eventi e attività;
- Miglioramento della qualità del video.

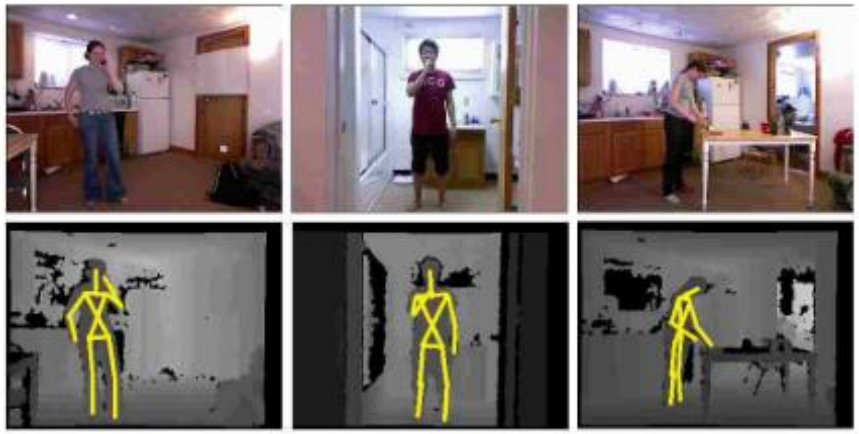

Ambiti applicativi

Traffic information

https://www.youtube.com/watch?v=PVCGDoTZHaI

Ambiti applicativi (2)

Sport

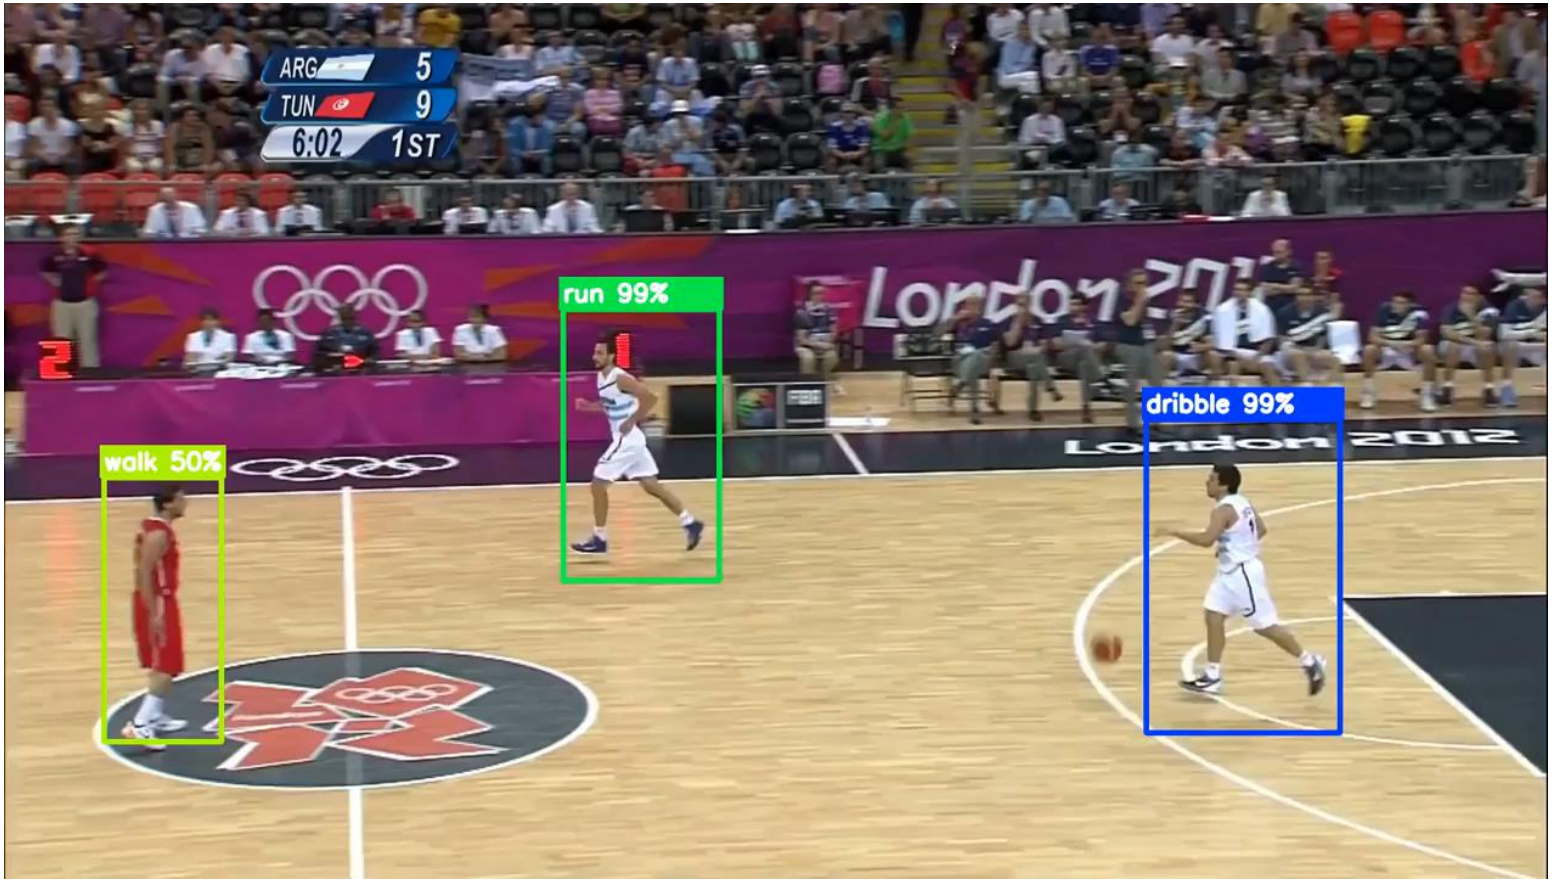

https://www.youtube.com/watch?v=PEziTgHx4cA

Ambiti applicativi (3)

Auto a guida autonoma

https://www.youtube.com/watch?v=URmxzxYlmtg&t=451s

Ambiti applicativi (4)

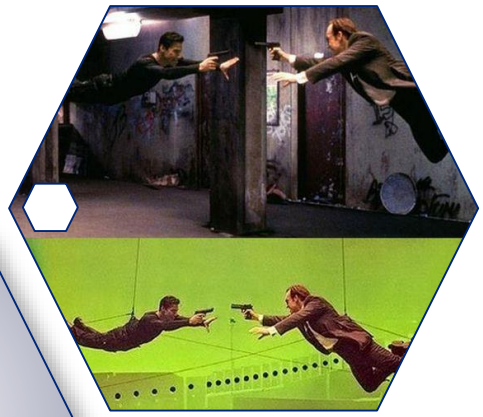

Film production

Surveillance

Human computer interaction

Problemi

- Cambiamenti nell'ambiente (es. illuminazione)
- Movimento della camera
- Camere multiple
- Oggetti multipli
- Occlusioni (parziali/totali)
- Movimenti rapidi (maggiori del frame rate)
- Oggetti di forma complessa, non rigida o articolata
- Scarsa disponibilità di dataset etichettati

Visual motion

Un video è una sequenza di frame catturati nel corso del tempo.

I valori dell'immagine sono funzione dello spazio (x,y) e del tempo (t).

La variabilità osservabile nelle tre dimensioni non è omogenea.

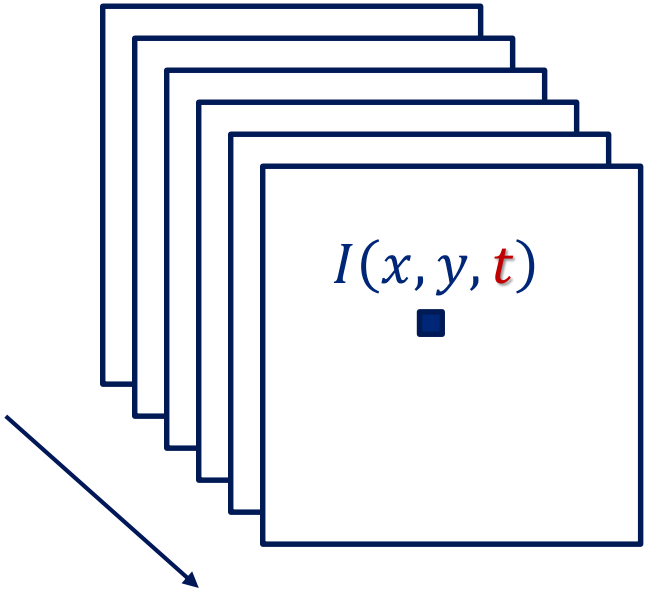

La percezione del movimento

Notate delle differenze tra le immagini (A) e (B)?

(A)

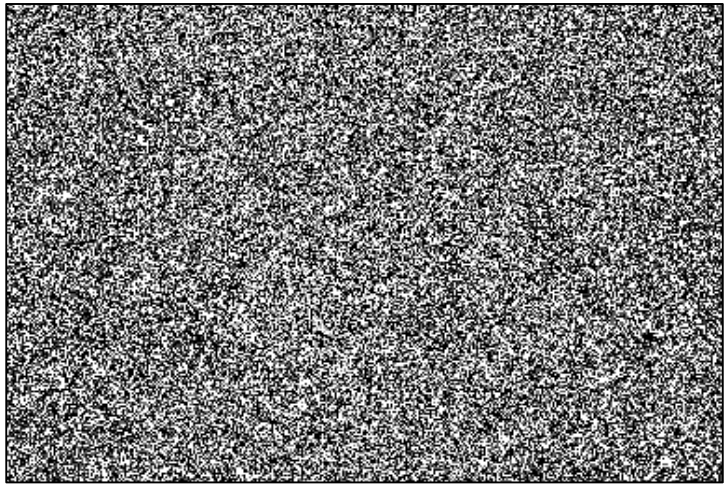

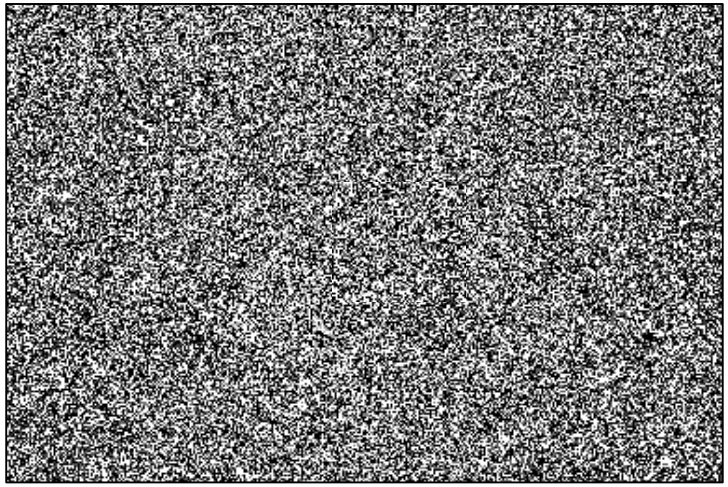

(B)

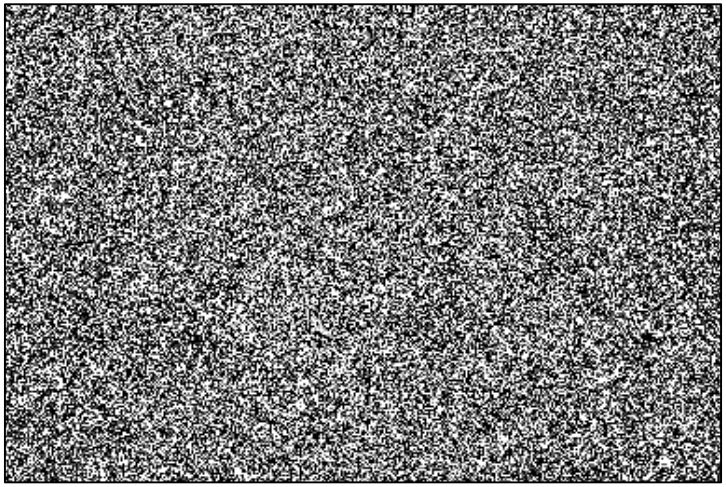

Motion estimation

In una sequenza video, un oggetto si dice in movimento se cambia la sua posizione rispetto al background.

Feature-based

- Estrazione di feature visuali (es. corner, key points) e tracking in frame consecutivi.
- *Sparse motion field*, robusto per il tracking.
- Adatto ad applicazioni nelle quali il cambiamento (movimento) tra frame consecutivi è ampio.

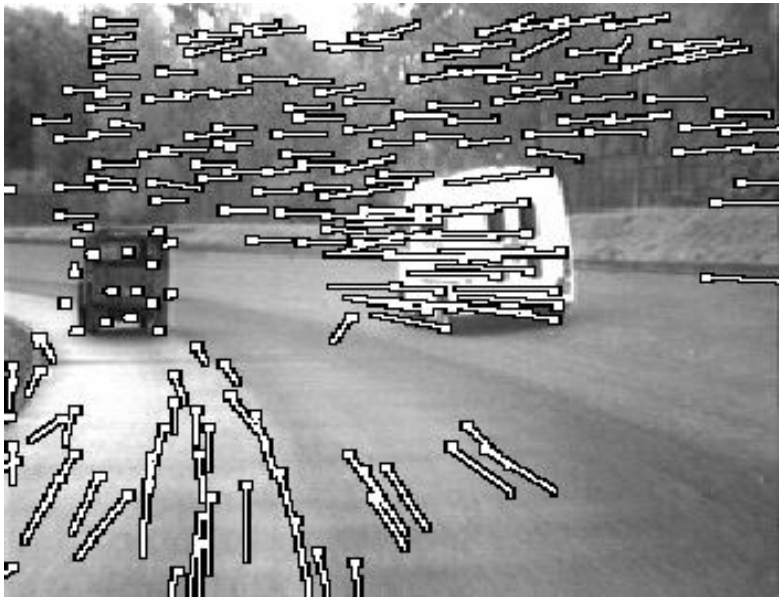

Motion estimation (2)

Metodi diretti (o densi)

- Calcolo diretto del movimento di ciascun pixel, a partire dalla variazione di luminosità nello spazio-tempo.
- *Dense motion field*, sensibile a variazioni dell'immagine.
- Adatto per applicazioni in cui il cambiamento tra frame consecutivi è limitato.

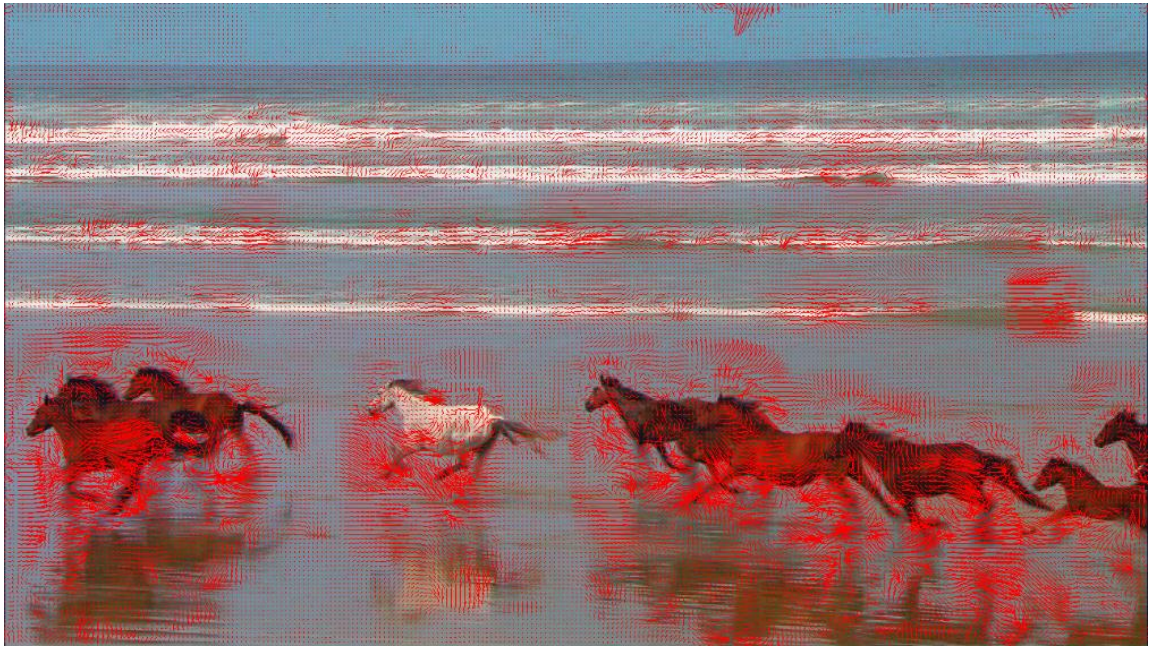

Sottrazione del background

Obiettivo: separare il background statico dal foreground in movimento.

Condizioni di utilizzo: camera statica.

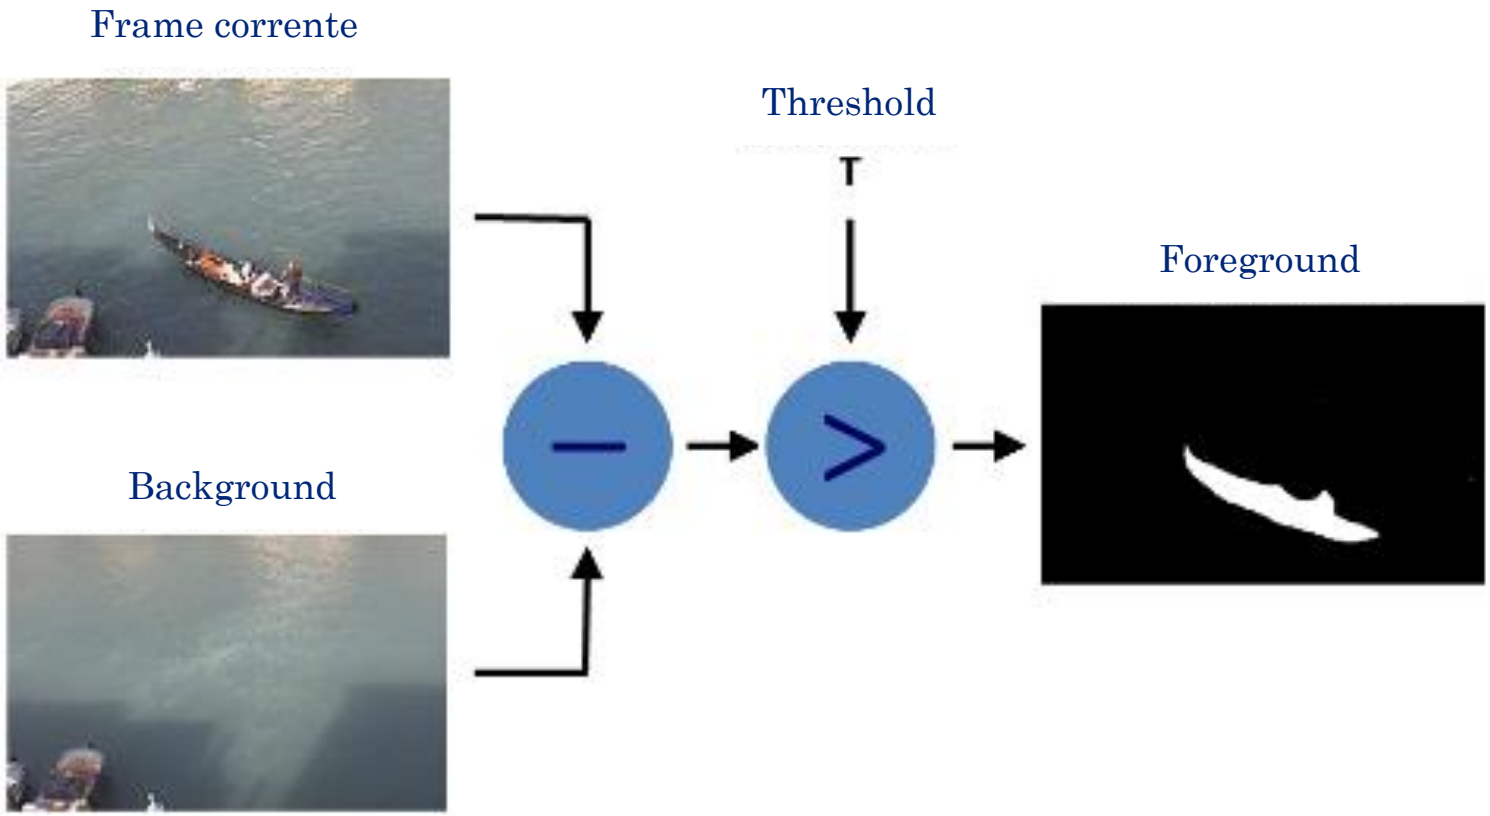

Background subtraction

- La tecnica di ***background subtraction*** è molto utilizzata per rilevare oggetti in movimento da telecamere statiche.

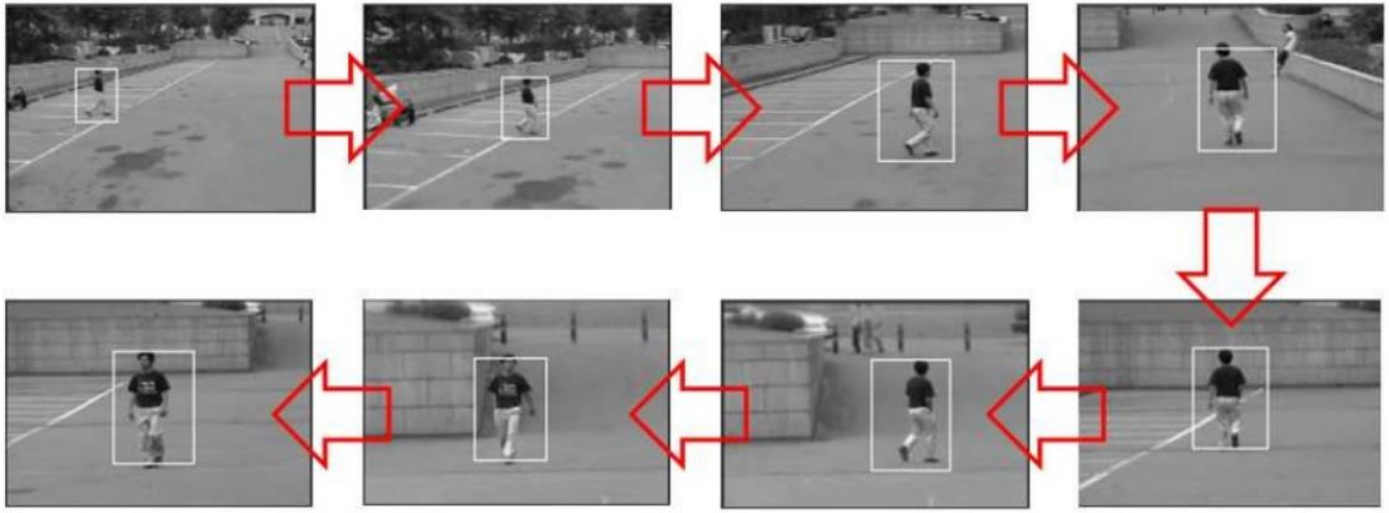

- L'idea di base è individuare gli oggetti in movimento osservando la differenza tra il frame corrente e un frame di riferimento che rappresenti il background (*frame differencing*)

Background subtraction: challenge

- L'immagine del background non è statica, dunque è necessario un approccio robusto a:
  - Cambiamenti di luminosità (graduali o improvvisi).

  - Movimento (oscillazioni della telecamera, oggetti di background in movimento).
  - Cambiamenti nella scena che rappresenta il background (es. auto parcheggiate).

Approccio semplice

- Siano $I(x, y, t)$ e $B(x, y, t)$ il frame e il background al tempo t;

- La maschera di foreground è costituita da tutti i pixel per i quali:

$$|I(x, y, t) - B(x, y, t)| > th$$

Come possiamo stimare il background al tempo t?

Stima del background (1)

- Frame precedente:

$$B(x, y, t) = I(x, y, t - 1)$$

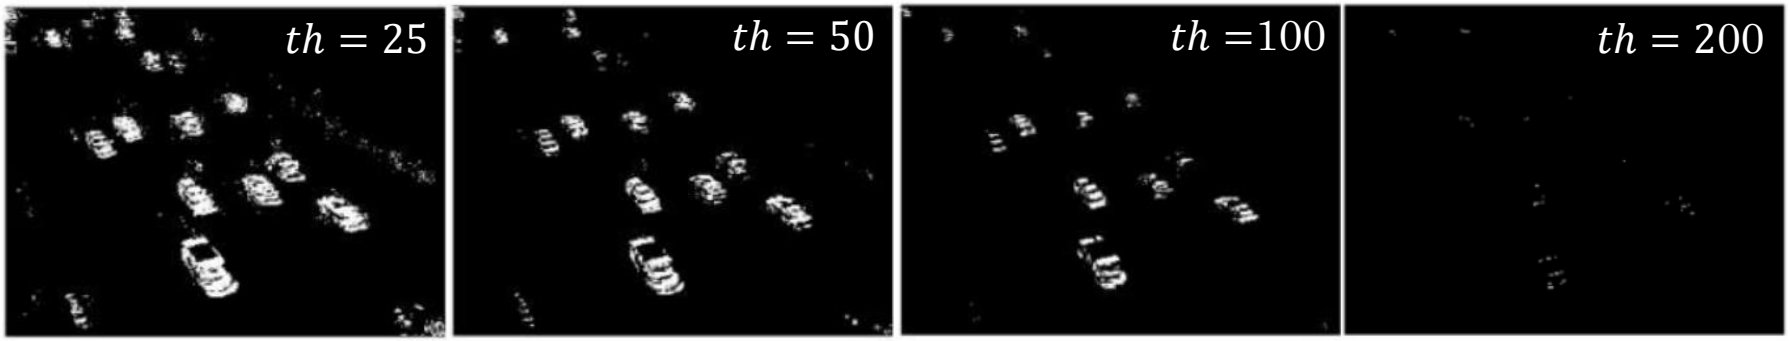

L'efficacia dipende fortemente dalla struttura degli oggetti, dalla loro velocità, dal frame rate e dalla soglia adottata.

Stima del background (2)

- Media degli *n* frame precedenti:

$$B(x,y,t) = \frac{1}{n}\sum_{i=0}^{n-1} I(x,y,t-i)$$

Il parametro *n* indica il numero di frame precedenti da prendere in considerazione per la modellazione del background → dovrebbe essere fissato in relazione a frame rate e velocità di variazione della scena.

n=10

n=50

Stima del background (3)

- **Mediana degli *n* frame precedenti:**

Nell'ipotesi che il background sia il *valore più probabile* per un determinato pixel, è possibile usare la mediana degli n frame precedenti come modello di background.

$$B(x,y,t) = mediana\{I(x,y,t-i)\}, \quad i = 1,..,n$$

La complessità computazionale è più elevata rispetto alla media: il calcolo della mediana può essere effettuato solo conoscendo tutti gli n valori e ordinandoli (per l'aggiornamento della media è sufficiente conoscere la media precedente e il numero di valori n).

$I(x,y,t)$

$B(x,y,t)$

Stima del background (4)

Vantaggi:

- estremamente semplici da implementare e da usare;
- sufficientemente veloci;
- modello di background adattivo.

Svantaggi:

- prestazioni dipendono dalla velocità di oggetti e frame rate;
- computazionalmente costosi;
- sensibilità rispetto al valore di soglia (fissa, non in funzione di t).

Gaussian Mixture Model

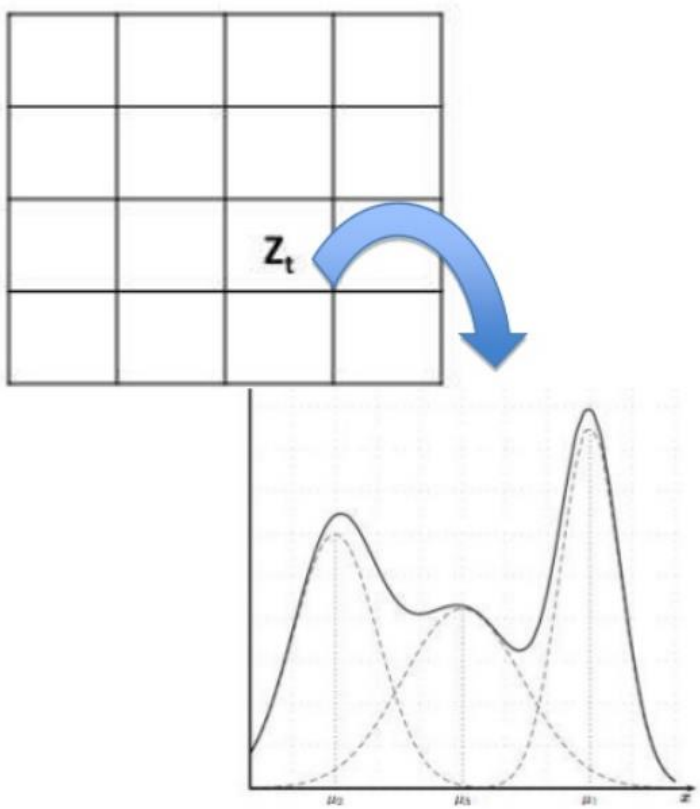

- A ciascun pixel è associata una mixture di distribuzioni Gaussiane (media e varianza) che ne modellano l'intensità.
- Rappresentazione in grado di modellare background multimodali.
- La memorizzazione dei parametri della distribuzione richiede meno spazio rispetto alla mediana.
- L'inizializzazione delle distribuzioni può avvenire osservando un piccolo intorno di ciascun pixel.
- Il background è variabile; è dunque necessario, ad ogni frame, aggiornare i parametri delle distribuzioni (modello adattivo).

C. Stauffer, W. Eric L. Grimson, "Adaptive background mixture models for real-time tracking," *conference on Computer Vision and Pattern Recognition (CVPR '99)*, pp. 23-25, 1999.

Gaussian Mixture Model (2)

- L'intensità di ciascun pixel è descritta da *K* distribuzioni Gaussiane ($K \approx 3-5$).
- Ciascuna Gaussiana è caratterizzata da:
  - $w_{i,t}$: peso della *i*-esima Gaussiana nella mixture al tempo *t;*
  - $\mu_{i,t}$: valore medio;
  - $\sigma_{i,t}^2$: matrice di covarianza.
- La probabilità di osservare il pixel x_t è:

$$P(x_t) = \sum_{i=1}^{K} w_{i,t} \times \eta\left(x_t, \mu_{i,t}, \sigma_{i,t}^2\right)$$

  dove η è la funzione di densità di probabilità.
- Un pixel "appartiene" all'*i*-esima Gaussiana se:

$$\mu_{i,t} - \gamma_i \cdot \sigma_{i,t} < x_t < \mu_{i,t} + \gamma_i \cdot \sigma_{i,t}$$

  dove γ_i è un parametro che può essere diverso per ogni pixel/distribuzione.

Gaussian Mixture Model (3)

- Ad ogni iterazione ciascun pixel è confrontato con le K Gaussiane.
- I parametri delle distribuzioni a cui appartiene il pixel x_t vengono aggiornati come segue:

$$w_{i,t} = (1-\alpha)w_{i,t-1} + \alpha$$

$$\mu_{i,t} = (1-\rho)\mu_{i,t-1} + \rho x_t$$

$$\sigma_{i,t}^2 = (1-\rho)\sigma_{i,t-1}^2 + \rho\left(x_t - \mu_{i,t}\right)^T\left(x_t - \mu_{i,t}\right)$$

$$\rho = \alpha \cdot \eta\left(x_t | \mu_{i,t-1}, \sigma_{i,t-1}\right)$$

  dove α è detto *learning rate*.

- I parametri delle altre distribuzioni non sono aggiornati.
- Se un pixel non appartiene ad alcuna distribuzione, la distribuzione meno probabile viene sostituita con una nuova distribuzione con una media pari a x_t, alta varianza e un peso iniziale basso.

Gaussian Mixture Model (4)

- Il background è rappresentato dalle distribuzioni che hanno bassa varianza e supporto elevato.

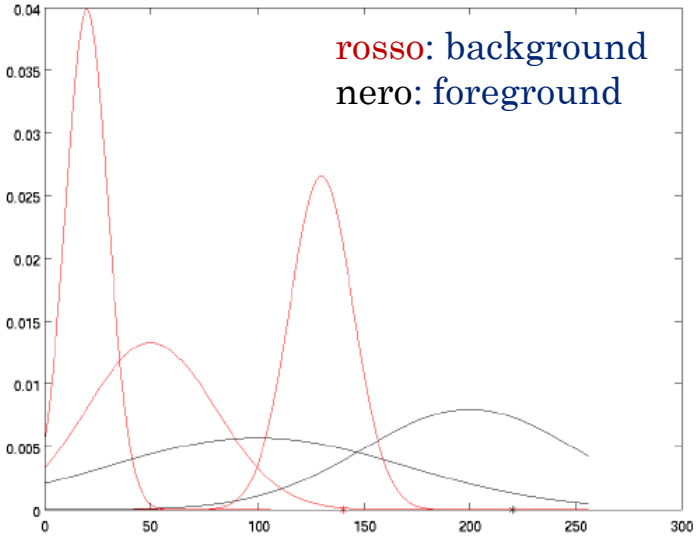

- Le Gaussiane sono ordinate sulla base del rapporto w_i/σ_i (valore elevato indica alto supporto e bassa varianza).
- Le prime B distribuzioni sono scelte come background:

$$B = argmin_b \left(\sum_{i=1}^{b} w_i > T_B \right)$$

dove T_B è la soglia di selezione del background.

- Ad ogni iterazione i pixel che non appartengono a nessuna delle distribuzioni di background (B) sono etichettati come foreground.

Gaussian Mixture Model (5)

- Vantaggi:
  - la "soglia" è locale per ciascun pixel;
  - il modello è adattivo;
  - gli oggetti possono entrare a far parte del background senza "distruggere" il modello esistente.
- Svantaggi:
  - non è in grado di gestire cambiamenti improvvisi;
  - sensibile all'inizializzazione (es. Median filtering);
  - presenza di parametri che devono essere valutati attentamente.

Queste semplici tecniche sono in grado di evidenziare i pixel in movimento, ma non di descriverne il movimento stesso. Per analisi video approfondite è necessario ricorrere a tecniche più avanzate di motion detection and tracking.

Object tracking

L'obiettivo dell'*object tracking* è quello di tracciare lo spostamento di uno o più oggetti in un flusso video.

Sono stati proposti in letteratura diversi algoritmi per diversi scenari applicativi che si differenziano per come rispondono alle seguenti domande:

- Qual è la rappresentazione degli oggetti più opportuna?
- Quali sono le feature più adatte?
- Come possono essere modellati il movimento, l'aspetto e la forma dell'oggetto?

Object tracking (2)

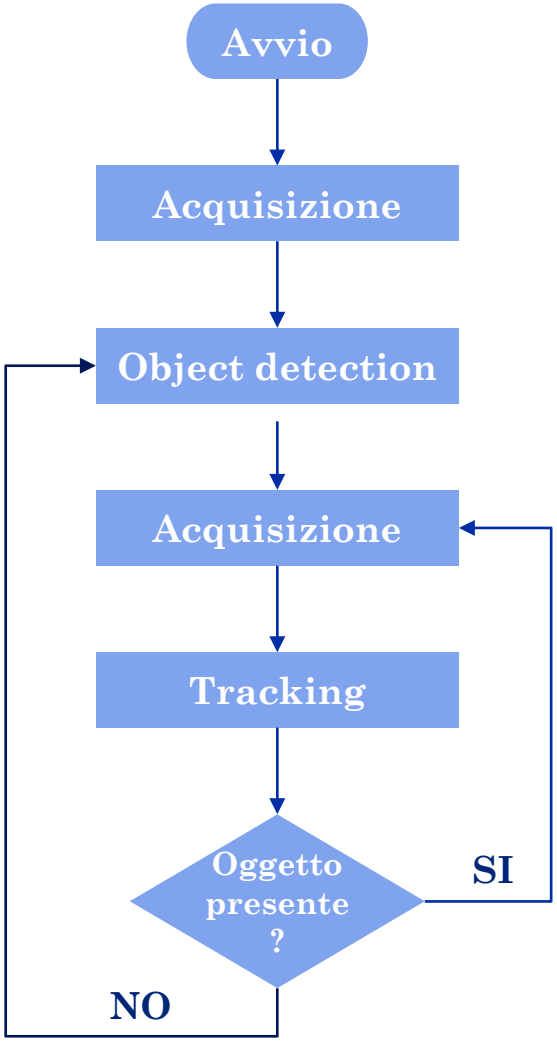

Object shape representation

Al fine di tracciarne il movimento un oggetto può essere rappresentato da diversi descrittori:

- *punto* – l'oggetto è rappresentato da un singolo punto, generalmente il baricentro. Questa rappresentazione è adatta quando gli oggetti sono piccoli rispetto all'immagine;

- *semplici forme geometriche* – come un rettangolo o un ellisse. Il movimento di queste forme è generalmente modellato con traslazioni, trasformazioni affini o omografiche. Vengono generalmente utilizzate per rappresentare semplici oggetti rigidi ma a volte sono utilizzati anche per oggetti articolati;

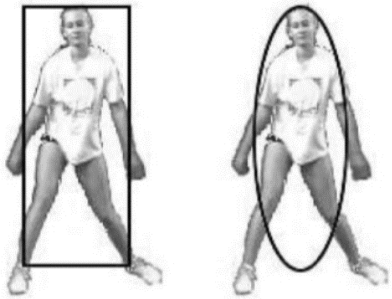

Object shape representation (2)

- *contorni e silhouette* – i contorni definiscono il confine dell'oggetto. La regione interna al contorno viene chiamata silhouette. Adatti per rappresentare forme articolate;

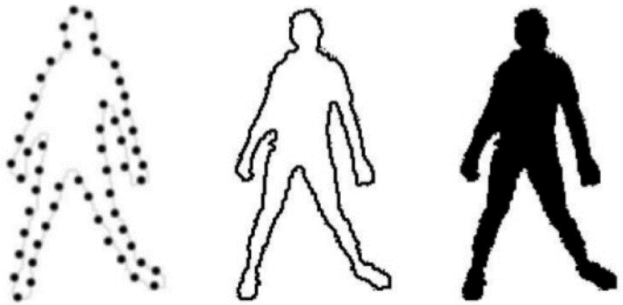

- *modelli articolati* – questi modelli sono composti da varie parti connesse tra loro tramite articolazioni. La relazione tra le varie parti è gestita da modelli cinematici;

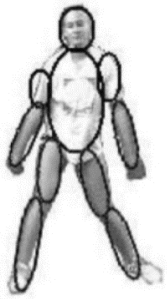

- *modelli scheletrici* – questi modelli sono generati applicando la *medial axis transform* alla siluette dell'oggetto. Possono essere utilizzati per modellare oggetti rigidi e articolati.

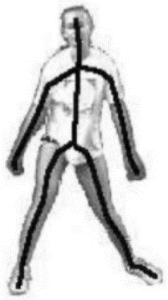

Object feature representation

La selezione delle feature più opportune gioca un ruolo fondamentale nei problemi di object tracking. Tra le feature più comunemente utilizzate vi sono:

- *colore* – lo spazio RGB viene solitamente utilizzato in image processing per rappresentare i colori. Altri spazi colore comunemente utilizzati per derivare delle feature sono HSL, Luv, Lab, ecc.. Tra le feature colore più comuni vi sono gli istogrammi colore e i *color moments*.
- *edge* – utili per rappresentare i contorni degli oggetti, queste feature sono meno sensibili a cambiamenti di illuminazione rispetto al colore;
- *optical flow* – o flusso ottico viene calcolato su una sequenza di frame e assegna a ogni pixel del frame corrente un vettore che punta verso la posizione dello stesso pixel nel frame successivo;
- *texture* – sono feature che misurano la variazione di intensità sulle superfici degli oggetti. La loro estrazione richiede l'utilizzo di algoritmi specifici che generano dei descrittori (es. matrici di co-occorrenza).

Object detection

Tutti i metodi di object tracking utilizzano meccanismi di object detection:

- ad ogni frame;
- quando un oggetto appare per la prima volta nella scena.

Solitamente vengono utilizzati approcci di object detection che operano su un singolo frame tuttavia alcuni metodi utilizzano le informazioni temporali ricavate da una sequenza di frame per ridurre il numero di falsi rilevamenti.

Tra i numerosi approcci di object detection ricordiamo: template matching, key points detector e tecniche di deep learning.

Anche la sottrazione del background, combinata con l'etichettatura delle componenti connesse permette di ottenere regioni connesse corrispondenti ai vari oggetti in movimento presenti sulla scena.

Tracking

Gli algoritmi di *tracking* possono essere divisi in tre macro-categorie:

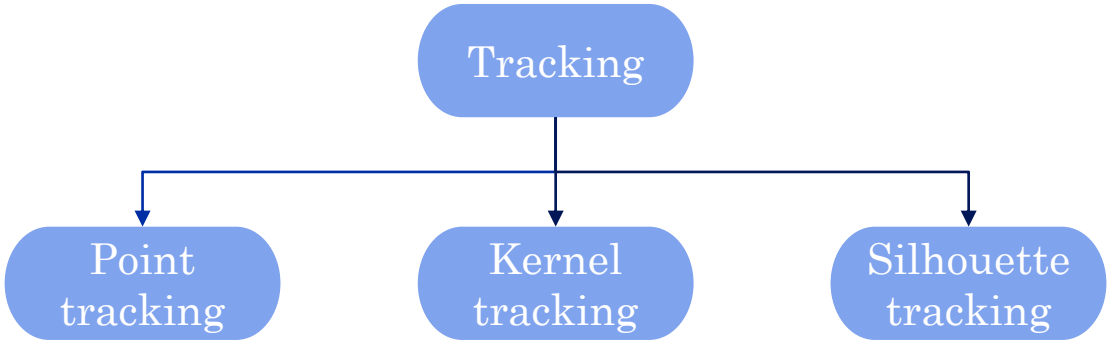

- *Point tracking* – gli oggetti rilevati sono rappresentati da un singolo punto (es. baricentro). L'associazione tra punti individuati su frame consecutivi avviene sulla base dello stato dell'oggetto (es. coordinate del punto e movimento). Questi approcci utilizzano un metodo esterno per individuare gli oggetti in ogni frame.

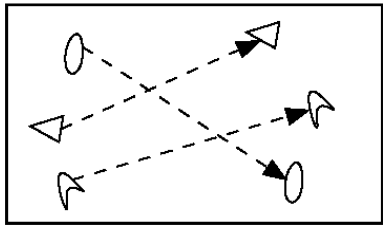

Tracking (2)

- *Kernel tracking* - con il termine kernel ci si riferisce alla forma e alle feature con cui sono rappresentati gli oggetti (es. un rettangolo o un'ellisse con associato un istogramma colore). Gli oggetti sono tracciati stimando il movimento del kernel su frame consecutivi. Solitamente il movimento viene rappresentato sotto forma di trasformazione parametrica (es. traslazione, rotazione e affine).

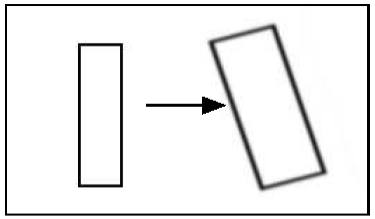

- *Silhouette tracking* – il tracking è eseguito stimando, per ogni frame, la regione occupata dall'oggetto. Le informazioni contenute nella regione dell'oggetto sono codificate in un modello per rappresentarne forma e aspetto (es. *edge map*). Ottenuti i modelli dei vari oggetti, questi sono tracciati confrontando le forme o valutando l'evoluzione del contorno.

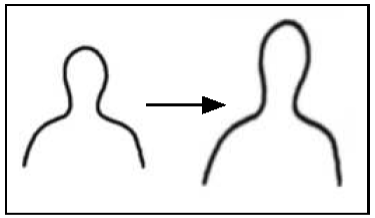

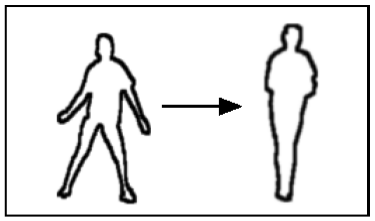

Kalman filter

Il filtro di Kalman è un filtro ricorsivo che valuta lo stato di un sistema dinamico a partire da una serie di misure soggette a rumore.

Si può utilizzare in qualsiasi applicazione in cui:

- si disponga di informazioni incerte sullo stato di un sistema dinamico;
- si può fare un'ipotesi plausibile sullo stato futuro del sistema.

Ha tre importanti caratteristiche che lo rendono uno strumento utile per l'object tracking. È in grado di:

- predire la posizione futura di un oggetto;
- ridurre il rumore introdotto da rilevamenti inaccurati (object detection);
- facilitare l'associazione di un oggetto alla corrispondente traccia.

Kalman filter (2)

Esempio:

Supponiamo di voler tracciare un robot che si muove liberamente in uno spazio bidimensionale avendo a disposizione un modello matematico per rappresentarne il movimento e un sensore per rilevarne la posizione (entrambi affetti da errore).

Lo stato del robot essere rappresentato con le coordinate della sua posizione: $\hat{\mathbf{x}} = \begin{bmatrix} \hat{x} \\ \hat{y} \end{bmatrix}$.

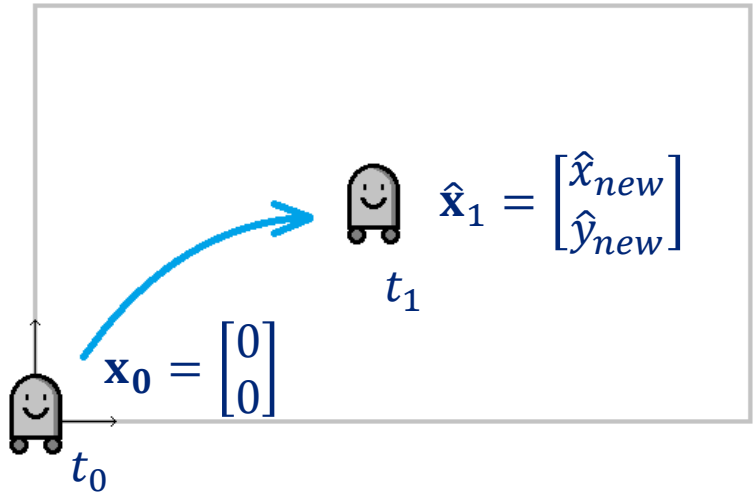

Kalman filter (3)

Esempio (continua):

Come possiamo stimare lo stato del robot al tempo t conoscendone lo stato al tempo $t-1$?

1. Si calcola la posizione del robot al tempo t applicando il modello matematico.
2. Essendo il modello affetto da errore si otterrà una funzione di densità di probabilità rappresentata da media e matrice di covarianza.
3. Tramite il sensore viene rilevata la posizione del robot (object detection) anch'essa affetta da errore.
4. Si calcola il *Kalman gain*.
5. Si stima lo stato del robot al tempo t: $\hat{\mathbf{x}}_t$.
6. Si aggiorna la covarianza.
7. Si ricomincia dal punto 1.

$\mathbf{x}_{t-1}$

https://mayitzin.com/2015/06/04/kalman-filter-a-painless-approach/

Mean-shift

Mean-shift è un metodo non parametrico per la ricerca delle mode di una funzione di densità di probabilità. Può essere utilizzato per il tracking di oggetti il cui aspetto può essere modellato utilizzando la distribuzione del colore (es. istogramma colore).

Utile per oggetti articolati (es. una persona che cammina) in cui è difficile specificare esplicitamente un modello matematico del movimento.

L'oggetto da tracciare viene scelto nel primo frame:

- manualmente;
- utilizzando un metodo di object detection.

Le feature colore vengono estratte da una regione di forma rettangolare o ellissoidale.

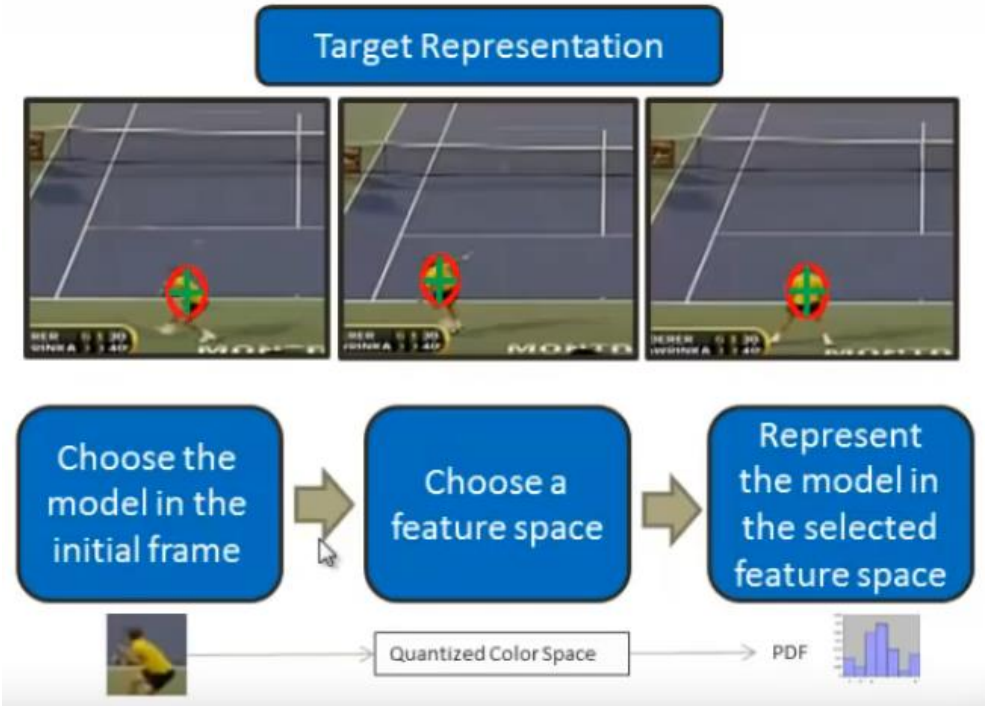

Mean-shift (2)

Date le feature q e la posizione x, y dell'oggetto nel frame $t-1$:

1. si imposta la regione di interesse (RoI) nel frame t centrata in posizione x, y;
2. si individua il candidato più simile all'interno della RoI utilizzando una funzione di similarità tra distribuzioni del colore.

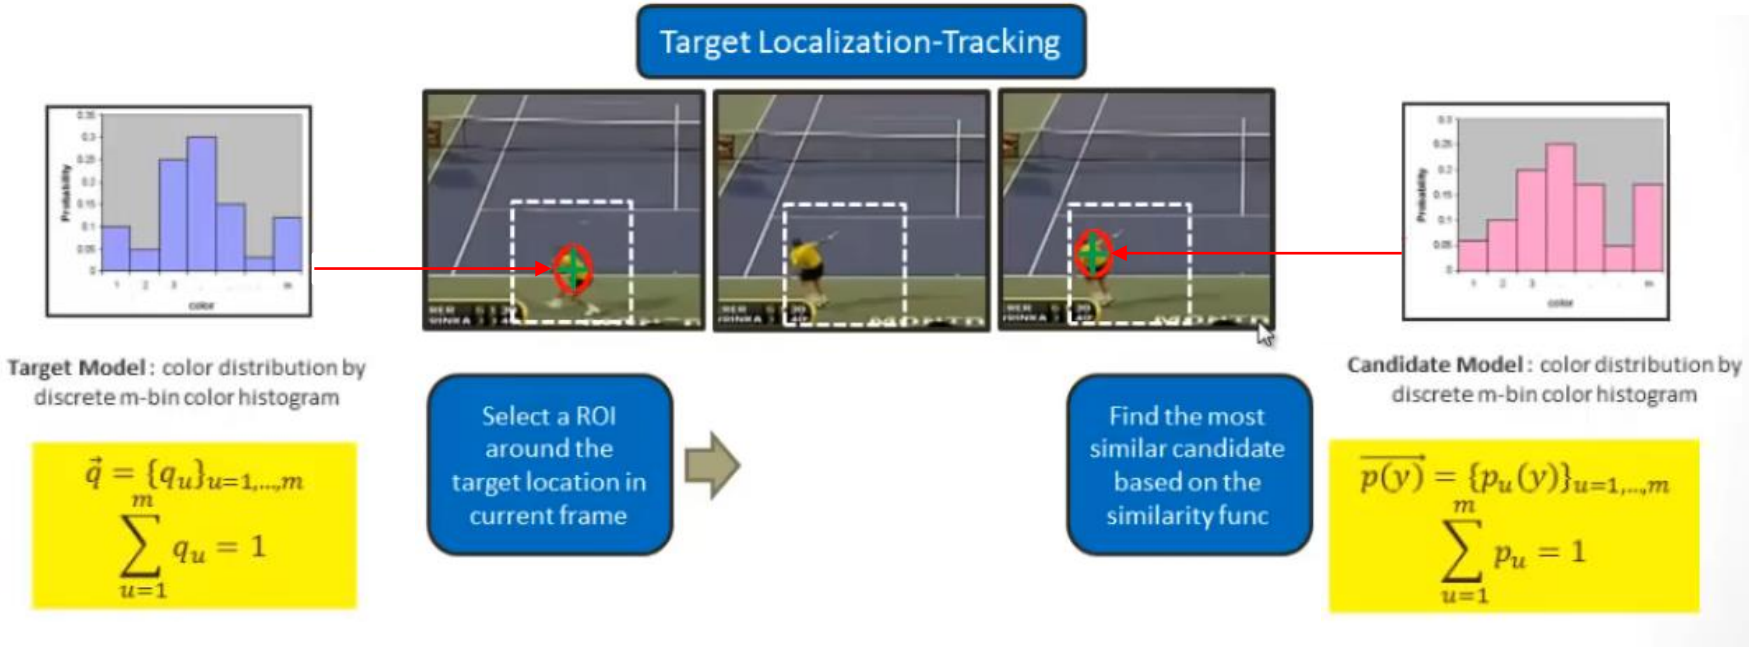

GOTURN

Nel 2016 viene proposto uno dei primi metodi per l'object tracking (di un singolo oggetto) basato su deep learning: *Generic Object Tracking Using Regression Networks* (GOTURN).

- Il modello è costituito da due CNN (ognuna composta da cinque convolutional layer) che prendono in input rispettivamente i crop del frame corrente e di quello precedente (entrambi centrati sulla detection del frame precedente).
- L'output delle due CNN viene concatenato e passato in input a tre fully-connected layer.
- Il livello di output contiene quattro neuroni che rappresentano la bounding box.

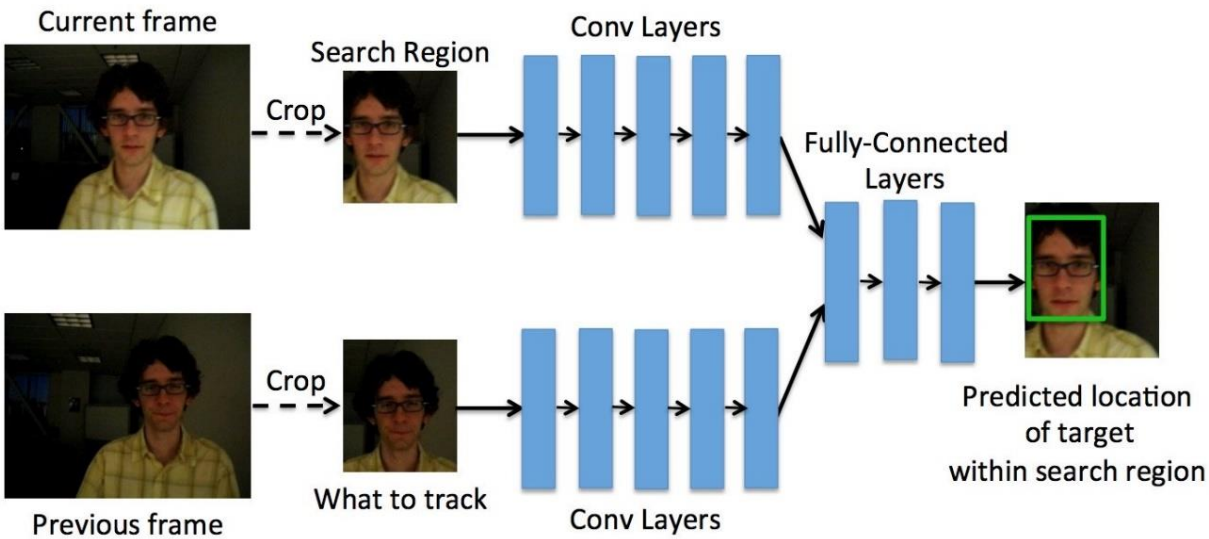

Action e activity recognition

È il processo che associa a un flusso video un'etichetta o una descrizione che esprime l'azione/attività compiuta dal/i soggetto/i presenti nella scena.

Alcuni termini:

- evento - un singolo momento nel tempo (es. una porta che si chiude);
- azione –un movimento "atomico", un singolo gesto (es. mettersi a sedere);
- attività – una serie di azioni che avvengono simultaneamente (es. interazione tra persone).

Temporal templates

Cosa rappresentano questi punti in movimento?

Nel video a lato si intuisce che i punti in movimento rappresentano una persona che cammina.

Non riconosciamo che è una persona dall'aspetto dei punti ma bensì dal loro movimento.

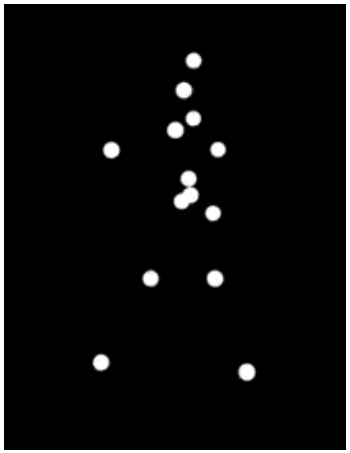

Notiamo qualche oggetto nell'immagine a lato?

Dopo aver visto il video possiamo dire che sulla destra vi è una persona in piedi che si siede (probabilmente su una sedia) e sullo sfondo potrebbe esserci una finestra o una lavagna.

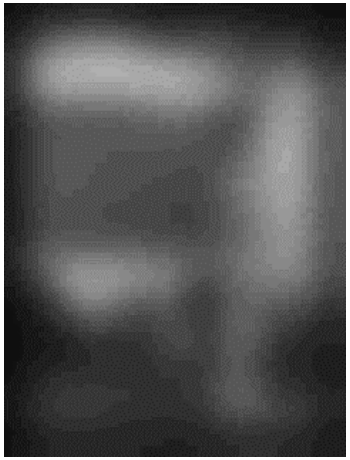

Conclusione: un umano è in grado di riconoscere facilmente un'azione anche senza informazioni dettagliate. È possibile rilevare un'azione dal movimento stesso.

Temporal templates (2)

La *Motion Energy Image* (MEI) è una rappresentazione binaria che mette in risalto le regioni dell'immagine in cui è presente del movimento.

$$I(x, y, t)$$

$$E_\tau(x, y, t) = \bigcup_{i=0}^{\tau-1} D(x, y, t - i)$$

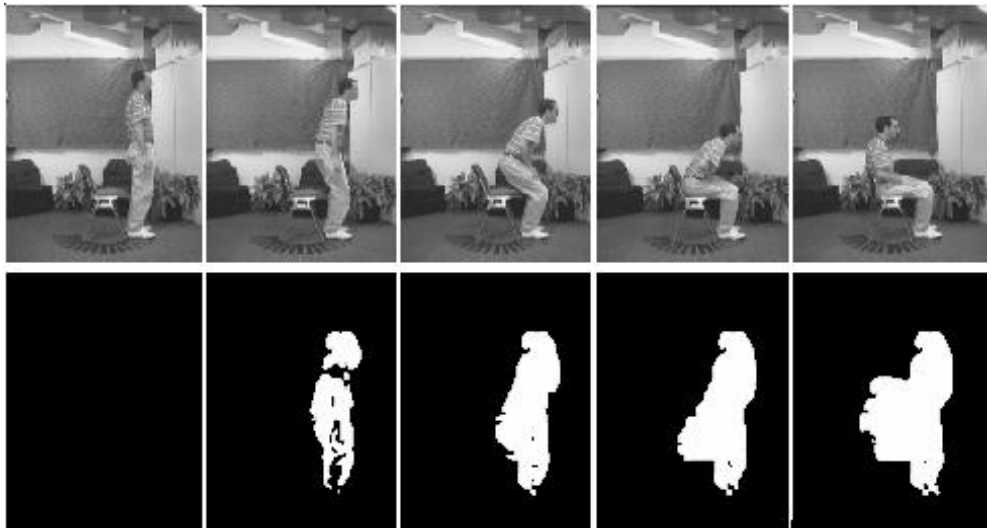

dove $D(x, y, t)$ è una sequenza di immagini binarie che mostrano le regioni in cui vi è stato del movimento in due frame contigui (es. semplice differenza tra frame binarizzata con una soglia).

Temporal templates (3)

La *Motion History Image* (MHI) è un'immagine in cui l'intensità di ogni pixel è funzione di quanto recentemente vi è stato del movimento in quella posizione.

$$H_\tau(x,y,t) = \begin{cases} \tau & \text{se } D(x,y,t) = 1 \\ \max(0, H_\tau(x,y,t-1) - 1) & \text{altrimenti} \end{cases}$$

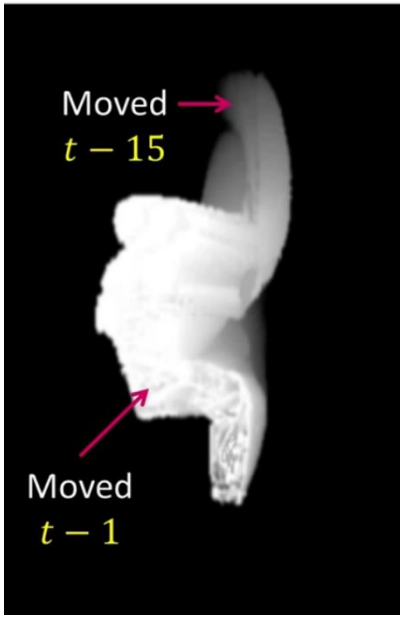

Temporal templates (4)

Data una sequenza video, vengono calcolate la MEI e la MHI che insieme vanno a formare il *temporal template* della sequenza.

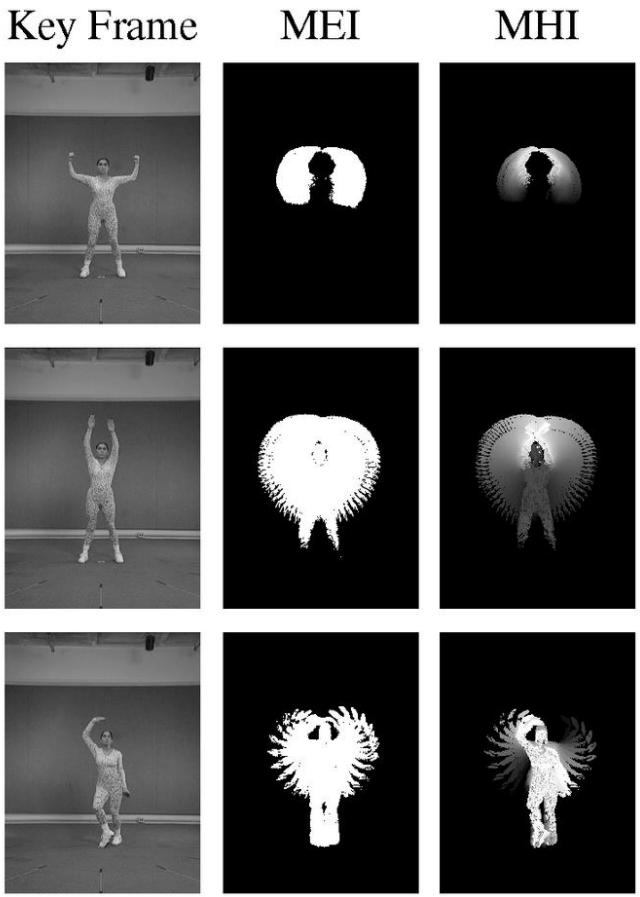

Temporal templates (5)

I momenti invarianti sono una particolare media pesata dell'intensità dei pixel che compongono l'immagine.

Data un'immagine $I(x,y)$, il momento semplice M_{ij} è dato da:

$$M_{ij} = \sum_x \sum_y x^i y^j I(x,y)$$

I momenti centrali (invarianti per traslazione) si calcolano come:

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q I(x,y)$$

in cui $\bar{x} = \frac{M_{10}}{M_{00}}$ e $\bar{y} = \frac{M_{01}}{M_{00}}$ sono le componenti del centroide.

Temporal templates (6)

Momenti di Hu

- 7 momenti centrali
- Invarianti per traslazione, rotazione e scala
- Permettono di ottenere un descrittore di forma spazio-temporale globale

$$[h_1, h_2, h_3, h_4, h_5, h_6, h_7]$$

Temporal templates (7)

$$h_1 = \mu_{20} + \mu_{02}$$

$$h_2 = (\mu_{20} - \mu_{02})^2 + 4\mu_{11}^2$$

$$h_3 = (\mu_{30} - 3\mu_{12})^2 + (3\mu_{21} - \mu_{03})^2$$

$$h_4 = (\mu_{30} + \mu_{12})^2 + (\mu_{21} + \mu_{03})^2$$

$$h_5 = (\mu_{30} - 3\mu_{12})(\mu_{30} + \mu_{12})[(\mu_{30} + \mu_{12})^2 - 3(\mu_{21} + \mu_{03})^2] +$$
$$+(3\mu_{21} - \mu_{03})(\mu_{21} + \mu_{03})[3(\mu_{30} + \mu_{12})^2 - (\mu_{21} + \mu_{03})^2]$$

$$h_6 = (\mu_{20} - \mu_{02})[(\mu_{30} + \mu_{12})^2 - (\mu_{21} + \mu_{03})^2] +$$
$$+4\mu_{11}(\mu_{30} + \mu_{12})(\mu_{21} + \mu_{03})$$

$$h_7 = (3\mu_{21} - \mu_{03})(\mu_{30} + \mu_{12})[(\mu_{30} + \mu_{12})^2 - 3(\mu_{21} + \mu_{03})^2] +$$
$$-(\mu_{30} - 3\mu_{12})(\mu_{21} + \mu_{03})[3(\mu_{30} + \mu_{12})^2 - (\mu_{21} + \mu_{03})^2]$$

Temporal templates (8)

Addestramento

1. Sono generati i temporal template (MEI+MHI) di tutte le sequenze di training.
2. Sono calcolati i momenti di Hu di ogni temporal template.
3. Per ogni tipo di azione viene generato un modello statistico (media μ e matrice di covarianza S) dei corrispondenti momenti di Hu.

Riconoscimento

1. Viene generato il temporal template della sequenza di input.
2. Vengono estratti i momenti di Hu (x) dal temporal template di input.
3. Viene calcolata la distanza di Mahalanobis tra x e tutti i modelli statistici ottenuti in fase di training:

$$D_M(x) = \sqrt{(x-\mu)^T S^{-1}(x-\mu)}.$$

3. L'etichetta restituita è quella associata all'azione del modello statistico con la distanza minore.

RGB vs RGB-D

- Molti degli approcci recenti per il riconoscimento di attività utilizzano sensori RGB-D che permettono di acquisire, oltre alle informazioni relative ai canali RGB, la profondità dei punti sulla scena.
- Questi sensori, sfruttando le informazioni di profondità, si prestano per operare in modo ottimale in ambienti indoor. Infatti, il sensore IR di cui sono dotati ha una profondità che può raggiungere, nei casi migliori, 6-7 metri.
- Kinect permette il tracking di individui e l'estrazione di informazioni scheletrali: caratteristiche fondamentali nel in questo dominio.

Challenges RGB-D - 1

- Cambiamenti di illuminazione (RGB)
  - I video contengono variazioni di illuminazione più o meno significative

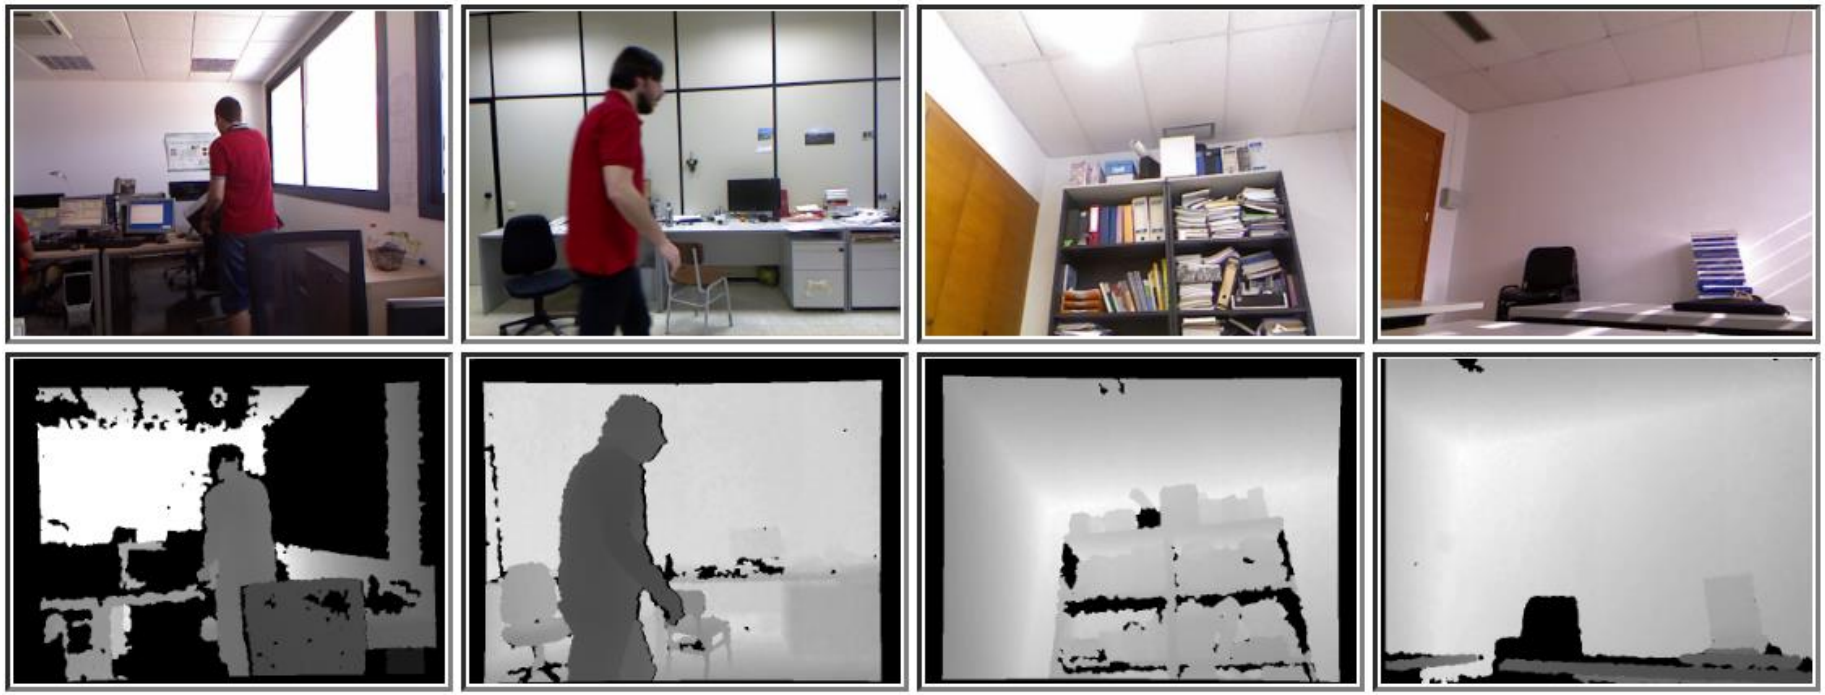

Challenges RGB-D - 2

- Color camouflage (RGB)
  - Difficoltà a segmentare gli oggetti in foreground dal background a causa di una similarità a livello di colore.

Challenges RGB-D - 3

- Depth Camouflage (D)
  - I video includono oggetti foreground con profondità molto simile al background

Challenges RGB-D - 4

- Out of Sensor Range (D)
  - I video includono oggetti foreground o background che sono troppo vicini o lontani dal sensore

Un approccio multimodale

- Obiettivo: sfruttare le potenzialità del sensore Kinect per creare un sistema automatico di riconoscimento di attività che combini
  - informazioni sullo scheletro della persona (estratte dalle mappe di profondità)
    - catturare al meglio le pose che il soggetto assume durante lo svoglimento delle attività
  - immagini RGB
    - Modellare in modo più preciso l'evoluzione temporale dell'attività e l'interazione con gli oggetti.

A. Franco, A. Magnani and D. Maio, "A multimodal approach for human activity recognition based on skeleton and RGB data", Pattern Recognition Letters, vol.131, pp.293-299, March 2020.

Codifica dello scheletro

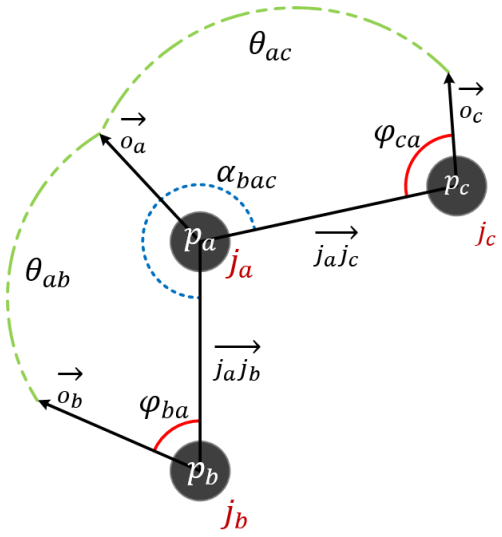

Un sottoinsieme di joints (j_a, j_b, j_c) e i relativi angoli θ,φ e α

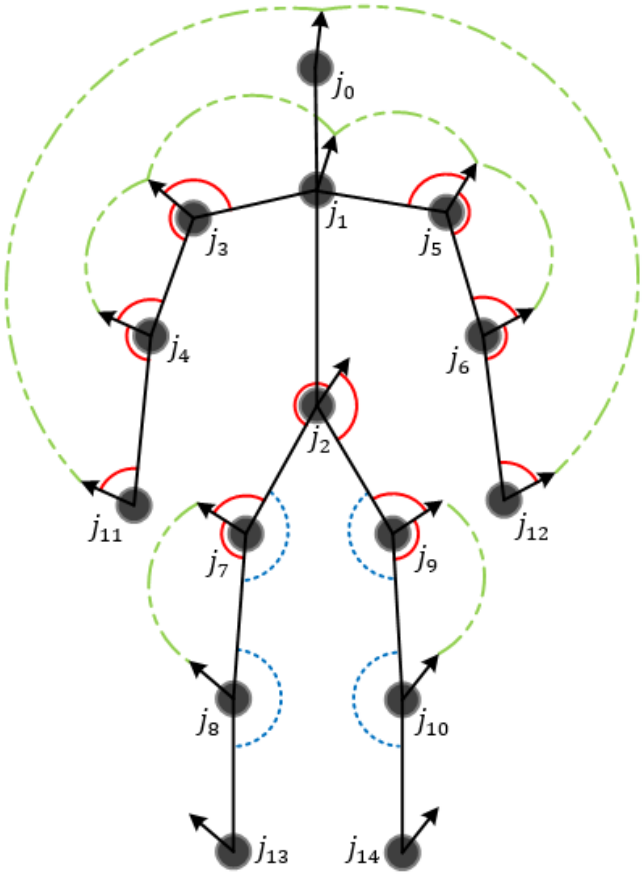

Configurazione composta da 28 angoli derivati da 15 joints scheletrali

Activity Recognition: Training

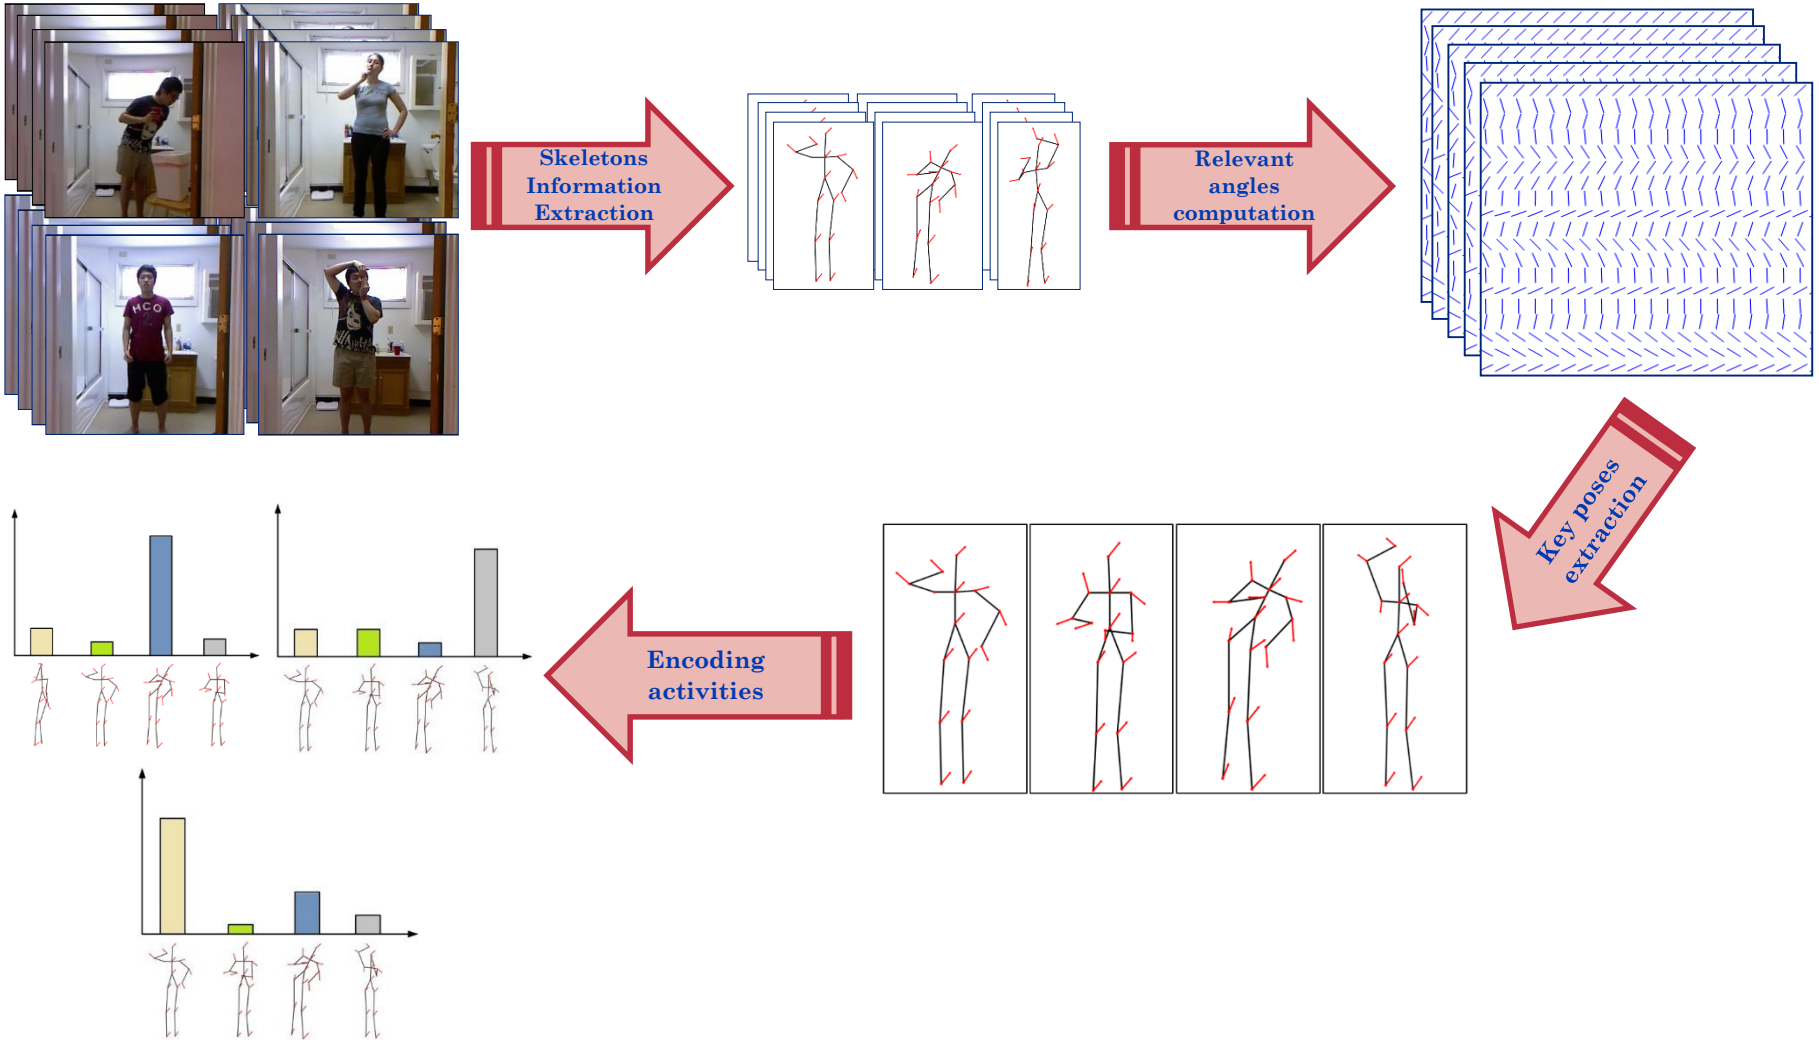

Modello Bag-of-Word - 1

- Ogni frame f_i di una sequenza è rappresentato da un vettore di *features* ottenuto dalla concatenazione ordinata dei valori degli angoli.

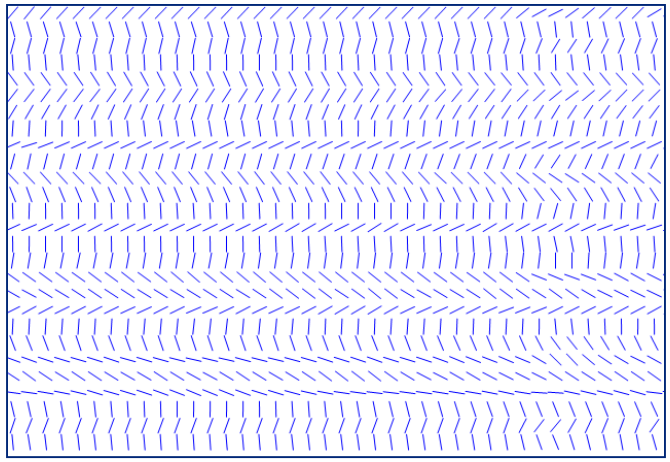

- Per ogni attività, il numero di frame può essere estremamente alto:
  - non tutti i risultanti vettori di features sono significativi;
  - ogni soggetto esegue una attività in maniera unica (forte variabilità anche nella lunghezza)
- Necessità:
  - minimizzare la rappresentazione di ogni sequenza;
  - produrre un descrittore a lunghezza fissa.
- Possiamo rappresentare ogni attività come un istogramma di occorrenze di alcune pose chiave (cioè descrivere un'attività come una collezione di pose rilevanti).

Modello Bag-of-Word - 2

1. Algoritmo K-Means
   - Al fine di produrre un dizionario di riferimento (W) che permetta di codificare le principali pose assunte durante le differenti attività del training set.

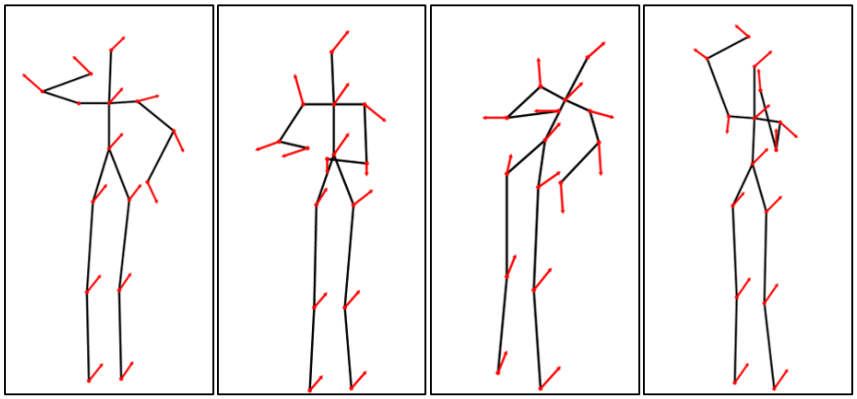

2. Ogni attività è codificata come un istogramma normalizzato di occorrenze di posture di riferimento in W.
   - Ogni vettore di feature è associato alla parola più vicina del dizionario.

Activity Recognition

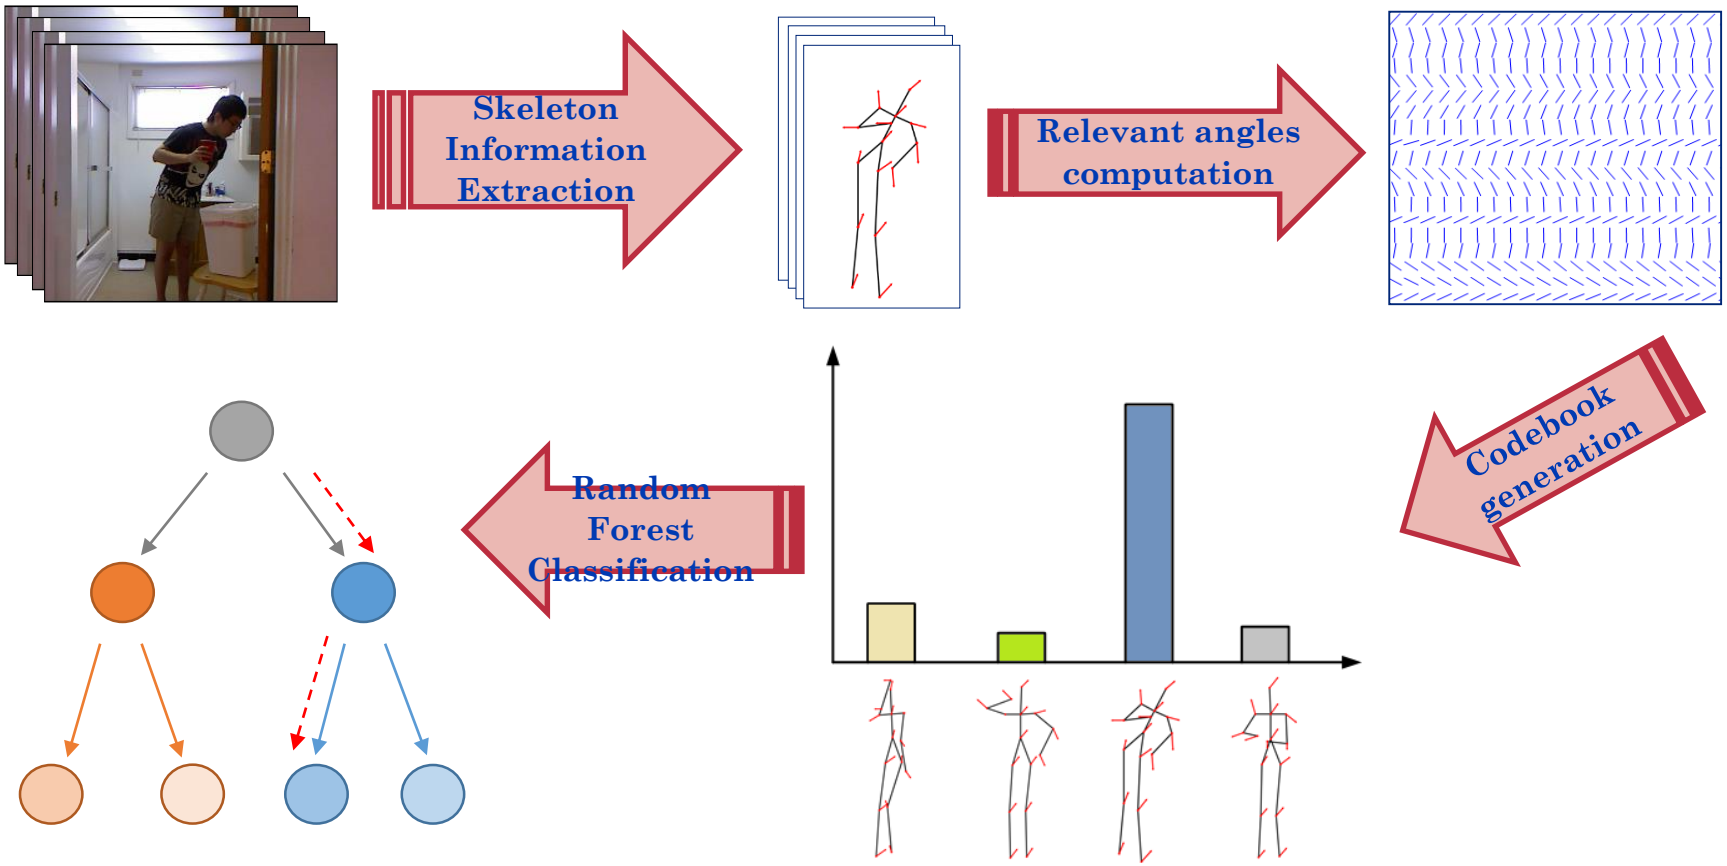

Temporal Image Gradient

- Miglior encoding dell'evoluzione temporale delle azioni.
- Cerca di catturate l'interazione dell'utente con gli oggetti.

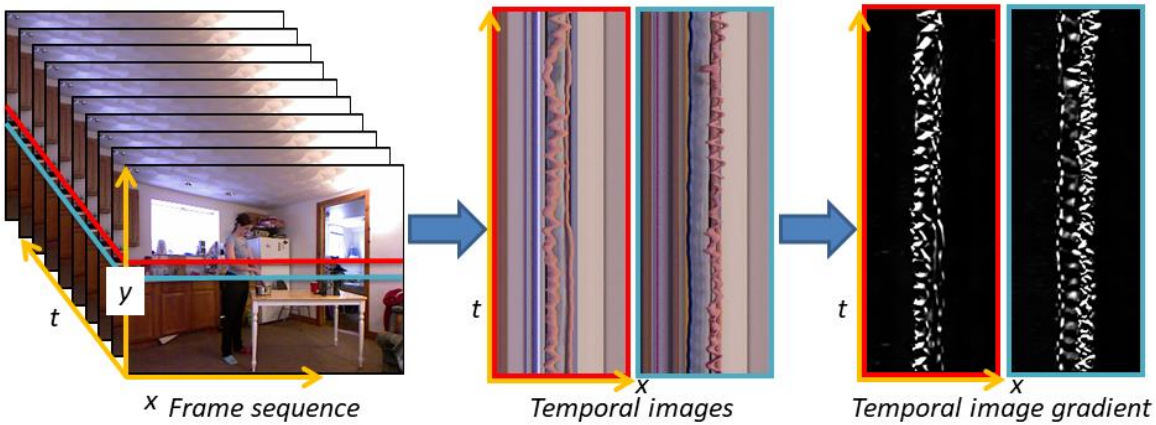

- Le immagini temporali sono sezioni del volume 3D che rappresenta la sequenza di frame.
- Rilevanti cambiamenti nel tempo (e pattern di movimento) sono chiaramente evidenziati nelle *Temporal Image Gradient* (TIG).
- Ogni frame è centrato rispetto al joint scheletrale corrispondente alla vita del soggetto e ritagliato ad una specifica dimensione.

Classificazione delle azioni
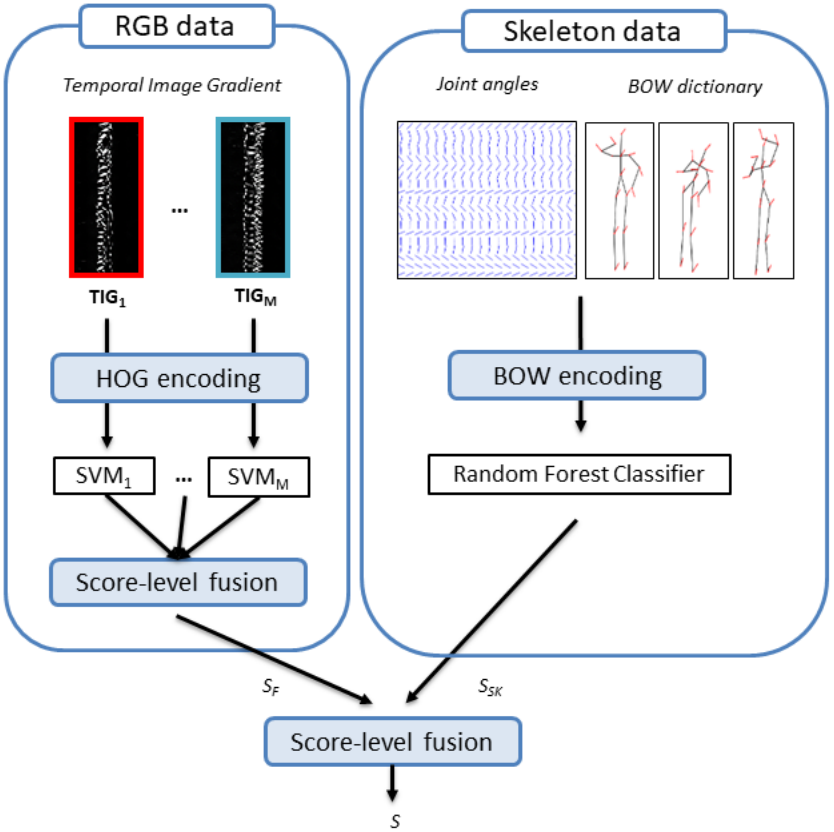
- La lunghezza delle sequenze video è variabile → TIG di differenti dimensioni.
- TIGs sono codificate tramite descrittori Histogram of Oriented Gradients (HOG):
  - Descrittori a lunghezza fissa con un numero fissato di blocchi.
- Il classificatore della componente RGB si compone di un insieme di M SVM lineari:
  - Ogni SVM rappresenta una specifica porzione del volume 3D della sequenza;
  - La classificazione è ottenuta tramite semplice fusione dei singoli score ottenuti dai singoli classificatori SVM.
- Gli output dei due classificatori sono quindi combinati (somma).